

Overview Tables - Research Data & Technology Reference

Datensätze

Name/Abkürzung	Paper	Erläuterung
CommonCrawl	<i>All</i>	Öffentlicher Web-Crawl mit Petabytes an Daten; primäre Quelle für alle drei Pipelines
RefinedWeb	<i>RefinedWeb, Nemotron</i>	5T Token englisches Dataset aus CommonCrawl (RefinedWeb); 600GT öffentlich verfügbar
RW-Raw	<i>RefinedWeb</i>	Minimale Filterung: nur Extraktion + Sprach-ID
RW-Filtered	<i>RefinedWeb</i>	Nach Dokumenten- und Zeilen-Filterung
The Pile	<i>All</i>	340GT kuratiertes Dataset mit 18% Web-Daten, 82% hochwertige Quellen (Bücher, Papers, etc.)
C4 (Colossal Clean Crawled Corpus)	<i>RefinedWeb, Nemotron</i>	~360GT aus CommonCrawl mit NSFW-Filterung und 3-Satz-Deduplizierung
OSCAR-21.09	<i>RefinedWeb</i>	~370GT Web-Daten mit Zeilen-basierter Deduplizierung
OSCAR-22.01	<i>RefinedWeb</i>	~283GT, neuere Version ohne Standard-Deduplizierung
DCLM (DataComp-LM)	<i>Nemotron, FineInstructions</i>	3.8T Token (1T unique), aggressive modellbasierte Filterung auf Instruktionsdaten
FineWeb-Edu	<i>Nemotron, FineInstructions</i>	1.3T Token (0.2T unique), fokussiert auf educational content

Name/Abkürzung	Paper	Erläuterung
FineWeb-Edu-2	Nemotron	5.4T Token (1.1T unique), erweiterte Version
Nemotron-CC	Nemotron	6.3T Token (4.4T real + 1.9T synthetic) aus CommonCrawl
Nemotron-CC-HQ	Nemotron	1.1T Token High-Quality Subset für faire Vergleiche
FineInstructions	FineInstructions	1B+ Instruction-Answer Paare aus ~18M Templates
WildChat	FineInstructions	657K User-Queries für Template-Erstellung
LMSys Chat	FineInstructions	559K User-Queries
Reddit QA	FineInstructions	7.47M User-Fragen
GooAQ	FineInstructions	3.01M Fragen aus Google-Suchen
BookCorpus	RefinedWeb	Frühe LLM-Trainingsdaten, dokumentfokussiert
Wikipedia	All	Hochwertige kuratierte Daten; explizit aus RefinedWeb/Nemotron-CC entfernt
IPT Corpus	FineInstructions	~23B Token aus RefinedWeb für Instruction Pre-Training

Technologie & Modelle

Name/Abkürzung	Paper	Erläuterung
MDR (MacroData Refinement)	RefinedWeb	Pipeline für Filterung und Deduplizierung bei sehr großem Maßstab
Trafilatura	RefinedWeb, Nemotron	HTML-zu-Text Extraktor; entfernt Menüs, Ads, Footer

Name/Abkürzung	Paper	Erläuterung
Justext	<i>Nemotron</i>	Alternativer HTML-Extraktor; höherer Token-Yield (+28.6% HQ tokens)
warcio	<i>RefinedWeb, Nemotron</i>	Bibliothek zum Lesen von WARC-Dateien (Web ARChive)
pycld2	<i>RefinedWeb, Nemotron</i>	Sprach-Identifikations-Tool
FastText lid176	<i>RefinedWeb, Nemotron</i>	Sprach-Klassifikator für 176 Sprachen (n-gram basiert)
MinHash	<i>All</i>	Locality-Sensitive Hashing für Fuzzy-Deduplizierung; approximiert Jaccard-Similarity
Exact Substring Deduplication	<i>All</i>	Suffix-Array-basiert; findet exakte Token-Matches ≥ 50 Tokens
KenLM	<i>Nemotron</i>	Perplexity-Filter basierend auf Wikipedia/Books-Modell
CCNet	<i>RefinedWeb, Nemotron</i>	CommonCrawl-Verarbeitungs-Pipeline mit FastText-Klassifikator
FineWeb-Edu Classifier	<i>Nemotron, FineInstructions</i>	Modellbasierter Qualitätsfilter für educational content (Scores 0-5)
DCLM Classifier	<i>Nemotron</i>	FastText-basiert; trainiert auf Instruktionsdaten + ELI5 Reddit
Mistral 8x22B-Instruct	<i>Nemotron</i>	LLM für Qualitäts-Annotation und Synthetic Data Generation
Nemotron-340B-Instruct	<i>Nemotron</i>	Großes LLM für Qualitäts-Scoring
Mistral NeMo 12B	<i>Nemotron</i>	Für Synthetic Data Generation (FP8 inference)
Llama-3.3 70B Instruct	<i>FineInstructions</i>	LLM für Silver-Standard Data Generation

Name/Abkürzung	Paper	Erläuterung
Llama-3.2 1B/3B Instruct	<i>FineInstructions</i>	Distilled Models für Query Genericizer und Instantiator
BGE-M3	<i>FineInstructions</i>	Embedding-Modell für Template-Document Matching
Flow Judge	<i>FineInstructions</i>	3.8B Parameter Judge-Modell (5-Punkt Likert-Skala)
Snowflake-arctic-embed-m	<i>Nemotron</i>	Embedding-Modell für Quality Classifier Training
GPT-3	<i>RefinedWeb, Nemotron</i>	Baseline-Modell für Vergleiche (175B Parameter)
GPT-4 / GPT-5 mini	<i>FineInstructions</i>	Judge-Modelle für Benchmark-Evaluation
PaLM	<i>RefinedWeb</i>	Google's Pathways Language Model (8B-540B)
Falcon-40B	<i>RefinedWeb</i>	Trainiert auf RefinedWeb; state-of-the-art bei Release
Llama 3.1	<i>Nemotron</i>	Meta's Modell (8B-405B); trainiert auf 15T Tokens
OPT	<i>RefinedWeb, Nemotron</i>	Open Pre-trained Transformer von Meta
Pythia	<i>RefinedWeb, Nemotron</i>	Suite von Modellen (70M-12B) für Deduplizierungs-Studien
Cerebras-GPT	<i>RefinedWeb</i>	Modelle mit μ -parametrization
ALiBi (Attention with Linear Biases)	<i>RefinedWeb, Nemotron</i>	Positional Encoding-Technik
FlashAttention	<i>RefinedWeb, Nemotron</i>	Effiziente Attention-Implementierung
SwiGLU	<i>FineInstructions</i>	Aktivierungsfunktion (Swish + GLU)
GQA (Grouped Query Attention)	<i>FineInstructions</i>	Effiziente Attention mit Query-Gruppen

Filter Strategien & Techniken

Name/Abkürzung	Paper	Erläuterung
URL Filtering	<i>RefinedWeb, Nemotron</i>	Blocklist (4.6M Domains) + URL-Scoring für NSFW/Spam
NSFW Filtering	<i>All</i>	Entfernung von pornografischen/gewalttätigen Inhalten
Language Identification	<i>All</i>	FastText-basiert; Threshold 0.3-0.65 für Spracherkennung
Repetition Removal	<i>RefinedWeb, Nemotron</i>	Entfernt Dokumente mit exzessiven Zeilen/Paragraph-Wiederholungen
Document-wise Filtering	<i>RefinedWeb, Nemotron</i>	Heuristische Filter für Länge, Symbol-zu-Wort-Ratio, etc.
Line-wise Corrections	<i>RefinedWeb, Nemotron</i>	Entfernt Navigation-Buttons, Social-Media-Counter, etc.
Fuzzy Deduplication	<i>All</i>	MinHash mit 9,000 Hashes/Dokument, 20 Buckets (RefinedWeb)
Exact Deduplication	<i>All</i>	Suffix-Array-basiert; ≥ 50 Token Matches
URL Deduplication	<i>RefinedWeb, Nemotron</i>	Entfernt URLs, die über Dumps hinweg revisited wurden
Global Deduplication	<i>Nemotron, FineInstructions</i>	Über alle Snapshots hinweg, nicht nur innerhalb
Perplexity Filtering	<i>Nemotron</i>	KenLM-basiert; entfernt low-quality Text
Quality Bucketing	<i>Nemotron</i>	20 Buckets (0-19) basierend auf Classifier-Ensemble
Quality Labeling	<i>Nemotron</i>	5 Kategorien: High, Medium-High, Medium, Medium-Low, Low
Annealing	<i>Nemotron</i>	50B Token Continued Pre-Training zur Bucket-Qualitäts-Messung

Name/Abkürzung	Paper	Erläuterung
Decontamination	<i>FineInstructions</i>	Entfernung von Benchmark-Overlap (Tulu 3 Prozedur)
Gaussian Pooling	<i>FineInstructions</i>	Custom Pooling für K Dokument-Chunks (K=5)
Ensemble Filtering	<i>Nemotron</i>	Maximum-Operation über 3 Classifier-Scores

Synthetic Data Generation

Name/Abkürzung	Paper	Erläuterung
SDG (Synthetic Data Generation)	<i>Nemotron, FineInstructions</i>	Generierung synthetischer Trainingsdaten
Wikipedia-Style Rephrasing	<i>Nemotron, FineInstructions</i>	Umschreibung in Wikipedia-Stil für low-quality Daten
Diverse QA Pairs	<i>Nemotron, FineInstructions</i>	Verschiedene Fragetypen (Yes/No, Open-ended, Multi-choice)
Distill	<i>Nemotron</i>	Kondensierung in prägnante Passagen
Extract Knowledge	<i>Nemotron</i>	Extraktion von Fakten unter Ignorierung uninformativer Inhalte
Knowledge List	<i>Nemotron</i>	Organisierte Listen von Key-Information
WRAP (Web Rephrase Augmented Pre-training)	<i>Nemotron, FineInstructions</i>	Baseline-Technik für Rephrasing
IPT (Instruction Pre-Training)	<i>FineInstructions</i>	Konvertierung von Dokumenten in Instruction-Answer Paare
Template Instantiation	<i>FineInstructions</i>	Füllen von Tags mit Dokument-Inhalten

Name/Abkürzung	Paper	Erläuterung
Query Genericizer	<i>FineInstructions</i>	Llama-3.2 1B Model; konvertiert Queries zu Templates
Instantiator Model	<i>FineInstructions</i>	Llama-3.2 3B Model; füllt Templates + generiert Antworten
Excerpt Tags	<i>FineInstructions</i>	...<...>... für effiziente lange Textgenerierung
Silver-Standard Data	<i>FineInstructions</i>	LLM-generierte Trainingsdaten für Distillation

Evaluation & Benchmarks

Name/Abkürzung	Paper	Erläuterung
MMLU (Massive Multitask Language Understanding)	<i>All</i>	57 akademische Tasks; Wissens-Benchmark
HellaSwag	<i>All</i>	Sentence Completion; Common Sense Reasoning
ARC-Easy / ARC-Challenge	<i>All</i>	AI2 Reasoning Challenge; Multiple Choice Science QA
Winogrande	<i>All</i>	Coreference Resolution; Common Sense
PIQA	<i>All</i>	Physical Interaction QA; Physical Common Sense
LAMBADA	<i>RefinedWeb</i>	Sentence Completion; Long-range Dependencies
BoolQ	<i>RefinedWeb, Nemotron</i>	Yes/No Questions; Reading Comprehension
COPA	<i>RefinedWeb</i>	Choice of Plausible Alternatives; Causal Reasoning
OpenBookQA	<i>RefinedWeb, Nemotron</i>	Multiple Choice mit externem Wissen
CommonsenseQA	<i>All</i>	Common Sense Knowledge QA

Name/Abkürzung	Paper	Erläuterung
Social IQA	Nemotron	Social Interaction Reasoning
RACE	Nemotron	Reading Comprehension from Examinations
MixEval	FineInstructions	Subset akademischer Benchmarks; korreliert mit Human Judgment
MT-Bench-101	FineInstructions	Multi-Turn Benchmark; realistische User-Queries (Likert 0-10)
AlpacaEval	FineInstructions	Head-to-head LLM Comparison; Length-Bias korrigiert
EAI Harness (Eleuther AI)	All	Standard Evaluation Framework
Perspective API	RefinedWeb, Nemotron	Toxicity-Messung ("rude or disrespectful")
ToxicBERT	FineInstructions	Toxicity Detection für Daten-Curation

Training Frameworks & Tools

Name/Abkürzung	Paper	Erläuterung
Megatron-LLM	RefinedWeb, Nemotron	NVIDIA Framework für LLM-Training
NeMo Curator	Nemotron	Open-Source Library für Data Curation (Apache 2.0)
DataDreamer	FineInstructions	Framework für Synthetic Data Generation
Lingua	FineInstructions	PyTorch Library für kontrollierte Pre-Training Ablations
TensorRT-LLM	Nemotron	NVIDIA Inference-Optimierung

Name/Abkürzung	Paper	Erläuterung
NeMo-Skills	Nemotron	Large-Scale Data Synthesis
FAISS	FineInstructions	Facebook AI Similarity Search; Retrieval Index
deduplicate-text-datasets	Nemotron	Google Library für Exact Substring Deduplication

Metriken und Konzepte

Name/Abkürzung	Paper	Erläuterung
Token Yield	All	Anzahl extrahierter Tokens nach Verarbeitung
HQ Tokens	All	High-Quality Tokens nach Classifier-Bewertung
Unique Tokens	All	Nach Global Fuzzy Deduplication; echte Diversität
Fuzzy Duplicates	All	~80% in FineWeb-Edu/DCLM; ~50% in RefinedWeb
Removal Rate	All	% entfernter Daten durch Filter/Deduplication
Jaccard Similarity	All	Maß für Set-Overlap; approximiert durch MinHash
Bits-per-Byte (BPB)	RefinedWeb, FineInstructions	Perplexity-Metrik für Language Modeling
Zero-Shot Performance	All	Modell-Performance ohne Task-spezifisches Fine-Tuning
Scaling Laws	All	Hoffmann et al. 2022: N (params) und D (data) gemeinsam skalieren
Chinchilla Optimal	RefinedWeb, Nemotron	~20 Tokens pro Parameter für optimales Training
Compute Budget (PF-days)	All	Petaflop-Tage; C = 6ND (Kaplan et al. 2020)

Name/Abkürzung	Paper	Erläuterung
Epochs	<i>All</i>	Durchläufe durch Dataset; >4 Epochs = diminishing returns
Contamination	<i>FineInstructions</i>	Benchmark-Overlap in Trainingsdaten
Length-Bias	<i>FineInstructions</i>	LLM-Judge bevorzugen längere Antworten
Win Rate	<i>FineInstructions</i>	% in Head-to-Head Vergleichen (AlpacaEval)
Likert Scale	<i>FineInstructions</i>	5- oder 10-Punkt Bewertungsskala

Architecture Components

Name/Abkürzung	Paper	Erläuterung
Transformer	<i>All</i>	Basis-Architektur für alle Modelle
Decoder-Only	<i>All</i>	Autoregressive Architektur (wie GPT)
Causal Language Modeling	<i>All</i>	Next-Token Prediction Objective
Instruction-Tuning	<i>All</i>	Fine-Tuning auf Instruction-Answer Paaren
Chat Template	<i>FineInstructions</i>	“Instruction: {{instruction}}: {{answer}}”
Context Length	<i>All</i>	Max Sequence Length (512-2000 Tokens je nach Task)
FP8 Inference	<i>Nemotron</i>	8-Bit Floating Point für effiziente Inference
μ -parametrization	<i>RefinedWeb</i>	Spezielle Initialisierung für bessere Skalierung
Rotary Embeddings	<i>RefinedWeb</i>	Alternative zu ALiBi für Positional Encoding

Name/Abkürzung	Paper	Erläuterung
Parallel Attention	<i>RefinedWeb</i>	Attention + FFN parallel statt sequentiell