

TU Dresden

Fakultät für Sprach-, Literatur- und Kulturwissenschaften

Institut für Germanistik

Professur für Angewandte Linguistik

Masterarbeit im Studiengang Germanistik

Maschinelle Analyse sprachlicher Muster in Risikoberichten

-

Konzeptionierung und Evaluation linguistischer Modelle zur Beschreibung
wirtschaftlicher Entwicklungen

Vorgelegt von: Franz Keilholz

Geburtsdatum: 17. September 1990

Betreuer/Erstgutachter: Prof. Dr. Joachim Scharloth

Zweitgutachter: Mihael Švitek M.A.

Adresse: Emil-Ueberall-Straße 25, 01159 Dresden

E-Mail: Franz.Keilholz@tu-dresden.de

Telefon: 0174/2086631

Matrikelnummer: 3681696

Eingereicht am 24. Januar 2017

Gliederung

1. Einleitung.....	1
2. Grundlagen der unternehmerischen Risikoberichterstattung.....	3
2.1. Unternehmenskommunikation – Risikokommunikation.....	3
2.2. Wirtschaftswissenschaftliche Risikobegriffe und Definitionen.....	4
3. Vorangegangene Forschungen zur Risikoberichterstattung.....	8
3.1. Manuelle Ansätze.....	9
3.2. Maschinelle Ansätze.....	12
3.3. Ansätze dieser Arbeiten.....	15
4. Methodische Grundlagen.....	16
4.1. Frame-Semantik.....	16
4.2. Korpuslinguistik.....	19
4.3. Korpuspragmatik.....	22
4.4. Grounded Theorie.....	24
5. Datengrundlage.....	26
5.1. Deutsche vs. amerikanische Wirtschaftsberichte.....	26
5.2. Datenauswahl – Unternehmen und Jahrgänge.....	31
5.3. Korpuserstellung.....	32
5.4. Wirtschaftliche Vergleichsbasis.....	35
5.5. Subkorporaerstellung.....	37
6. Phraseframeberechnung.....	39
6.1. N-Gram Konfiguration.....	39
6.2. Filter bei der Frameberechnung.....	40
6.3. Technische Umsetzung.....	42
7. Datenreduktion.....	45
7.1. Signifikanzberechnungen.....	46
7.2. Levenshtein-Distanzalgorithmus.....	48
7.3. Zusammenfassung.....	52
8. Modelltest.....	55
8.1. Korrelationsberechnung und vorläufige Ergebnisse.....	55
8.2. Optimierung.....	59
8.2.1 Wirtschaftswörterbücher.....	60
8.2.2 Wirtschaftliche Keywords.....	61

8.2.3 Adjektive.....	61
8.2.4 SentiWordNet.....	62
8.3. Ergebnisse der Optimierungen.....	63
9. Fazit und Ausblick.....	65
10. Literaturverzeichnis.....	69
11. Anhang.....	I
11.1. Unternehmen und Jahrgänge.....	I
11.2. Korrelationstabelle.....	VII
Selbstständigkeitserklärung.....	

Abbildungsverzeichnis

Abbildung 1: Long Tail Verteilung.....	41
Abbildung 2: Verteilung Frames auf Cluster.....	53
Abbildung 3: Korrelation Texas Instruments.....	58
Abbildung 4: Korrelationen: Alle Unternehmen mit Cluster.....	59
Abbildung 5: Optimierungsergebnisse.....	63

Tabellenverzeichnis

Tabelle 1: Anzahl Berichte nach Jahr.....	34
Tabelle 2: Beispiel Korpuszuordnung.....	38
Tabelle 3: Verteilung der Dokumente auf Subkorpora.....	39
Tabelle 4: Cluster Id 115 ">monthgin-bottom:#px"> XXX XXX of \$# million/billion. 54	
Tabelle 5: Rangkorrelation Texas Instruments Cluster: Bestes Jahr.....	56

1. Einleitung

Am 18.01.2017 veröffentlichte Finanzanalyst auf den Webseiten der Deutschen Börse eine Kolumne unter dem Titel: „Das neue Trump-Risiko“ (Goldberg, 2017a). Darin schildert Joachim Goldberg ein schwindendes Vertrauen von Investoren in Hinblick auf den designierten US-Präsidenten. In seinem Blog beschreibt er die Entwicklung näher: Es existiere ein gestiegenes Risikobewusstsein. Vor Trump hätten „die Investoren [...] besonders Angst vor einem Zerfall der EU, vor Bankenkrisen oder einem Crash im Bondmarkt“ (Goldberg, 2017b) gehabt. Diese Wahrnehmung verändere sich hin zu einer „Angst vor den negativen Folgen des Protektionismus sowie generell vor Fehlern in der US-Politik“ (ebd.).

Der designierte Präsident wird aus dieser Sicht zum Risikofaktor, welcher wiederum mit Ängsten verbunden ist. Die Wirtschaft reagiert, Goldberg führt Prognosen an und weist auf eventuelle Kurswechsel und Veränderungen hin. Er erörtert einerseits, dass sich die Emotionen zwar in Zahlen fassen und Risiken somit beziffern lassen, schreibt andererseits aber auch von einem *neuen* Risiko und *besonderen Ängsten*. Dabei werden vermeintlich objektive Darstellungen und emotionale Konnotationen vermischt. Goldberg zeigt die Mehrdeutigkeit des Risikobegriffes auf, welcher indirekt auch in dieser Arbeit untersucht werden soll. Dabei stehen allerdings nicht der Einfluss des President-elect auf die Weltwirtschaftslage oder irrationale Ängste im Zentrum, sondern es wird versucht, wirtschaftliches Risiko sprachlich zu fassen. Während Goldberg kurz- und mittelfristige Prognosen wagt, nutzt die Arbeit zurückliegende Daten, um ein Modell zu erstellen. Dieses soll in der Lage sein, Tendenzen wirtschaftlicher Verläufe über Verteilungen sprachlicher Muster auszumachen. Während Goldberg Veränderungen auf Basis einzelner Ereignisse beschreibt, werden hier Unternehmensberichte aus zehn Jahren genutzt, um Aussagen zu treffen.

Das Ziel, wirtschaftliche Entwicklungen mit sprachlichen Äußerungen zu verbinden ist nicht neu und die Risikoberichterstattung wird wirtschaftswissenschaftlich breit beforscht. Zentrale Fragestellung ranken sich dabei nicht nur um einzelne Aspekte der Offenlegung, sondern auch darum, wie sich Informationen möglichst effizient extrahieren lassen. Wenn allein der deutsche Geschäftsbericht der Volkswagen AG für das Jahr 2015 424 Seiten umfasst (Volkswagen AG, 2016), wird das Bedürfnis nach möglichst maschinellen Zugängen und Auswertungen nachvollziehbar. Insbesondere bei

Untersuchungen zu übergeordneten Entwicklungen muss automatisiert vorgegangen werden, da die dazu nötige Textmenge händisch kaum zu bewältigen ist.

An diesem Punkt setzt auch die vorliegende Arbeit an, geht jedoch über wirtschaftswissenschaftliche Untersuchungen hinaus, da mit komplexeren linguistischen Kategorien gearbeitet und korpuslinguistisch vorgegangen wird. Dabei werden, entgegen einem Großteil der bisherigen Ansätze, keine einzelnen Worte gezählt und ausgewertet, sondern alle Muster eines bestimmten Typs. Nachdem die Daten mit statistischen und algorithmischen Mitteln zusammengefasst wurden, sollen spezifische Verteilungen als Grundlage für Modelle dienen, die sich wiederum an wirtschaftlichen Kennzahlen testen lassen. Mit Hilfe von Korrelationsberechnungen werden anschließend etwaige Zusammenhänge überprüft. Aus den sprachlichen und wirtschaftlichen Daten der Vergangenheit kann somit bestenfalls ein Modell abgeleitet werden, welches in der Lage ist, zukünftige Entwicklungen zu prognostizieren. Zunächst wird jedoch versucht, die zurückliegenden Verläufe zu beschreiben. Dazu werden verschiedene Datensätze erhoben, evaluiert und angepasst, um resultierende Zwischenergebnisse zu optimieren und letztendlich ein möglichst realitätsnahes Modell zu generieren.

Zu Beginn der Arbeit wird auf die Grundlagen der wirtschaftlichen Risikokommunikation eingegangen und die Forschungen aus diesem Umfeld rezipiert, sodass sich der Unterschied zum hier verwendeten Ansatz weiter herausstellt. Der Diskussion wirtschaftlicher sowie linguistischer Grundlagen schließt sich ein angewandter Teil zur Datenerhebung, Musterberechnung und Datenreduktion an. Alle computergestützten Arbeitsschritte und Berechnungen wurden mit Hilfe von eigens entwickelten Skripten in der Programmiersprache Perl realisiert.

Die Arbeit verbindet wirtschaftswissenschaftliches und linguistisches Erkenntnisinteresse. Sie fußt zum Teil auf Vorarbeiten, die im Rahmen eines Moduls zum Forschen und Lehren im interdisziplinären Kontext an der TU Dresden in den Jahren 2015 und 2016 entstanden. Im Zuge dessen entwickelte sich eine fruchtbare Zusammenarbeit zwischen den Professuren für Betriebliches Rechnungswesen und Controlling unter Prof. Thomas Günther und der Angewandten Linguistik unter Prof. Joachim Scharloth. Diese Arbeit profitiert von der Interdisziplinarität und wäre ohne die Unterstützung beider nicht denkbar gewesen.

2. Grundlagen der unternehmerischen Risikoberichterstattung

Dieser Abschnitt soll die grundlegenden Motivationen von Unternehmen, über Risiken zu berichten, skizzieren. Es werden theoretische Annahmen zur Unternehmensbeziehungswise Risikokommunikation zusammengefasst und insbesondere wirtschaftswissenschaftliche Risikodefinitionen rezipiert. Auf der Basis soll eine Begriffsbestimmung erarbeitet werden, die sich für diese Arbeit eignet.

2.1. Unternehmenskommunikation – Risikokommunikation

Organisationen bestimmen das Leben von Menschen. Sie leben in und mit ihnen. Es sind Arten sozialer Netzwerke, die mittels Kommunikation bestimmte Bedürfnisse befriedigen und Probleme lösen. Die Organisationskommunikation untersucht dieses Spannungsfeld und die Unternehmenskommunikation spezifiziert den Rahmen, sobald es sich bei den Organisationen um wirtschaftliche Unternehmen handelt (vgl. Mast, 2015: S. 3). „Unternehmen basieren [...] auf Kommunikation. Sie sind zunächst beobachtbare Netze von Interaktionen, die geplant, regelmäßig und systematisch zwischen Menschen ablaufen“ (ebd.). Dass die Unternehmenskommunikation ein sehr breit gefächertes Gebiet beschreibt, wird durch die Definition von Lies deutlich: Demnach ist sie der Teil der Unternehmensführung, „der mit Hilfe des Wahrnehmungsmanagements die Reputation (Ruf) prägt“ (Lies, o. J.). Letztendlich lassen sich demnach nahezu alle kommunikativen Prozesse und Erzeugnisse unter dem Begriff der Unternehmenskommunikation fassen, so lange sie von wirtschaftlichen Organisationen hervorgebracht werden. Externe Kommunikation steuert das Vertrauen der Stakeholder¹ und hat die Etablierung eines vermeintlich guten Rufes in der interessierten Öffentlichkeit zum Ziel (vgl. Mast, 2015: S. 6). Die Bedeutung der Kommunikation fassen Schmid und Lyczek in drei Punkten zusammen: 1.) Produkte werden für den Kunden wahrnehmbar; 2.) Das Unternehmenshandeln und dessen Ziele werden durch den internen und externen Dialog definiert und 3.) Das Unternehmen verortet sich selbst im Umfeld der eigenen Stakeholdergruppen (vgl. Schmid, Lyczek, 2008: S. 133).

Für diese Arbeit sind Aspekte wie die interne Kommunikation, public relations, Werbung, Öffentlichkeitsarbeit etc. nicht näher von Belang, da sich die Untersuchung im Spannungsfeld der Risikoberichterstattung im Rahmen von Lageberichten ansiedeln

¹ Unter dem Begriff *Stakeholder* werden alle internen und externen Personengruppen gefasst, die direkt oder indirekt von den unternehmerischen Tätigkeiten betroffen sind (Vgl. Thommen, o. J.).

wird. Es wird daher ein spezifischer Teilbereich der Unternehmenskommunikation untersucht. Ohne dem Punkt 2.2 *Wirtschaftswissenschaftliche Risikobegriffe und Definitionen* vorgreifen zu wollen und näher auf etwaige Risikodefinitionen einzugehen, sei der Teilbereich entsprechend in der Kommunikation von wirtschaftlichen Risiken verortet.

Risiken entstehen zwangsweise, da sie für unternehmerische Tätigkeiten unvermeidbar sind (vgl. Zepp, 2009: S. 20). Deren Kommunikation wiederum begründet sich zum einen auf einer staatlichen Pflicht, zum anderen jedoch auch auf einer gesellschaftlichen Verantwortung der Unternehmen (vgl. Gassert, 2003: S. 30). Die Verminderung der Informationsasymmetrie zwischen Stakeholdern und Management kann zum Schutz der finanziellen Interessen von Investoren und einem besseren Unternehmensmanagement insgesamt beitragen (vgl. Dobler u. a., 2011: S. 2). Unternehmen wirken Stakeholdern und Rating-Agenturen gegenüber glaubwürdiger, was auf längere Sicht die weitere Finanzierung sicherstellt. Sexena, Dube und Mishra postulieren, dass aus einer vermeintlich gelungenen Risikokommunikationen Vorteile für den gesamten Finanzmarkt entstehen, da sich übergeordnete oder verbreitete Risiken verstehen und anschließend steuern lassen (vgl. Sexena u. a., 2015: S. 7). Bekannte Risiken und Unsicherheiten lassen sich besser steuern als Unbekannte.

Diese Arbeit stützt sich auf die Untersuchung von Risikoberichten wirtschaftlicher Unternehmen und wertet diese auf automatisiertem Weg aus. Auf die Extraktion der Berichte und rechtliche Grundlagen wird dabei in Punkt 5.1 *Deutsche vs. amerikanische Wirtschaftsberichte* näher eingegangen.

2.2. Wirtschaftswissenschaftliche Risikobegriffe und Definitionen

Der etymologische Ursprung des Begriffes *Risiko* ist nicht lückenlos belegt. Wahrscheinlich geht er auf das altgriechische Wort für *Wurzel* beziehungsweise *Klippe*: *rhiza* oder das italienische *risicare*, welches *abwägen*, *Gefahr laufen* meint, zurück. Risiko wird im alltäglichem Gebrauch, losgelöst von fachspezifischen Einschlügen zumeist negativ besetzt und mit Verlust, Gefahr oder Schaden assoziiert. Es handelt sich um ein subjektives Gefühl der Unsicherheit, verbunden mit der Annahme, zukünftige Entwicklungen nicht in ihrer Gänze beherrschen oder abschätzen zu können (vgl. Jacobsen, 2015: S. 9; vgl. Kajüter, 2012: S. 16).

An dieser Stelle soll keine globale Auseinandersetzung mit dem Risikobegriff folgen, geschweige denn versucht werden, eine möglichst umfangreiche Definition des

Terms zu liefern. Das ist im Rahmen der Arbeit weder möglich, noch zielführend, da Risikobegriffe in diversen Disziplinen eine zentrale Rolle einnehmen und auch dort unterschiedlich ausdefiniert werden. Kaack attestiert, dass vor allem entscheidungstheoretische Ansätze sowie „finanz-, bank-, und versicherungswirtschaftlich geformte Risikobegriffe“ (Kaack, 2012: S. 12) den modernen Diskurs dominieren, wobei auch in vermeintlich entfernten Bereichen wie den Umweltwissenschaften oder der Chemie unterschiedliche Definitionen zum Einsatz kommen. Auch sei an die Risiken und Nebenwirkungen in Verbindung mit Medikamenten gedacht. Eine übergeordnete Definition lässt sich somit nicht zufriedenstellend ausmachen. Trotzdem muss der Begriff im für diese Arbeit relevanten Spannungsfeld näher betrachtet und die betriebswirtschaftlichen Dimensionen erläutert werden.

In der Forschungsliteratur zu Risiken im wirtschaftswissenschaftlichen Umfeld besteht allerdings ebenfalls keine konsensfähige Bestimmung. Der Terminus lässt sich auch fachspezifisch nicht einheitlich fassen (vgl. Kaack, 2012: S. 13ff.). Die Definitionen scheiden sich bereits auf einer vergleichsweise basalen Ebene in der Frage, ob Risiken lediglich mit Schäden und Verlust verbunden werden oder auch mit möglichen Gewinnen. Wenn Wittmann beispielsweise das Risiko als „die Gefahr einer Fehlentscheidung“ (Wittmann, 1959: S. 189) bestimmt oder Hax von der „Gefahr des Misslingens“ (Hax, 2005: S. 32) spricht, so lässt dies keinen Spielraum für einen etwaigen Erfolg, es handelt sich um absolut negative Auswirkungen. Den Begriff weiter fassen Kürsten und Straßberger mit der „Möglichkeit des Abweichens zukünftiger Zielgrößen von ihrem geplantem beziehungsweise erwartetem Wert“ (Kürsten, Straßberger, 2004: S. 202). Die Definition ließe auch eine Abweichung in positiver Richtung zu, ohne dem Ausschlag den gesonderten Begriff *Chance* zuzuordnen. Explizit wird die Möglichkeit zwar nicht verhandelt, implizit scheinen *Chancen* dabei dem *Risiko* jedoch inhärent. Brühweiler vollzieht den weiteren Schritt. Er beschreibt mit *Risiko* eine Eintrittserwartung für explizit negative Ereignisse, der er bei einem positiven Verlauf die *Chance* entgegengesetzt. Es handle sich in beiden Fällen um „ungeplante Abweichungen von den Systemzielen“ (Brühwiler, 2001: S. 8). Jacobsen schließt sich dem an und beschreibt Chancen und Risiken als zwei Seiten einer Medaille. Er verweist damit auf den Charakter einer Streuung, welche sich um ein angestrebtes Ziel einstellt (vgl. Jacobsen, 2015: S. 10ff).

Ein Risiko besteht und entsteht nicht aus sich selbst heraus, es existiert nicht *per se*. Erst wenn es bestimmte Ziele zu erreichen gilt, entstehen auch Risiken, da diese verfehlt werden könnten. Je nachdem, welche Definition angelegt wird – entsprechend lediglich als mögliche Verlustrechnung oder auch als Schwankungen in den positiven Bereich. Risiken sind damit immer abhängig von individuellen Zielen. Sie sind subjektbezogen, wobei mit Subjekt eine Vielzahl von unterschiedlichen Entitäten gemeint sein kann: Von Einzelpersonen und Unternehmen bis hin zu Staaten. Im Umkehrschluss bedeutete das: Wenn ein bestimmter Einfluss, eine bestehende Zielsetzungen nicht in eine Richtung ablenkt, besteht in dem Sinne auch kein Risiko. Konjunkturschwankungen in bestimmten Märkten mögen zwar gewisse Unsicherheiten für Unternehmen, die nicht in diesen agieren, bergen, nach Kajüter besteht damit allerdings noch kein wirtschaftliches Risiko. (vgl. Kajüter, 2012: S. 16ff.).

Als vorerst letzte Bestimmung sei auf das Forscherteam um Sexena verwiesen: „The essential concept being that risk is a subjective idea about the real dangers or uncertainties of life that is faced by individuals and organizations that may not always be quantifiable.“ (Sexena u. a., 2015: S. 4). Die Definition liefert zwar keine neuen Erkenntnisse zum Begriff selbst, trifft sich allerdings mit den Annahmen in dieser Arbeit. Wenn Risiken nicht immer quantifizierbar, d.h., numerisch darstellbar sind, müssen sich Autoren auf eine Ebene der Beschreibung begeben. Diese wiederum sollte sich in sprachwissenschaftlichen Sinne identifizieren und analysieren lassen.

Systematisch kann sich dem wirtschaftswissenschaftlichen Risikobegriff von zwei übergeordneten Wegen aus angenähert werden. Der Erste geht auf einen Ansatz aus den 1920er Jahren von Frank H. Knight zurück (Knight, 1921). Er beschreibt Risiken aus einer *ursachenbezogenen* Perspektive. Sie entstehen auf Basis von unvollständigen Informationen bei der Entscheidungsfindung in Verbindung mit der Unsicherheit über zukünftige Ereignisse. Risiken sind demnach berechenbare Eintrittswahrscheinlichkeiten, die zunächst auf objektiven, also empirisch erfassten oder gesetzmäßigen Daten beruhen. So lassen sich beispielsweise Ausfälle durch Krankheit von Mitarbeitern, Wechselkursschwankungen etc. mit Hilfe von Statistiken ermitteln. Finden sich keine empirischen Grundlagen, so muss auf subjektive Schätzungen zurückgegriffen werden. Dem gegenüber steht die *Ungewissheit* für Zustände, die absolut nicht kalkulierbar sind (vgl. Kajüter, 2012: S. 16).

Investitionen, Umstrukturierungen und sämtliche betriebliche Entscheidungen können nicht *ideal* geplant und umgesetzt werden, da sich der Anspruch, *alle* relevanten

Informationen einbeziehen zu können, als utopisch erweist. Entscheidungen werden also immer auf Basis eines Ausschnittes, den tatsächlich vorliegenden Fakten, getroffen, sodass Unsicherheiten bleiben und Risiken entstehen. Ursachenbezogene Strategien im Risikomanagement zielen darauf ab, mögliche Konsequenzen *vor* der Entscheidung zu beeinflussen. Als zentrale Annahme ließe sich formulieren: Je mehr Informationen vorliegen, umso präziser können Ziele definiert und das damit verbundene Risiko minimiert werden (vgl. Jacobsen, 2015: S. 9–11; vgl. Kajüter, 2012: S. 16–17).

Wirkungsbezogene Sichtweisen hingegen stellen die Konsequenzen von Entscheidungen in den Vordergrund, sodass vor allem Abweichungen von Zielsetzungen nach vermeintlichen Fehlentscheidungen betrachtet werden. Die Abfederung steht im Mittelpunkt. Zentrale Konzepte und Strategien werden jedoch nicht erst im Eintrittsfall entwickelt, sondern in der Regel längerfristig geplant. Beispielhaft genannt sei zum einen die Risikovorsorge – ein Unternehmen kann den entstandenen Schaden selbst ausgleichen – und zum anderen der Risikotransfer – Schäden lassen sich abwälzen und etwa über Versicherungen begleichen. (vgl. Kaack, 2012: S. 14–15; vgl. Kajüter, 2012: S. 18, vgl. 2012: S. 187ff.).

Die vergleichsweise theoretischen Überlegungen schlagen sich im Umfeld der Risikobewertung in der folgenden Formel nieder, welche das Risiko als Produkt der bereits beschriebenen ursachen- (Eintrittswahrscheinlichkeit) und wirkungsbezogenen (Schadenshöhe) Dimensionen berechnet (vgl. Kajüter, 2012: S. 165):

$$\text{Risiko} = \text{Eintrittswahrscheinlichkeit} * \text{Schadenshöhe}$$

Obwohl die Gleichung mit dem Begriff *Schadenshöhe* auf einer sprachlichen Ebene vor allem einen vermeintlichen Verlust betrachtet, lässt sich theoretisch auch ein positives Ergebnis errechnen. Was in der Rechnung anklingt und auch in einigen Definitionen Einzug fand, wird in der Theorie in einem *engeren* oder *weiteren* Risikokonzept beschrieben. Während eine *enge* Definition lediglich Schaden und Verlust beschreibt, können Abweichungen von der Zielsetzung im positiven Sinne mit einem *weiten* Risikobegriff beschrieben werden. Wie bereits dargelegt, finden sich in der Literatur Belege für beide Sichtweisen, die gleichwertig nebeneinander Beachtung finden (vgl. Jacobsen, 2015: S. 9ff.; vgl. Kaack, 2012: S. 14ff.; vgl. Kajüter, 2012: S. 16ff; vgl. Katarzyna, 2009: S. 4ff.).

Letztendlich muss für diese Arbeit eine Definition erarbeitet und die Frage beantwortet werden, ob lediglich negative Konsequenzen des Risikos zu betrachten sind oder ob die Möglichkeit einer Streuung eingeräumt wird, sodass sich auch Chancen

abbilden ließen. Eine Antwort muss allerdings nicht zwingend auf argumentativer Ebene gesucht werden, sondern erschließt sich bereits aus den Methodiken und der Datengrundlage, die im Einzelnen noch vorgestellt werden. Es sei allerdings vorweggenommen, dass ein datengeleiteter Ansatz verfolgt wird. Demzufolge werden sprachliche Muster, ungeachtet des vermeintlichen Inhaltes zunächst berechnet und mit Hilfe statistischer Verfahren gefiltert. Inhaltliche Analysen werden somit an das Ende der Untersuchung gestellt und da Risikoberichte von Unternehmen als Basis dienen, werden entsprechend auch die Muster gefunden, welche eventuell mit Chancen in Verbindung stehen. Die Frage erübrigt sich somit nahezu vollständig und in dieser Arbeit wird allein aus methodischen Gründen ein weiter Risikobegriff genutzt. Selbstverständlich lassen sich Chancen in Abgrenzung zu Risiken auch nur dann auffinden, wenn Unternehmen diese in ihren Risikoberichten aktiv aufgreifen und in statistisch signifikanten Häufigkeiten nutzen. Mit dem datengeleiteten Ansatz geht entsprechend einher, dass lediglich Phänomene untersucht werden können, die tatsächlich vorhanden sind. Theoretische Diskussionen, inwieweit Chancen implizit verhandelt werden, lassen sich zunächst nicht führen. Dies ist jedoch auch nicht das Ziel der vorliegenden Arbeit. Darüber hinaus wird nicht versucht, einzelne Aspekte der Risikoberichterstattung detailliert zu beschreiben, sondern über Korrelationsberechnungen übergeordnete wirtschaftliche Entwicklungen aufzudecken. Der Risikobegriff dieser Arbeit ist in dem Sinne nochmals erweitert, da er alle statistisch relevanten sprachlichen Muster mit dem unternehmerischen Risiko über die Veränderungen wirtschaftlicher Kennzahlen in Verbindung bringt.

3. Vorangegangene Forschungen zur Risikoberichterstattung

Die Risikokommunikation von Unternehmen soll Investoren und Interessenten in die Lage versetzen, zukünftige Renditen und Entwicklungen abschätzen – Informationsasymmetrien sollen abgebaut werden (vgl. Kajüter, 2012: S. 178). Da in diesem Spannungsbereich entsprechende Summen gehandelt werden, ist es nicht verwunderlich, dass sich bereits eine Vielzahl von Studien und Untersuchungen den Berichten widmet. Um den vergleichsweise neuen Ansatz dieser Arbeit herausstellen zu können, sollen zunächst einige Untersuchungen vorgestellt, insbesondere auf deren methodisches Vorgehen eingegangen und eventuelle Ergebnisse verkürzt dargestellt werden. Da die Digitalisierung und deren Folgen auch in diesem Zusammenhang grundlegende Veränderungen in der Forschungspraxis mit sich brachte und immer noch

bringt, werden die Studien zunächst gegliedert in manuelle und computergestützte Vorgehensweisen.

3.1. Manuelle Ansätze

Zunächst sei zentral auf die Zusammenfassung der bisherigen Forschung von Li aus dem Jahr 2010 verwiesen (Li, 2010a). Er stellt fest, dass obwohl in der wirtschaftswissenschaftlichen Betrachtungsweise immer wieder Unsicherheiten in Bezug auf die Nützlichkeit textueller Informationen auftreten, diese jedoch unabdingbar seien, um Hypothesen zu überprüfen. Lediglich tabellarische und numerische Informationen reichen anscheinend nicht aus, um die Komplexität des Gegenstands zu beschreiben. Dies liege allein darin begründet, als dass Texte erörtern, welche Größen in wirtschaftliche Kennzahlen einfließen und wie sie berechnet werden. Aus einer Tabelle sei dies nicht herauszulesen. Dieser Punkt muss zentral hervorgehoben werden, da er beschreibt, dass Risiken sich eben nicht auf vergleichsweise einfache Zahlen herunterbrechen lassen. Dem Text wird ein Mehrwert zugesprochen (ebd.). Aufbauend auf Li werden daher auch nur Studien vorgestellt, die auch Texte auswerten und weniger die numerischen Angaben untersuchen.

Forschungen in diesem Feld, seinen nach Li übergeordnet insbesondere an drei Charakteristiken interessiert. Dabei handelt es sich um *the level* – wie viel wird ausgesagt, *the tone* – was wird gesagt – und *the transparency* – wie wird es gesagt. Ein Großteil der Studien versuche *the level* zu beschreiben, indem manuell bestimmte Kategorien untersucht werden, um den Umfang der Berichterstattung zu messen (vgl. Li, 2010b: S. 1054ff.).

Das *Level* wird beispielsweise von Elzahar und Hussainey in 72 Risikoberichten britischer Unternehmen mit Hilfe von Inhalts- und Regressionsanalysen zunächst jeweils beschrieben und dann verglichen. Risikorelevante Sätze wurden dazu unter der Maßgabe: „if the reader is informed of any opportunity or prospect, or of any hazard, danger, harm, threat or exposure“ (Elzahar, Hussainey, 2012: S. 140) identifiziert und entsprechend kategorisiert. Die Indikatoren wurden dabei anhand von Listen vorangegangener Forschungen erstellt und erweitert. Es geht bereits hervor, dass ein Leser (lediglich) informiert werden muss, sodass von einem subjektiven Ausschlag in der Studie auszugehen ist. Entsprechend der ermittelten Satzzahlen wird ein Score errechnet und mit wirtschaftlichen sowie betrieblichen Kennzahlen in Verbindung gesetzt. Demnach sei vor allem festzustellen, dass sowohl größere Unternehmen

quantitativ mehr über Risiken berichten als vergleichsweise Kleinere und auch der Sektor einen nicht unerheblichen Einfluss hat. Industrieunternehmen legen der Studie zu folge mehr offen als Dienstleister (vgl. Elzahar, Hussainey, 2012).

2004 findet sich in dem Ansatz von Beretta und Bozzolan verstärkt das Bestreben, auch den *tone* und *transparency* zu untersuchen. Die Analyse der Risikokommunikation wurde mit Hilfe eines eigens entwickeltes Frameworks durchgeführt. Im Rahmen der Studie wurden Risikoindizes ermittelt und diese wiederum mit Hilfe von Regressionsanalysen geprüft. Die erweiterte Betrachtung wurde durch ein vierdimensionales Modell repräsentiert. Dabei handelt es sich um „the content of information disclosed; the economic sign attributed to expected impacts; the type of measures used to quantify and qualify the expected impacts; (the outlook orientation of risk communication) and the managerial approach to the management of risks“ (Beretta, Bozzolan, 2004: S. 270). Ähnlich wie Elzahar wurde dazu auf Satzebene manuell nach Risikoindikatoren in den jeweiligen Dimensionen gesucht. Eine entsprechende Liste von Indikatoren wurde dabei genutzt und anschließend der Index für jede Dimension berechnet. Die Untersuchung kommt zu dem Ergebnis, dass die Unternehmensgröße zwar einen Einfluss auf die Quantität der Berichterstattung ausübt, jedoch nicht auf deren Qualität. Das Framework eigne sich daher, um Unternehmen größen- und brachenübergreifend zu vergleichen (Beretta, Bozzolan, 2004). Die Studie ließe sich jedoch ob ihres kleinen Samples von 85 Berichten italienischer Unternehmen eines Jahrgangs, kritisieren. Darüber hinaus wurden die Indikatoren zwar in einem mehrstufigen Verfahren evaluiert, nichtsdestotrotz lassen sich subjektive Einschläge nicht vollkommen vermeiden.

Der inhaltsanalytische Ansatz wird in den Untersuchungen relativ häufig genutzt. Linsely und Shrives analysierten etwa Berichte von 79 britischen Unternehmen, wobei auch sie auf Satzebene zunächst Risiken identifizierten und dann klassifizierten. Die Untersuchung stützt sich dabei nicht auf Wortlisten, sondern definiert einen Satz bereits dann als risikorelevant, „if it was considered that the reader was better informed about risks that have already had an impact upon the company, or may in the future have an impact upon the company, or if the reader is better informed about risk management within the company“ (Linsley, Shrives, 2005: S. 296). Selbst wenn der *reader*, wie in der Studie angegeben, wirtschaftswissenschaftlich erfahren ist und die Methodiken zunächst anhand von Proben, die mehrere Personen auswerten, diskutiert werden, so ist der Ansatz dennoch stark subjektiv. Allerdings lassen sich auf den

Auswertungen statistisch signifikante Ergebnisse eruieren. Ein Großteil der risikorelevanten Informationen bezieht sich demnach auf strategische Risiken, die allerdings häufig als „neutral“ kategorisiert wurden (vgl. Linsley, Shrives, 2005).

Ein ähnliches Vorgehen nutzten Abraham und Cox in einer Studie aus dem Jahr 2007. Darin wurden insgesamt 100 britische Risikoberichte untersucht. Einschätzungen hinsichtlich risikorelevanter Termini basierten wiederum auf coding sheets, in welchen Worte, Phrasen und Sätze nach inhaltlichen Schwerpunkten festgelegt wurden. Abraham und Cox sind sich der methodischen Kritikpunkte bewusst und versuchen die Subjektivität herauszufiltern, indem mehrere Personen die Listen erstellen und überarbeiten. Darüber hinaus wurden gleichartige Merkmale auf unterschiedliche Arten abgefragt. Statistische Übereinstimmungstests sollten die Ergebnisse mehrerer Beobachter auswerten und somit eine Art Goldstandard aufbauen. Letztendlich basiert der Ansatz allerdings auch auf einer vergleichsweise simplen Wortliste. Risiken wurden in drei Kategorien eingeteilt, die sich jeweils aus vier oder fünf Keywords und deren Derivaten ableiten ließen (vgl. Abraham, Cox, 2007: S. 235ff.). Die aus linguistischer Sicht stark verkürzte Darstellung von Risiko errechnet unter zur Hilfenahme von außertextlichen Informationen eine Reihe an Korrelationen. Ohne diese einzeln zu benennen, sei angemerkt, dass zwar rechnerische Modelle zu signifikanten Ergebnissen führen, auf einer methodischen Ebene sollten diese jedoch angezweifelt werden. Auch wenn die Listen mehrfach überprüft werden, Einschätzungen durch mehrere Hände bestätigt und statistische Verfahren auf der gewonnen Datengrundlage einen „Output“ produzieren, so wird doch versucht, komplette Narrative mit Hilfe von in diesem Fall neun Stichwörtern nicht nur zu ent- sondern auch abzudecken.

Zusammenfassend sei an dieser Stelle erneut Li zitiert, der die manuellen Auswertungen von Risikoberichten mit zwei zentralen Nachteilen beschreibt. Zum einen ist der Aufwand, um wirklich aussagekräftige Analysen durchzuführen, sehr hoch: Texte müssen einzeln gelesen und entsprechende Annotationen vorgenommen werden. Der zeitliche und personelle Umfang sei demnach zu groß. Größere Samples sind weder von einer Person händisch zu bearbeiten, noch von einem Team wirklich konsistent auszuwerten. Auf Grund der vergleichsweise kleinen Datengrundlagen lassen sich die Ergebnisse nicht generalisieren und auch die Aussagekraft sei eher als niedrig einzustufen. Daraus abgeleitet seien die Studien zum anderen auch schwer zu reproduzieren, da sie eben den beschriebenen, subjektiven Ansätzen folgen (vgl. Li, 2010a: S. 145ff.). Auch aus sprachwissenschaftlicher Sicht bieten die manuellen

Analysen der Berichte Ansatzpunkte für Kritik. Listenbasierte Vorgehensweisen müssen sich den Vorwurf gefallen lassen, dass eben nur Phänomene gefunden werden können, nach denen auch gesucht wird. Es werden demnach nur Strukturen gezählt und ausgewertet, die mit der vorangegangenen Theoriebildung kompatibel sind. Gegenargumente lassen sich nicht finden. Die Verkürzung des Gegenstands gepaart mit der zwar kundigen, doch immer noch händischen „Zählung“ bestimmter Indikatoren, kann in der Regel kein vergleichsweise komplexes Abbild der Wirklichkeit liefern. Statistische hoch signifikante Korrelationen mögen sich zwar errechnen lassen, der Wert sei jedoch ob deren Integrität angezweifelt.

3.2. Maschinelle Ansätze

Ein Großteil der geschilderten Problematiken, die mit einer manuellen Auswertung von Risikoberichterstattung einhergehen, sollen sich durch die Nutzung maschineller Verfahren eindämmen, wenn nicht gar vollständig lösen lassen. Die Ansätze gliedern sich in zwei übergeordnete Kategorien: 1. Wörterbuchbeziehungswise regelbasierte Vorgehensweisen und 2. statistische Methodiken (vgl. Li, 2010a: S. 146).

Wörterbuchbasierte Anwendungen beschreiben den verlängerten Arm von Inhaltsanalysen auf Listenbasis. Einem Programm wird eine vorab definierte Menge an Indikatoren übergeben und letztendlich vollzieht sich der gleiche Schritt, wie bei der Klassifikation durch einen Menschen. Die Textoberfläche wird abgeglichen und wenn ein bestimmtes Merkmal bei direkten Vergleich getroffen wurde, wird ein entsprechender Zähler erhöht. Dem manuellen Vorgehen ist die Methodik „lediglich“ durch die ihr innewohnende Systematik und Verarbeitungsgeschwindigkeit überlegen. Algorithmen können dabei beliebig komplex sein und neben Wörtern auch Phrasen oder Sätze untersuchen. Es ließe sich mit spezifischen Verteilungen arbeiten und so ganze Abschnitte klassifizieren. Letztendlich jedoch bildet die Grundlage immer ein vorab definierter Pool an Zeichenketten.

Davis, Piger und Sedor nutzen, wie auch Cho, Roberts und Patton, die Software DICTION² für ihre Analysen. Wie der Name bereits vermuten lässt, führt das

2 DICTION ist eine proprietäre Software, deren erste Version von Roderick P. Hart in den 1970er Jahren vorgestellt wurde. Hart ist Professor für Kommunikationswissenschaften an der University of Texas und publiziert unter anderem populärwissenschaftliche Werke zur politischen Kommunikation und Rhetorik (vgl. Hart, 2016). Die Software bietet 33 Wörterbücher beziehungsweise Wortlisten. Sie sind thematisch geordnet und können vom Benutzer nach den jeweiligen Vorgaben und Zielen gewählt werden. Zusammenfassend werden in fünf übergeordneten Kategorien Scores für die zu untersuchenden Texte bereitgestellt. Die aktuelle Version ist 7.0 (vgl. Diction, o. J.).

Programm Textanalysen mit Hilfe von Wörterbüchern durch. Es existieren diverse Schwerpunklisten, die beispielsweise auf Reden von Entscheidungsträgern, Politikern aber auch explizit annual reports etc. hin optimiert wurden. Die von DICTION gezählten Wörter werden anschließend „assigned to 35 theoretically based linguistic categories to characterize text on several dimensions“ (Davis u. a., 2012: S. 851). Auf diese Weise haben Davis, Piger und Sedor Pressemitteilungen untersucht und nach positiven beziehungsweise negativen Einschlägen gesucht. Die Software nutzt dazu „linguistics theory (e.g., optimistic words)“ (Davis u. a., 2012: S. 846). Sie stellen fest, dass ein „positiver“ Sprachgebrauch in den Pressemitteilungen Rückschlüsse auf eine ebenso positive Unternehmensentwicklung zulässt. Sie ziehen das Resümee, dass Anleger den Sprachgebrauch von Managern durchaus reflektieren und entsprechend bewerten (Davis u. a., 2012: S. 863).

Cho, Roberts und Patten bedienen sich in einer Studie ebenfalls DICTION und wenden die Verfahren auf 10-K Reports an. 10-K Reports sind Lageberichte amerikanischer Unternehmen. Sie dienen auch in dieser Arbeit als Datengrundlage und werden daher in Punkt 5.1 *Deutsche vs. amerikanische Wirtschaftsberichte* näher beschrieben. Das Team um Cho untersuchte insbesondere die Berichterstattung im Zusammenhang mit Umweltrisiken. Dazu ermittelten sie Werte für *Optimismus* und *Sicherheit* im Sinne von *Gewiss-* beziehungsweise *Bestimmtheit* (engl. *certainty*) in insgesamt 190 Berichten aus dem Jahr 2002. Es wird eine direkte Korrelation zwischen „worse enviromental performance“ und dem vermehrten Gebrauch optimistischer Sprache in den Berichten postuliert. Unternehmen, die eine „schlechte Umweltleistung“ erbringen, neigen demnach zu einer positiveren Berichterstattung als Unternehmen mit vergleichsweise besseren Leistungen. Darüber hinaus fänden sich Strategien der Verschleierung durch den Gebrauch einer „less certain language.“ (Cho u. a., 2010: S. 442).

DICTION wird in dieser Studie nur am Rande kritisch betrachtet. Zwar wird anerkannt, dass die berechneten Scores nicht in der Lage seien, subtile Äußerungen zu erfassen, die prinzipielle Verknappung von Komplexität durch die Arbeit mit Wörterbüchern wird allerdings nicht adressiert. Letztendlich wird die Verantwortung der Wortlistenerstellung, welche bei den manuellen Ansätzen in den Händen der Forscher selbst lag, um eine Instanz verschoben. Die prinzipiellen Nachteile, die mit regelbasierten Vorgehensweisen einhergehen, lassen sich nicht ausräumen und vervielfältigen sich unter Umständen. Wenn beispielsweise der Algorithmus auf das

Wort *increase* trifft, wird eventuell die Entscheidung getroffen, ob es positiv oder negativ zu Klassifizieren ist. Manuelle Untersuchungen können abschätzen, ob sich eventuell ein *Ertrag* erhöht oder aber sich *Ausgaben* erhöhen. Inwieweit das algorithmische Vorgehen von DICTION derartige Unsicherheiten fassen kann, kann an dieser Stelle nicht beurteilt werden. Die Software selbst und die damit verbundenen Analysemöglichkeiten seien dabei keineswegs per se absolut kritisiert oder deren Ergebnisse herabgewürdigt, sie müssten allerdings stärker reflektiert werden. Das Potential computergestützter Analysen wird damit nicht ausgenutzt.

Während Cho, Roberts und Patten das untersuchte Sample im Vergleich zu den meisten qualitativen Analysen bereits vergrößerten, finden sich in neueren Studien Ansätze mit sehr viel größeren Textmengen. Zu Korpuserstellung nutzten beispielsweise Kravet und Muslu nahezu die gleichen Verfahren wie diese Arbeit. Sie stellen mit Hilfe von Perl-Skripts automatisierte Anfragen an eine Datenbank und extrahieren so insgesamt 28100 10-K Berichte von 4315 Unternehmen aus den Jahren 1994 bis 2007. Die Untersuchung ist damit in der Lage auf längerfristige Entwicklungen einzugehen. Sie bezieht sich ähnlich wie viele der manuellen Ansätze auf inhaltsanalytische Schwerpunkte. Auch in diesem Fall werden Sätze auf Grund bestimmter Keywords als risikorelevant klassifiziert. Demnach liegt auch dieser Studie eine Wortliste zu Grunde. Sie wurde auf Basis einer manuellen Auswertung von 100 zufällig ausgewählten Berichten erstellt und führt insgesamt 15 Keywords. Die so gewonnen Werte wurden daraufhin mit wirtschaftlichen Entwicklungen in Beziehung gesetzt. Auf dieser methodischen Grundlage wurde eine Korrelation zwischen erhöhtem Handelsvolumen und Quantität der Risikoberichterstattung festgestellt. Als sehr zentral stellt die Untersuchung heraus, dass die Hypothese: Textuelle Abschnitte in Risikoberichten seien lediglich Bausteine oder Dummys, verworfen werden muss. Mit der gestiegenen quantitativen wie qualitativen Ausweitung textueller Offenlegung von Risiken gehe auch die Erhöhung der Risikowahrnehmung von Investoren einher (vgl. Kravet, Muslu, 2013).

Als vorerst letzte und gleichzeitig einzige Studie mit einem statistischen Ansatz, sei auf eine Untersuchung von Li aus dem Jahr 2010 verwiesen (Li, 2010b). In dieser wird der *tone in forward looking statements* untersucht. Mit *tone* beschreibt er dabei jedoch nicht, wie hier bereits eher besprochen, das *was wird berichtet*, sondern die vier Dimensionen: *positiv*, *negativ*, *neutral* und *nicht spezifiziert*. Da sich keine geeignete deutsche Entsprechung für die mit dem englischen Wort *tone* verknüpften

Konzepte finden lässt, wird der Begriff an dieser Stelle im Sinne der Dimensionen weiter genutzt. Im Vergleich der betrachteten Studien nutzt Li das größte Korpus. Er bezieht die Abschnitte zur *Management Discussion and Analysis* in 10-K und 10-Q³ Berichten aus den Jahren 1994 bis 2007 in die Untersuchung ein. Obwohl die Studie explizit untersucht, inwieweit statistische Verfahren rein wortlistenbasierten Ansätzen überlegen sind, kommt auch diese nicht vollständige ohne sie aus. Zur Identifikation der letztendlich 13 Millionen *forward looking statements* wurden Wortlisten mit zukunftsbezogener Lexik herangezogen. Mit Hilfe des Bayes-Klassifikators, einem wahrscheinlichkeitsbasierten Klassifikationsverfahrens, wurden die Statements entsprechend dem *tone* zugeordnet. Das maschinelle Lernverfahren benötigt Trainingsdaten, welche Li in Form von 30000 manuell annotierten Sätzen liefert. Das Verfahren klassifiziert die Statements in den vier übergeordneten Kategorien und ordnet sie darüber hinaus einer von zwölf Unterkategorien zu. Li kommt zu dem Ergebnis, dass der *tone* positiv mit der Unternehmensentwicklung korreliert, selbst dann, wenn Unterkategorien und wirtschaftliche Kennzahlen mit in die Berechnung einfließen. Der Zusammenhang ist allerdings an die Bedingung geknüpft, dass die Statements in die entsprechenden Dimensionen durch das maschinelle Lernverfahren klassifiziert wurden. Ein wörterbuchbasierter Ansatz wurde in der Studie ebenfalls getestet. Li beschreibt die listenbasierten Verfahren nach dem Abgleich der Ergebnisse als nicht geeignet zur Analyse von Risikoberichterstattung (vgl. Li, 2010b: S. 1050ff.).

3.3. Ansätze dieser Arbeiten

Ohne bereits auf Einzelheiten einzugehen, soll an dieser Stelle der prinzipielle Unterschied in der Vorgehensweise anderer Studien und dieser kurz erläutert werden. Alle Methodiken, die hier lediglich zur Übersicht genannt werden, werden in einzelnen Kapiteln vertieft.

Während sowohl die maschinellen als auch manuellen Ansätze der angerissenen Studien zumeist das Ziel hatten, anhand vergleichsweise weniger, vorab definierter Variablen das Risikoniveau von Unternehmen abzuschätzen, soll in dieser Arbeit globaler vorgegangen werden. Es werden nicht einzelne Wörter, Wortgruppen oder Sätze untersucht und das Ziel ist es auch nicht, Ergebnisse anhand singulärer Wertigkeiten festzumachen, sondern Tendenzen aufzuzeigen und nachvollziehbar zu machen. Der Unterschied zu den bisherigen Studien liegt insbesondere darin, dass an

³ 10-Q Berichte sind bei der Securities and Exchange Commission vierteljährlich einzureichen. Sie enthalten ähnliche wenn auch verkürzte Darstellungen wie 10-K Jahresabschlussberichte.

die Risikoberichte als Ganzes herangetreten wird. Es werden zunächst alle Muster eines bestimmten Typs in vorab definierten Korpora berechnet. Über deren Verteilung in den Korpora der einzelnen Unternehmen soll wiederum untersucht werden, ob spezifische Distributionen in der Lage sind, wirtschaftliche Entwicklungen widerzuspiegeln. Die Beschreibung bestimmter Muster als besonders aussagekräftig in Bezug auf die Unternehmensperformance wird daher nicht anhand einzelner Beispiele festgemacht, sondern über die Verteilung des spezifischen und signifikanten Sprachgebrauchs. Während etwa bei listenbasierten Ansätzen auch nur gelistete Phänomene gefunden werden können, geht diese Vorgehensweise darüber hinaus, da an das Korpus ohne ein solches „Vorwissen“ herangetreten wird. Weiterhin ist das Ziel dieser Arbeit nicht, prinzipielle Aussagen über die Quantität oder Qualität der Offenlegung zu machen. Zunächst soll untersucht werden, inwiefern die Nutzung bestimmter Muster in einen Zusammenhang mit der Unternehmensperformance gebracht werden kann und wie sich dieser systematisch beschreiben lässt.

4. Methodische Grundlagen

Obwohl die Arbeit sehr stark an angewandten Vorgehensweisen orientiert ist und insbesondere Datenerhebung, Analyse und Auswertung im Mittelpunkt stehen, müssen zunächst die theoretischen Grundlagen diskutiert werden. Die berechneten Muster und gewählten Ansätze sind korpuslinguistische Operationalisierungen übergeordneter Modelle, mit denen wiederum Aussagen zum Sprachgebrauch in bestimmten Korpora getroffen werden sollen. Das Kapitel wird daher die zu Grunde liegenden Annahmen zusammenfassen und zentrale Konzepte aufzeigen.

4.1. Frame-Semantik

Die Arbeit wählt einen frame-semantischen Ansatz, der mit Hilfe von diskontinuierlichen n-Grammen versucht, wirtschaftliche Entwicklungen zu beschreiben. Bevor die Operationalisierungen im Rahmen von Phraseframes beschrieben werden können, soll auf die konstruktionsgrammatischen Ursprünge der Theorie eingegangen werden. Dabei handelt es sich um eine Reihe grammatischer Modelle mit kognitivistischen Hintergrund. Sprache bilde einen geeigneten Zugang zu „Erforschung kognitiver Schemata“ (Wildgen, 1990: S. 66). Ein Kernpunkt nahezu aller Modelle findet sich in der Annahme, dass Sprache als ein System verschiedener Konstruktionen interpretiert wird. Obwohl die Vermutung nahe liegen könnte, meint

Konstruktion nicht gleich *Satz*, sondern referiert zunächst auf „konventionalisierte[...] linguistische[...] Ausdrücke“ (Fischer, Stefanowitch, 2006: S. 6) und fasst den Begriff damit weiter. Sätze können somit Konstruktionen bilden, doch auch kleinere oder größere Einheiten rekurrenter Ausdrücke lassen sich unter dem Term fassen. Bloomfield beschreibt Konstruktionen als „recurrent same of order“ (Bloomfield, 1926: S. 158). Derartige Strukturen sind kulturspezifisch, Bedeutungen werden pragmatisch definiert. Erst das kommunikative Ziel eines Ausdrucks ermöglicht eine Zuschreibung. Die Bedeutung einer Konstruktion erschließt sich nicht nur aus der Summe von Einzelbedeutungen der verwendeten Wörter, sondern gleichzeitig aus der Konstruktion selbst (vgl. Fischer, Stefanowitch, 2006: S. 89).

Konstruktionsgrammatische Theorien versuchen zumeist nicht, die Konstruktionen semantisch zu erläutern. Diesen Anspruch stellt die Frame-Semantik (vgl. Fischer, 2006: S. 345). Fillmore führt den Begriff *Frame* an und beschreibt damit *Deutungsrahmen* also *Wissenshintergründe*, *Kontexte* und *kognitive Schemata*, die für Interpretationen von Worten genutzt werden. Die Bedeutung einzelner Wörter erschließt sich demnach nicht aus sich selbst heraus, sondern erst im Zusammenhang mit allen anderen sprachlichen Elementen in einem Referenzrahmen (vgl. Fillmore, 1988; vgl. Fillmore, Atkins, 1992: S. 75ff.). Dieser Rahmen ist ein Frame. Unterschiedliche Wortbedeutungen sind somit auf unterschiedliche Kontexte zurückzuführen. Um ein Wort in seiner Bedeutung zu erfassen, sind mehrere ergänzende Elemente nötig (Fillmore, Atkins, 1992: S. 76). Derartige Zusammenhänge lassen sich als Netzwerke begreifen, die wiederum das gesamte sprachliche Wissen anhand untereinander verbundener Frames abbilden (vgl. Goldberg, 2003: S. 222ff.). In die einzelnen Frames fließen dabei nicht nur sprachliche Informationen mit ein, sondern alle Sinnesdaten (vgl. Ziem, 2005: S. 2).

Gegeben sei das folgende Szenario: „Nach dem Zwischenfall hat sich die letzte Reihe wieder beruhigt.“ Die sehr wenigen Informationen des Satzes reichen aus, um sich ein recht komplexes Bild der wahrscheinlichen Situation zu schaffen. Mit dem Verweis auf eine letzte Reihe beispielsweise wird das Geschehen in einer Unterrichtssituation verortet – eventuell an einer Schule oder Universität. Damit einher gehen Vorstellungen zu Räumlichkeiten, Sitzordnungen, beteiligten Personen, Hierarchien etc. Es lassen sich auch begründete Vermutungen über vorangegangene Handlungen und Zeiträume anstellen. Das *wieder* liefert Hinweise, dass der Zwischenfall den üblichen Ablauf, der bereits begonnen Unterrichtseinheit, hörbar

gestört und verzögert hat. Das Netzwerk verbundener Frames lässt sich bereits an diesem Beispiel verdeutlichen und gleichzeitig aufzeigen, dass Frames niemals isoliert für sich selbst stehen können. Informationen zu einzelnen Bedeutungen in spezifischen Situationen können erst über die Einbettung eines Phänomens in das Netzwerk aller Frames bezogen werden. Minsky beschreibt Frames daher zwar als kulturell fixierte, allerdings variable Wissensstrukturen:

„We can think of a frame as a network of nodes and relations. The “top levels” of a frame are fixed, and represent things that are always true about the supposed situation. The lower levels have many terminals–“slots” that must be filled by specific instances or data.“ (Minsky, 1975: S. 2).

Mit Slots und „must be filled“ beziehungsweise Fillern werden zentrale Elemente eines Frames definiert. Slots bezeichnen Leerstellen, die aufgefüllt werden können mit. Sprachwissenschaftlich lassen sich solche Deutungsrahmen auf verschiedene Arten fassen und rekonstruieren. Zunächst bieten sich Kollokationen an. Es handelt sich dabei um „häufig auftretende Wortverbindungen [...], die für eine Sprache oder einen Teilbereich einer Sprache charakteristisch sind“ (Bubenhofer, 2009: S. 112). Wenn entsprechende Wörter signifikant häufig in Verbindung miteinander auftreten, kann davon ausgegangen werden, dass sie im weitesten Sinne eines Frames verbunden sind. Damit sind sie sowohl für den Sprachgebrauch, als auch die Ordnung von Wissen relevant. Über die statistische Signifikanz wird der Framezusammenhang rekonstruiert. Während Kollokationen jedoch signifikante Wortverbindungen zumeist zweier Phänomene innerhalb definierter Grenzen meinen, lassen sich frame-semanticische Ansätze weiter denken und mit Hilfe von diskontinuierlichen n-Grammen beziehungsweise Phraseframes an den Framebegriff von Minsky heranzuführen.

Kontinuierliche N-Gramme bezeichnen zunächst eine Verbindung aus n aufeinander folgenden Einheiten. Indem Glieder dieser Ketten systematisch durch Leerstellen oder Slots ersetzt werden, die beliebig gefüllt werden können, entstehen Phraseframes, die der Beschreibung Minsky sehr nahe kommen (vgl. Bubenhofer, 2009: S. 183). Sie werden in dieser Arbeit korpuslinguistisch untersucht und entsprechend im Abschnitt 6. Phraseframeberechnung weiter vertieft betrachtet.

4.2. Korpuslinguistik

Die Korpuslinguistik gilt als eine zentrale Methodik der Linguistik und wird genutzt, um „Daten zu konservieren, zu strukturieren und gezielt zu analysieren“ (Scharloth, 2017: S. 2; vgl. Scharloth, Bubenhofer, 2011: S. 197). Korpuslinguistische Untersuchungen verfolgen daher das Ziel, „mehr über das Wesen der Sprache herauszufinden“ (Perkuhn u. a., 2012: S. 18). Der Begriff *Korpuslinguistik* legt nahe, dass es sich um eine sprachwissenschaftliche Dimension handelt, die, ähnlich wie andere sogenannte Bindestrich-Linguistiken, ein Erkenntnisinteresse in einem bestimmten Teilbereich der Sprache aufweisen. Die Soziolinguistik untersucht etwa den Sprachgebrauch von Gemeinschaften und betrachtet Sprache damit als soziales Phänomen; die Neurolinguistik erforscht neuronale Abläufe im Zusammenhang mit der Sprachproduktion und Rezeption im menschlichem Gehirn und die forensische Linguistik siedelt im Spannungsfeld zwischen Sprachwissenschaft und Kriminalistik. Vielen Teilbereichen ist insbesondere gemein, dass sie interdisziplinär verankert sind. Die Korpuslinguistik entzieht sich jedoch zumindest teilweise dieser Logik. Sie versucht mit Hilfe der namensgebenden Korpora, d.h. Sammlungen von Texten, sprachliche Theorien zu entwickeln beziehungsweise zu überprüfen. Da die Nutzung von Korpora als Belegquelle keine neue oder sehr moderne Entwicklung ist und beispielsweise die Lexikographie sich derer seit langem bedient (vgl. Scharloth, 2017: S. 2), muss hervorgehoben werden, dass die Korpuslinguistik Textsammlungen nicht lediglich als moderne „Zettelkästen“ betrachtet, sondern ihnen zugesteht, Aussagen über den Sprachgebrauch mit Hilfe von quantitativen Analysen machen zu können (vgl. Perkuhn, Belica, 2006: S. 2). Linguistische Fragestellungen werden operationalisiert, sodass sich Interpretationen an algorithmische Berechnungen und teilautomatisierte Auswertungen anschließen. Es lassen sich Hypothesen testen, aber auch neue Erkenntnisse über den Sprachgebrauch gewinnen. Letzteres wird durch die Identifikation von bezeichnenden sprachlichen Mustern über Signifikanzen ermöglicht. Somit werden Phänomene betrachtet, die in statistisch relevanten Häufigkeiten auftreten. Es werden Muster entdeckt, die bei der manuellen Analyse oder dem reinen Überprüfen von Hypothesen eventuell keine Beachtung fanden. Dazu ist ein einfaches Nachschlagen auf der Suche nach Belegen in „Zettelkästen“ nicht in der Lage.

Die Datengrundlage bilden dementsprechend nicht einzelne Texte, sondern eine möglichst große Anzahl. Nichtsdestotrotz können keine Rückschlüsse auf ein vermeintlich globales Sprachsystem gezogen werden, da – auch wenn zum Teil immens

große Korpora vorliegen – immer nur ein Ausschnitt *aller* möglichen Sprachdaten betrachtet werden kann (vgl. Bubenhofer, 2009: S. 16). Aus diesem Grund werden die untersuchten Textsammlungen nach bestimmten Kriterien zusammengestellt, die einer Forschungsfrage nachkommen oder aber anderweitig einen Zusammenhang bilden. Die Daten sind somit interpretiert.

Das Interesse liegt dabei an übergeordneten Erkenntnissen über den spezifischen Sprachgebrauch innerhalb des untersuchten Korpus. Der bereits angesprochene methodische Charakter wird deutlich. Es handelt sich weniger um ein eigenständiges Fachgebiet als um Konzepte und Ansätze, die den angrenzenden linguistischen Disziplinen bei der Untersuchung von Forschungsfragen zur Seite stehen. Im Kernbereich korpuslinguistischer Methodiken lassen sich zwei sehr unterschiedliche Herangehensweisen unterscheiden. Die eine nutzt Korpora, um vorab definierte Phänomene und Hypothesen zu überprüfen. Untersuchungen, wie die listenbasierten Ansätze, die in Punkt 3.1 *Manuelle Ansätze* und 3.2 *Maschinelle Ansätze* näher beschrieben wurden, ließen sich somit durchführen. Linguistisch annotierte Korpora und die entsprechende Software ist in der Lage, derartige Anfragen in kürzester Zeit zu beantworten. Die listenbasierten Ansätze ließen sich problemlos erweitern. Nichtsdestotrotz tritt man auf diese Weise an die Korpora lediglich in Form der bereits beschriebenen Zettelkästen heran. Solche Vorgehensweisen werden als *corpus-based* beziehungsweise deduktive Verfahren bezeichnet, in denen vorab definierte, theoretisch begründete Hypothesen getestet werden (vgl. Bubenhofer, 2009: S. 100ff.; vgl. Scharloth, 2017: S. 4). Dem gegenüber stehen Konzepte die *data-* beziehungsweise *corpus-driven* an die Textsammlungen herantreten. Erst diese Verfahren ermöglichen den Gewinn neuer Erkenntnisse über das reine Testen von Hypothesen hinaus, da sie die Daten selbst als Grundlage zur Entwicklung von Theorien nutzt. Sprachliche Muster werden dazu in großen Datenmengen induktiv berechnet und über signifikante Verteilungen Rückschlüsse auf rekurrentes Sprachhandeln gezogen. Die Theoriebildung schließt sich demnach der Berechnung an und ist ihr nicht vorangestellt (vgl. Scharloth, 2017: S. 4ff.).

Sowohl die Erstellung der Korpora als auch die Analyse selbst wird dabei durch die zunehmende Digitalisierung der Gesellschaft begünstigt (vgl. Scharloth, 2017: S. 3). Diskurse lassen sich nicht nur digital nachverfolgen – etwa in Form von Onlinezeitungen, Blogs, Twitter- oder Facebooktimelines – die *Zählbarkeit* der Dinge ermöglicht es außerdem, Daten mit mathematischen und informatischen Modellen zu

bearbeiten. Potentielle Grundlagen können somit extrem umfangreich sein und deren Möglichkeiten werden im aktuellen Diskurs um das Schlagwort *Big-Data* verhandelt (vgl. Scharloth, 2017: S. 3). Mit der Verfügbarkeit immer größerer Datengrundlagen geht jedoch auch einher, dass relevante von irrelevanten Informationen getrennt werden müssen, um dem Erkenntnisinteresse entgegen zu kommen. Dazu ist eine (teil-)automatisierte Verarbeitung nötig, was die Korpuslinguistik methodologisch zuweilen stark in Richtung der Informatik drängt. Im Zuge der Automatisierung ist die Verwendung von spezieller Software oder selbst geschriebener Skripts zur maschinellen Weiterverarbeitung der gewonnen Sprachdaten unabdingbar. Perkuhn und Belica meinen, dass zur Nutzung von korpuslinguistischen Methodiken kein sprachwissenschaftliches Hintergrundwissen erforderlich sei. Dieses werde erst gebraucht, um die Ergebnisse zu interpretieren (vgl. Perkuhn, Belica, 2006: S. 3). Dabei beziehen sie sich jedoch zunächst auf das rein mechanische Vorgehen, welches den Verfahrensweisen im Rahmen von Data-Mining nahe stehen. In diesem Punkt lässt sich der Aussage zustimmen, dem Erkenntnisgewinn ist das jedoch nicht zuträglich. Sollen linguistische Theorien deduktiv an Korpora untersucht werden, geht der Musterberechnung eine Hypothese voraus und insbesondere wenn an Korpora induktiv herangetreten wird, lässt sich die Aussage aus technischen Gründen nicht ohne weiteres halten. Selbstverständlich können rein hypothetisch *alle* Muster in einem Text berechnet werden. Die Basis bilden jedoch immer Algorithmen zum einen zur Mustererstellung und zum anderen zur Auswertung. Diese werden mit gewissen Zielsetzungen entwickelt, sie berechnen nicht wahllos alle Muster, sondern eher alle Vertreter bestimmter Muster. Darüber hinaus werden jedoch ganz im Sinne Perkuhns und Belicas die weiteren Interpretationen erst nach Vorfilterung der Daten und statistischen Auswertungen vorgenommen. Die Anwendung korpuslinguistischer Verfahren selbst setzt also nur bedingt linguistisches Wissen voraus, der Begriff *Anwendung* suggeriert jedoch auch bereits, dass weder auf die Datenauswahl, ein Preprocessing oder die anschließende Interpretation referiert wird, die selbstverständlich sprachwissenschaftliches Verständnis einfordern.

Obwohl der Begriff mehrfach bereits Verwendung fand, wurde das *Muster* noch nicht näher definiert. Nach Bubenhofer sind Muster im korpuslinguistischen Sinn zunächst Zeichenkomplexe wie Wortformen und Verbindungen mehrerer Wortformen untereinander. Auch „nichtsprachliche“ Elemente wie Sonderzeichen können Teil eines Musters sein. Sie dienen als Vorlage für weitere Zeichenkomplexe und sind gleichzeitig

selbst Teil der Phänomene (vgl. Bubenhofer, 2009: S. 23). Insbesondere der Dualismus zwischen einerseits als Vorlage dienend und andererseits selbst Teil der Ergebnismenge seiend, legt nahe, dass Muster nicht per se existieren. In Untersuchungen werden bestimmte Zeichenverkettungen demnach als Muster definiert, andere wiederum nicht. Die Entscheidung muss aktiv getroffen werden und hat einen entscheidenden Einfluss auf das Ergebnis. Sprachliche Muster lassen sich auf einem analytischen Level feststellen, im Rahmen des Sprachgebrauchs von SprechernInnen oder SchreiberInnen sind sie jedoch nur sehr vereinzelt wahrnehmbar. Sie können zwar im Nachhinein berechnet und identifiziert werden, im Zuge der Produktion bleiben sie aber Großteils unbemerkt (vgl. Bubenhofer, 2009: S. 24).

Während die traditionelle Korpuslinguistik die Textoberfläche nutzt, um Phänomene zu identifizieren und Strukturen aufzudecken, rücken die, mit den sprachlichen Äußerung verbundenen, Handlungen zunächst in den Hintergrund, da es sich in erster Linie um strukturelle Befunde handelt. Pragmatische Ansätze beziehen wiederum einen Äußerungskontext stark in die Beurteilung ein und um diesen am Korpus nachvollziehen zu können, mussten zunächst die grundlegenden Ansätze überdacht werden. Die Korpuspragmatik schlägt dabei die Brücke zwischen den beiden scheinbar schwer in Einklang zu bringenden Disziplinen.

4.3. Korpuspragmatik

Korpuspragmatische Ansätze gehen indirekt über die Textebene hinaus und bilden so pragmatische Konzepte nach. Musterberechnungen in Korpora fußen zwar auf der Zeichenebene, die Zwischenergebnisse werden jedoch mit Hilfe von statistischen Signifikanzberechnungen weiterverarbeitet. Die Resultate lassen sich interpretieren und sind in der Lage, Rückschlüsse auf Sprachhandlungen im Rahmen des untersuchten Korpus zuzulassen.

Zunächst sei jedoch auf die pragmatischen Ursprünge des Konzepts verwiesen. „[Die] Pragmatik als linguistische Teildisziplin erforscht das Handeln in und mit Sprache“ (Felder u. a., 2011: S. 3). Ihr eigen sind Kategorien, die eben nicht an der sprachlichen Oberfläche greifbar sind. Man denke beispielsweise an ironische Äußerungen: Dem Sprecher wird unterstellt, er meine das Gegenteil vom Gesagtem. Es handele sich mitunter um eine Strategie der impliziten Kritik. Der ironische Sprechakt kann dabei vom Hörer in einer definierten Situation als solcher erkannt werden, dem spielen ein spezifischer Kontext sowie verbale und nonverbale Ironiesignale zu (vgl.

Schwarz-Friesel, 2009: S. 223ff.). Im Rahmen von korpuslinguistischen Untersuchungen ließe sich der illokutionäre Akt wahrscheinlich nicht nachgewiesen, wodurch die Ironie als solche nicht zu erkennen sein dürfte. Die Betrachtung von Korpora als Sammlung von Sprachdaten ohne Kontext scheint daher schnell an ihre Grenzen zu stoßen.

Die Korpuspragmatik versucht deshalb nicht, die klassische Pragmatik strikt mit den Mitteln der Korpuslinguistik weiter zu betreiben, sondern setzt auf eine Verbindung der beiden Teildisziplinen. Zur Konstruktion beziehungsweise Rekonstruktion pragmatischer Bedeutungen müssen Strategien gefunden werden, die auf korpuslinguistisch erhobenen Daten beruhen können. Dabei muss zunächst konstatiert werden, dass sich derartige Bedeutungen nicht nur auf einer Ebene der Sprechakte manifestieren, sondern auch Zeichenhaft im Rahmen der Textoberfläche (vgl. Scharloth, 2017: S. 1). Im Zuge der pragmatischen Wende zu Beginn der 1980er Jahre vollzog sich nach Feilke eine Neuevaluation pragmatischer Grundannahmen. Schriftlichkeit gewann an Stellenwert und der *Text* als schriftliches Zeugnis, ohne die für die bisherige Forschung zentralen Bestandteile des im Raum und Zeit verankerten, dialogisch gebundenen Sprechhandelns rückt verstärkt in das Zentrum der Betrachtung. Weiterhin wird den Einheiten aller sprachlichen Strukturbereiche ein pragmatischer Mehrwert zugesprochen (vgl. Feilke, 2000: S. 77ff.). Diese Entwicklung verschiebt die linguistische Theoriebildung zu Gunsten der sprachlichen Oberfläche, da die Annahme geteilt wird, dass sprachlicher Kontext eben nicht a priori zur Beurteilung und Konstruktion von Bedeutung vorhanden sein muss, sondern sich auch gleichzeitig mit dem Sprachgebrauch manifestiert (vgl. Scharloth, 2017). Sprachhandlungen in einem Text werden demnach auch an dessen Oberfläche konstituiert, Rückschlüsse darauf lassen sich über signifikant häufig genutzte sprachliche Muster ziehen.

Charakteristische Muster verweisen damit auf spezifische Verwendungszwecke und Interpretationsrahmen. Ein Kontext wird bereits in diesem Rahmen mitgebildet und Rezipienten sind in der Lage, ihn zu erfassen. Besonders eindringlich lässt sich dies an stark formelhaften Textabschnitten, Äußerungen und Phrasen belegen. Ohne zu wissen, um was für Aussagen es sich im speziellen handelt, kann doch anhand von Äußerungen wie: „...von morgens bis zum Nachmittag ... liegen zwischen ... weitgehend sonnig vereinzelte Abschnitte“ (Scharloth, 2017; Scharloth, Bubenhofer, 2010: S. 85ff.) relativ eindeutig ein Wetterbericht kontextualisiert werden. Um den Schluss jedoch ziehen zu können, benötigen die HörerInnen oder LeserInnen ein Wissen um diesen typischen

Sprachgebrauch und damit verbundene Kontexte. Die Frame-Semantik, welche bereits näher erläutert wurde, beschreibt den Zusammenhang zwischen Konstruktionen und Weltwissen. Im Rahmen von korpuspragmatischen Forschungen werden sprachliche Muster daher induktiv berechnet, statistisch ausgewertet und daraufhin als „Muster mit soziokultureller Salienz“ (Scharloth, 2017: S. 5) interpretiert. Sie deuten auf rekurrente Sprachhandlungen hin. Die Arbeit setzt diesen Anspruch im Rahmen der frame-eemantischen Ansätze um. Signifikanzberechnungen fußen dabei wiederum auf unterschiedlichen Teilkorpora, denen eine Aussagekraft hinsichtlich bestimmter Kategorien zugesprochen wird. In den entsprechenden Punkten werden diese Ausführungen vertieft.

Felder, Müller und Vogel definieren die Ziele der Korpuspragmatik zusammenfassend folgendermaßen: Das Verhältnis zwischen sprachlichen Mitteln und Kontextfaktoren soll mit Hilfe von qualitativen und quantitativen Analyseverfahren innerhalb von digitalen Textsammlungen untersucht werden (vgl. Felder u. a., 2011: S. 4–5). Im speziellen wird dabei eine „Typik von Form-Funktion-Korrelation heraus[ge]arbeitet“ (Felder u. a., 2011: S. 4–5). Im Rahmen der Arbeit wird versucht, die Korrelation über den Gebrauch sprachlicher Muster in Risikoberichten in Verbindung mit wirtschaftlichen Kennzahlen zu beschreiben. Die korpuspragmatischen Ansprüche treffen sich produktiv mit den Entwicklungen der Korpuslingustik. Es werden vermehrt datengeleitete Vorgehensweisen, statistische Auswertungen, Ansätze des maschinellen Lernens und der Grounded Theorie genutzt, um derartige Zusammenhänge beschreiben.

4.4. Grounded Theorie

Da die Arbeit an Risikoberichte induktiv herantritt und mit signifikanten Phraseframes arbeitet, findet sich zunächst kein umfassender theoretischer Überbau. Es werden auch keine gezielten Hypothesen getestet. Ein Modell soll auf Basis der empirisch erhobenen Daten entwickelt werden. Diese Form der Theoriebildung lässt sich durch Ansätze der Grounded Theorie beschreiben. Modelle entstehen im Rahmen der Datenanalyse, verändern sich dabei stetig und differenzieren sich im Fortschreiten der Untersuchung immer weiter aus.

Glaser und Strauss plädierten in den 1960er Jahren darauf, Theorien auf Basis erhobener Daten zu generieren, anstatt „lediglich“ Hypothesen zu testen. Insbesondere im Rahmen der qualitativen Sozialforschung sollen empirisch erhobene Datensätze zur

Gewinnung theoretischer Grundlagen dienen (vgl. Glaser, Strauss, 2005: S. 12ff). Als theoretischen Unterbau entstand die Grounded Theorie, welche versucht, eine derartige Entwicklung zu systematisieren und zu operationalisieren. Die Grounded Theorie ist keine Theorie als solche, sondern liefert Methodiken, um auf Grundlage empirischer Forschung Theorien erst zu entwickeln (vgl. Clarke, 2012: S. 33). Sie ist gegenstandsverankert und spezifisch. Es werden keine universellen Modelle gebildet (vgl. Böhm, 1994: S. 121). Da korpuspragmatische Methodiken zunächst vergleichsweise theoriefrei an Sprachdaten herantreten, lassen sich die Annahmen der Grounded Theorie nutzen, um wiederum Modelle zu erstellen, die die Daten einordnen und in deren Spannungsfeld beschreiben.

Die Theoriegenese im Sinne der Grounded Theorie vollzieht sich durch einen mehrstufigen Prozesses aus das offenem, axialem und selektivem Kodieren. An dessen Ende ein steht Modell, „das als eine bereichsbezogene Theorie gelten kann“ (Scharloth, 2017: S. 8). Den Daten wird sich dabei im Zuge des offenen Kodierens zunächst sehr frei mit unterschiedlichen Methodiken und aus unterschiedlichen Blickwinkeln angenähert. Im Rahmen der empirischen Sozialforschung werden beispielsweise Samples analysiert und dabei sogenannte *Codes* anhand der von theoriegenerierenden „W-Fragen“ bestimmt (vgl. Mey, Mruck, 2010: S. 621). Diese wiederum lassen sich zu Kategorien zusammenfassen. Die Eigenschaften und Dimensionen der Kategorien sollen aufgedeckt und ein vermeintliches theoretisches Konzept „hinsichtlich seiner empirischen Relevanz [...] überprüf[t]“ (Truschkat u. a., 2005: S. 15) werden. Der Vorgang ist prozesshaft, Kategorien werden verworfen und wiederum Neue überprüft. Dieses Vorgehen ist symptomatisch für alle Kodierungsprozesse im Rahmen der Grounded Theorie: Sie befinden sich in ständiger Revision und werden stetig verändert (vgl. Scharloth, 2017: S. 8).

Kategorien, die sich im offenen Kodieren bewährt haben, werden anschließend beim axialen Kodieren hinsichtlich der empirischen Zusammenhänge untersucht und auf erweiterte Samples angewandt (vgl. Mey, Mruck, 2010: S. 621; vgl. Truschkat u. a., 2005: S. 15). Durch systematische Vergleiche von Kontexten lassen sie sich weiter gruppieren (vgl. Scharloth, 2017: S. 7). Ein vorläufiges Modell entsteht, welches getestet werden kann. Beim selektiven Kodieren werden die Ergebnisse validiert und Schlüsselkategorien identifiziert. Somit lässt sich eine Theorie beschreiben, welche die Phänomene bereichsspezifisch mit den jeweiligen Kontexten in Verbindung bringen beziehungsweise beschreiben kann.

Die angedachten Vorgehensweisen lassen sich nicht vollständig auf die vorliegende Arbeit übertragen, da sie zunächst von manuellen Kodierungsprozessen ausgehen. In dieser Arbeit wurden übergeordnete Kategorien – die Nutzung von Phraseframes etc. – bereits im Vorhinein festgelegt und nicht zunächst im Rahmen des offenen Kodierens erarbeitet. Rückt man die Arbeit jedoch in einen größeren Zusammenhang, so lässt sie sich komplett im Spannungsfeld der offenen Kodierung verorten, da zunächst überprüft wird, inwiefern sich die angelegte Kategorie zur Modellbildung eignet. Je nachdem, zu welchem Ergebnis gefunden wird, könnten weiterführende Forschungen die Kategorien verändern und eventuell andere Framekonfigurationen nutzen, um somit das Modell zu verbessern.

5. Datengrundlage

Nachdem grundlegende Annahmen sowohl zum sprachwissenschaftlichen als auch wirtschaftswissenschaftlichen Unterbau zusammengefasst wurden, soll die Datengrundlage der Arbeit in diesem Abschnitt zentral behandelt werden. Beschreibungen der konkreten Vorgehensweise zur Erstellung der unterschiedlichen Korpora folgen dabei zunächst einigen theoretischen Einführungen zur Textsammlung.

5.1. Deutsche vs. amerikanische Wirtschaftsberichte

Da sich entgegen dem Usus germanistischer Arbeiten hier auf englischsprachiges Material berufen wird, müssen die Gründe für diese Entscheidung aufgeführt und diskutiert werden. Es handelt sich dabei weniger um eine aktive Entscheidung *für* die amerikanischen Berichte, als mehr einen Entschluss gegen die Deutschen, aus vorrangig technischen Gründen.

Zunächst sei rekapituliert, dass in dieser Arbeit *Risikoberichte* untersucht werden sollen. Diese sind sowohl im amerikanischen wie auch im deutschen Raum Teil der *Lageberichte* beziehungsweise *annual reports* von börsennotierten Unternehmen aber nicht mit diesen gleichzusetzen. Es handelt sich jeweils um Ausschnitte, in denen über Risiken, mit welchen sich die einzelnen Unternehmen konfrontiert sehen, Auskunft gegeben wird. Die konkrete Gestaltung der Risikoberichte ist dabei unterschiedlich reglementiert. Im deutschsprachigen Raum hat der Vorstand einer Aktiengesellschaft für ein Risikomanagement Sorge zu tragen und ist verpflichtet, über Risiken im Lagebericht zu berichten. Insbesondere zukünftige Risiken sollen reflektiert und Schadenswahrscheinlichkeiten beziffert werden (vgl. Rogler, 2002: S. 1). Dies schlägt

sich im Aktiengesetz nieder, welches den Vorstand verpflichtet, Maßnahmen zu treffen, um „den Fortbestand der Gesellschaft gefährdende Entwicklungen früh [zu erkennen]“ (AktG §91 Abs. 2, o. J.). Es handelt sich entsprechend nicht zwingend um eine Weisung zur Berichterstattung, sondern vielmehr zunächst um interne Vorgaben, die jedoch nötig sind, um letztendlich über die Lage des Unternehmens Rechenschaft abzulegen.

Regelungen zur konkreten Kommunikation finden sich weiter im Handelsgesetzbuch. Demnach müssen Risiken wie auch Chancen begründet offengelegt werden. Es ist auf unterschiedliche Risiken, wie beispielsweise auf „Preisänderungs-, Ausfall- und Liquiditätsrisiken sowie die Risiken aus Zahlungsstromschwankungen“ (HGB §315 Abs. 2, o. J.) einzugehen. Im gleichen Paragraphen werden Informationen zur Forschung und Entwicklung, Zweigniederlassungen, Kapitalbeteiligungen, Befugnissen des Vorstandes etc. eingemahnt. Die Punkte im Einzelnen sind weniger relevant, ihr Kontext jedoch deutet auf die wenigen Reglementierungen zur Risikoberichterstattung im Allgemeinen hin. Wenn die Kommunikation von Risiken gleichwertig mit diesen Kategorien abgespeist wird, ist es nicht verwunderlich, dass sich im deutschsprachigen Raum ein sehr freier Umgang etabliert hat. Unternehmen sind zwar gezwungen, Berichte zu verfassen und haben inhaltliche Vorgaben, die Umsetzung obliegt ihnen jedoch. Wie umfangreich entsprechend Auskunft gegeben wird, in welchem Verhältnis Text und numerische Daten stehen, an welcher Stelle im Lagebericht über Risiken reflektiert wird etc. bleibt vollkommen offen. Die Berichterstattung im deutschen Raum erscheint daher recht unstrukturiert, zwar sind Inhalte grob vorgegeben, deren Layout und Position in Dokument allerdings nicht. Für die maschinelle Analyse großer Textmengen ist es jedoch unabdingbar, dass die entsprechenden Dokumente, in einem für die Maschine lesbaren Format, d.h., einheitlich, vorliegen oder zumindest die Rohmaterialien bis zu einem solchen Stadium bearbeitet werden können.

Aus den offenen Layout-Vorgaben folgen für die praktische Arbeit mit deutschsprachigen Texten gewichtige Nachteile. Die maschinelle Verarbeitung von Sprachdaten im korpuslinguistischen Spannungsfeld nutzt als Basis in der Regel *einfache* Texte, wobei *einfach* auf deren Formatierung referiert im Sinne von *plain* Text. Offene Formate lassen eine Rückführung in den simplen Text zu, sodass sich Inhalte filtern lassen. Wird beispielsweise mit einem Textverarbeitungsprogramm eine Überschrift fett geschrieben, erscheint diese zwar auf der Oberfläche mit eben diesem Merkmal – der Schriftsatz ist dicker – auf einer basalen Ebene wird dem Text jedoch

das Merkmal *Fett* sprichwörtlich hinzugeschrieben, indem beispielsweise mit Hilfe von HTML-Attributen oder einer beliebigen Markup-Language darauf verwiesen wird. Wie dies dann letztendlich realisiert wird, hängt von der genutzten Software - dem Browser oder Texteditor - ab, gemein ist ihnen jedoch, dass sie in den sogenannten what-you-see-is-what-you-get Editoren bereits vorverarbeitet werden und entsprechend die Überschrift auf dem Bildschirm fett ausgegeben wird (vgl. Myers, 1998). Das Merkmal wird zur Darstellung interpretiert und nicht selber ausgegeben. Wenn man **Überschrift** mit Hilfe von HTML-Code auszeichnen wollte, so sähe dies im nicht interpretierten Dokument beispielsweise folgendermaßen aus: `<b>Überschrift</b>`. Derartige Auszeichnungen sind bei der Korpuserstellung recht simpel herauszufiltern, da sie regelmäßig genutzt werden, um unterschiedliche Inhalte zu Kennzeichen und mit gleichen Tags auf gleiche Formatierungen zu verweisen. Sie helfen, die Daten zu strukturieren. Wenn neben der Auszeichnung für den Fettdruck die ebenfalls übliche Kennzeichnung *hl* gesetzt wird, so ist die Zeichenkette gleichzeitig auch als *Überschrift* fest definiert.

Die Auszeichnungen in spitzen Klammern sind nicht nur für HTML-Entitäten von Bedeutung, sie dienen auch in der Auszeichnungssprache XML zur Abgrenzung von Text und weiteren Informationen. Während eine HTML-Entität jedoch neben strukturellen auch Layoutinformationen – `<b>` beschreibt das *wie* nicht *was* der Darstellung – enthält, beschränken sich XML-Auszeichnungen auf eine Strukturierung des Inhaltes. Im Rahmen der Korpuserstellung und Annotation wird dabei verstärkt auf derartige Tags eingegangen. Lägen die deutschen Texte in einem HTML-Format oder bestenfalls als einfacher (plain) Text vor, ließen sie sich auslesen, weiterverarbeiten und nutzen.

In der Realität jedoch veröffentlichen Unternehmen ihre Wirtschaftsberichte im deutschsprachigem Raum vermehrt zwar im populären aber umso schwerer zugänglichen PDF Format. Der Vorteil des Formats liegt darin, dass es eben recht geschlossen ist und der Inhalt in der Regel nicht ohne weiteres geändert werden kann. Nahezu alle Endgeräte sind somit in der Lage, das betreffende Dokument zu öffnen, was bei anderen Formaten nicht immer der Fall ist. Die Standardisierung mag dabei für den Leser der Wirtschaftsberichte von Vorteil sein, dem maschinellen Zugang zu den Texten steht sie jedoch massiv im Weg. Das Format lässt sich nicht mehr von vermeintlich einfachen Editoren öffnen, sondern ist an bestimmte Programme gebunden. Entsprechend lässt es sich auch nicht ohne weiteres durchsuchen und auf der

maschinellen Ebene können die Texte nicht weiterverarbeitet werden. Technische Maßnahmen ermöglichen zwar, das Format zu öffnen und zurück in einen einfachen Text zu transferieren, Probleme entstehen jedoch dann durch unterschiedliche Formatierungen. Tabellen werden bei der Transformation nicht vollständig erkannt, Worttrennungen über Zeilen können zu Problemen führen und da die Berichte in der Regel unternehmensspezifisch gelayoutet sind, führt der Weg der Überführung in reinen Text zu einer Vielzahl von Fehlern, welche spezifisch bei jeder einzelnen Datei auftreten und händisch nachbearbeitet werden müssten. Dies kann nicht das Ziel einer automatisierten Verarbeitung sein und entsprechend sind die deutschsprachigen Berichte aus Sicht der Datenaufbereitung nicht effizient nutzbar. Neben den beschriebenen Schwierigkeiten, die Texte maschinell in ein verwertbares Format zu überführen, gestaltet sich im anschließenden Schritt die Extraktion der risikorelevanten Abschnitte als nahezu unmöglich, da die Dokumente nicht ansatzweise einer einheitlichen Struktur folgen. Zur automatisierten Identifikation derartiger Passagen ist eine solche Struktur jedoch unabdingbar, insbesondere wenn möglichst viele Texte akquiriert werden sollen und in der Folge ein sinnvoller Zugang zu den Abschnitten algorithmisch gefunden werden muss.

Neben den gerade beschriebenen Schwierigkeiten, resultiert jedoch noch ein weiteres schwerwiegendes Problem aus den gesetzlichen Grundlagen der Berichterstattung. Es wird gefordert, die Berichte im Bundesanzeiger⁴ zu veröffentlichen (HGB §325, o. J.). Lageberichte von Unternehmen sind jedoch nur ein Teilgebiet der vom Bundesanzeiger abgedeckten Veröffentlichungen, es finden sich u.a. auch gerichtliche und amtliche Abschnitte. Der Bundesanzeiger ist öffentlich zugänglich und dessen Inhalte den entsprechenden Webseiten einsehbar. Zur Korpuserstellung eignet sich das Portal allerdings nicht, da keine automatisierten Anfragen gestellt werden können und sich Berichte nicht systematisch erfassen lassen. Die Datenbank hinter der Suchmaske ist nicht zugänglich und selbst einmalige Anfragen müssen mit Captchas bestätigt werden, sodass ein Zugang über diesen Weg nahezu ausgeschlossen erscheint.

Die Lageberichte werden zumeist auch von Unternehmen auf den eigenen Internetauftritten veröffentlicht. Eine Korpuserstellung auf diesem Wege kommt jedoch nicht in Frage, da die Dokumente dezentral vorliegen und entsprechend händisch nicht

⁴ Der Bundesanzeiger dient zur Verbreitung amtlicher Mitteilungen und gesetzlich vorgeschriebener Bekanntmachungen. Letztendlich handelt es sich um einen Verlag (Matthias, o. J.).

nur zusammengetragen, sondern eben auch zugänglich gemacht werden müssen. Ein automatisiertes Abgreifen der Berichte von ausgewählten Unternehmen in dem hier angestrebten Umfang ist daher nicht möglich.

Anders verhält es sich im amerikanischen Raum. Unternehmen sind dort verpflichtet der *U.S. Securities and Exchange Commission* jährlich mehrere Berichte zuzusenden (vgl. United States Congress, 1934: Abschn. 13/15). Diese werden zentral gesammelt und der Öffentlichkeit in einer Datenbank zur Verfügung gestellt. Wie die Berichte im speziellen zugänglich gemacht wurden, wird im Rahmen der Korpuserstellung vertieft erläutert. Hier sei zunächst auf deren Vorteile eingegangen. Amerikanische *annual reports* folgen der bereits angeschnittenen 10-K Form. Insbesondere die Formate sind dabei hervorzuheben. Zum einen werden die Berichte als PDF veröffentlicht, zum anderen jedoch auch in einem HTML-Dokument, welches sich theoretisch simpel weiterverarbeiten lässt. Problematiken mit Umwandlungen von Formaten und daraus resultierenden Fehlern in Konvertierungen entfallen somit vollkommen. Darüber hinaus verlangt die 10-K Form eine bestimmte Struktur in den Berichten. So sind etwa Überschriften bis in den Wortlaut ausformuliert und ebenfalls Anforderungen an den Inhalt der entsprechenden Abschnitte definiert. Es lassen sich besonders risikoaffine Bereiche unter den Überschriften „*Item 1A. Risk Factors*“, „*Item 7. Management's Discussion and Analysis of Financial Condition and Results of Operations*.“ und „*Item 7A Quantitative and Qualitative Disclosures About Market Risk*“ identifizieren.⁵ Im Rahmen des automatischen Parsings wurden daher ausschließlich diese Bereiche gesucht. Die Weiterverarbeitung der Daten wird in den nächsten Punkten zur Datenaufbereitung vertieft erörtert.

Darüber hinaus eignet sich das englischsprachige Material, um innerhalb der internationalen wirtschaftswissenschaftlichen Community zu publizieren. Im Sinne weiterer Veröffentlichungen kann die somit erhöhte Reichweite als Argument für die Verlagerung angeführt werden.

Zusammenfassend lässt sich festhalten, dass sowohl technische Aspekte aber auch pragmatische, wirtschaftswissenschaftliche Interessen für die Analyse von Dokumenten aus dem amerikanischen Raum statt dem Deutschen sprechen. Insbesondere der vergleichsweise einfache Zugang und Möglichkeiten in der Datenweiterverarbeitung machen die Entscheidung beinahe alternativlos. Darüber hinaus ist davon auszugehen, dass die datengeleiteten Ansätze sprachunabhängig

⁵ Die Klassifikation beruht auf den Einschätzungen von Prof. Günther.

funktionieren. Entsprechende Modelle müssen sich daher auch mit deutschsprachigem Material bilden lassen. Derartige Vergleiche stehen jedoch nicht im Mittelpunkt dieser Arbeit.

5.2. Datenauswahl – Unternehmen und Jahrgänge

Nachdem amerikanische Dokumente gegenüber den deutschen Äquivalenten enorme Vorteile aufweisen, bleibt die Frage zu beantworten, von welchen Unternehmen die Risikoberichte untersucht werden sollen. Auf einer rein technischen Ebene ließe sich das gesamte Archiv der U.S. Securities and Exchange Commission durchsuchen, alle Berichte von 1994 bis aktuell 2016 herunterladen und nutzen. Zum einen ist dies jedoch vor dem Hintergrund der recht komplexen Berechnungen, welche entsprechend mit einem hohen zeitlichen Aufwand verbunden sind nicht sinnvoll. Zum anderen spricht auch die Zielsetzung der Arbeiten gegen einen derart globalen Ansatz, da damit gerechnet werden muss, dass die Daten sehr inkonsistent sind. Unternehmen ändern ihren Namen, gehen insolvent oder fusionieren. Würden entsprechend alle 10-K Berichte der Datenbank hinzugezogen, ließe sich das Ziel, Veränderungen im Gebrauch sprachlicher Mustern zunächst zu identifizieren und quantifizierbar auszuwerten, nicht unternehmensspezifisch verfolgen. Es ließen sich demnach Modelle nicht zielführend testen. Die Daten müssen einzelnen Unternehmen zugeordnet werden und entsprechend über einen längeren Zeitraum vorliegen, um gewonnen Theorien überprüfen zu können.

Auf Anraten von Professor Günther wurde sich daher auf die Unternehmen, welche im Standard and Poor's 500 (zukünftig als S&P 500 abgekürzt) Aktienindex geführt werden, beschränkt. Der Index wird von der Rating Agentur Standard and Poor's gepflegt und gibt insgesamt eine Übersicht über den Zustand des U.S.- Marktes. Es werden die 500 größten amerikanischen Unternehmen, welche ca. 80% des Kapitalmarktes abdecken, gelistet. Entscheidend für die Aufnahme ist die Marktkapitalisierung von mindestens 5,3 Milliarden US-Dollar. Sie ergibt sich aus dem Produkt des aktuellen Aktienkurses mit der Gesamtaktienanzahl und unterliegt daher starken Schwankungen. Um aufgenommen zu werden müssen unter anderem 50% der Unternehmensaktien dem Handel zur Verfügung stehen. Auch eine spezifische Zusammensetzung des Index in Hinblick auf Branchendiversität ist definiert (vgl. Standard & Poor's, 2016). Seit der ersten Veröffentlichung im Jahr 1957 änderten und ändern sich die geführten Unternehmen entsprechend, sodass mit einem bestimmten Stichtag auch eine spezielle Konstellation unterschiedlicher Unternehmen einhergeht.

Dieser Arbeit liegt der Stand aus dem Frühjahr 2016 zu Grunde.⁶ Als Ziel wurde angestrebt, Daten der einzelnen Unternehmen über einen Zeitraum von zehn Jahren, d.h., 2006 bis 2015 zu akquirieren.

Damit ist zum einen eine sinnvolle Operationalisierung zur Einschränkung der Unternehmen gefunden und zum anderen werden jedoch auch neue Problematiken in Bezug auf die Datenbasis geschaffen. Bedingt durch Neugründungen oder einem Börsengang nach 2006 ist es nicht zu erwarten, dass von allen gelisteten Unternehmen auch Dokumente über den gesamten Zeitraum vorliegen. Ein solcher Fall ist beispielsweise Facebook. Das Unternehmen existiert zwar bereits seit 2004, der Börsengang erfolgte jedoch erst 2012, sodass im Jahr 2013 der erste 10-K Bericht vorliegt (vgl. Buß, 2015). Auf der anderen Seite werden in den Daten auch Zeiträume abgedeckt, in denen ein Unternehmen nicht im S&P 500 gelistet wurde. Da sich die Entscheidung über eine Datenbasis jedoch strikt nach den Unternehmen im S&P 500 zu einem bestimmten Zeitpunkt richtet, müssen derartige Unregelmäßigkeiten in Kauf genommen werden. Darüber hinaus entsteht auch kein grundsätzliches methodisches Problem aus linguistischer Sicht, es wäre allerdings falsch zu behaupten, die Untersuchung würde sich jederzeit auf Unternehmen berufen, die immer im S&P 500 geführt wurden oder von denen zwingend zehn Dokumente vorliegen. Die Liste mit Unternehmensnamen wurde sowohl von Professor Günther als auch seiner Mitarbeiterin Deborah Nagel erstellt und zur Verfügung gestellt.

5.3. Korpuserstellung

Wie bereits beschrieben, liegen die englischsprachigen Wirtschaftsberichte öffentlich zugänglich auf den Seiten der *U.S. Securities and Exchange Commission* vor. Sie wurden mit Hilfe eines Perl Skriptes automatisiert heruntergeladen. Dieses erstellt zunächst eine URL, unter welcher die jeweiligen 10-K Berichte eines Unternehmens zu finden sind. Die Adresse wird aufgerufen und anschließend die Berichte in ihrer Textform gespeichert. Komplikationen stellten sich insbesondere durch die angesprochenen Namenswechsel oder Mehrdeutigkeiten ein. Frau Nagel war jedoch in der Lage bei den betreffenden Unternehmen die Änderungen nachzuvollziehen, sodass für nahezu alle Unternehmen entsprechende Berichte gefunden und heruntergeladen wurden. Die Dokumente wurden anschließend in ein XML-Format überführt. Die Auszeichnungssprache eignet sich, um Text übersichtlich aufzuarbeiten und dabei

⁶ Eine Übersicht findet sich in Anhang unter Punkt 11.1 *Unternehmen und Jahrgänge*. Es werden alle Unternehmen sowie die extrahierten Jahrgänge gelistet.

größtmögliche Maschinenlesbarkeit zu gewährleisten. Um die Datensätze über diese Masterarbeit hinaus nutzen zu können und Fragestellungen zu erweitern, wurden umfangreiche Annotationen vorgenommen, die nicht zwingend für die hier verfolgten Ziele notwendig sind. Das XML-Schema ist dabei zweckmäßig und folgt nicht etwaigen Anforderungen der Text Encoding Initiative.⁷ Letztendlich orientiert sich das Format vor allem an den Informationen, die die 10-K Berichte selbst liefern. Die Dokumente besitzen einen geordneten Header, der unter anderem Unternehmensnamen, Anschriften und Metainformationen listet. Diese wurden entsprechend beibehalten und überführt.

Für die weitere Arbeit mit den Daten ist es unerlässlich, die Unternehmen eindeutig in allen vorhandenen Jahrgängen zu identifizieren. Die bereits genannten Namensänderungen machen diese Zuordnung jedoch in den betreffenden Fällen unmöglich und obwohl die Header unterschiedliche Kennzahlen aufführen, finden sich doch keine eindeutigen Identifikationsnummern. Bei einer Analyse über mehrere Jahre hinweg könnte somit keine Relation zwischen ein und demselben Unternehmen hergestellt werden. Abhilfe schafft das nachträgliche Hinzufügen der International Securities Identification Number (ISIN). Dabei handelt es sich um eine zwölfstellige Kombination aus Buchstaben und Zahlen, welche ein Wertpapier weltweit eindeutig ausweist (vgl. International Organization for Standardization, 2013). Die Datensätze wurden wiederum von Frau Nagel bereitgestellt.

In den Dokumenten selbst findet sich zunächst kein *einfacher* Text, sondern ein Quelltext mit HTML-Auszeichnungen, welcher ausgelesen werden muss. Die Form ist allerdings nicht konsistent und verändert sich im Laufe der Jahre. Während vor allem in den frühen Jahrgängen HTML-Einschübe recht selten auftreten, finden sie sich vermehrt in den Späteren. Die zunächst trivial erscheinende Varianz im Aufbau erhält ihre Brisanz, wenn man versucht, die Texte maschinell zu verarbeiten und insbesondere dadurch, dass sie nicht von einem Jahrgang auf den nächsten global umgestellt wurde, sondern sich vielmehr schleichend entwickelte. Die für die Risikokommunikation entscheidenden Passagen der 10-K Form wurden bereits in Punkt 5.1 näher beschrieben und sollen aus den Lageberichten extrahiert werden. In der Theorie sollte demnach ein Parsing vergleichsweise schnell in der Lage sein, die entsprechenden Überschriften zu identifizieren und Abschnitte zu extrahieren. Der Ansatz scheitert jedoch an der Realität.

⁷ Die Text Encoding Initiative ist eine internationale Organisation, die umfassende Guidelines zur Codierung von Texten im Hinblick auf Standardisierungen und Maschinenlesbarkeit herausgibt (vgl. TEI, 2014). Da das Korpus jedoch nur in einem begrenztem Rahmen weiterverwendet wird, ist eine derart umfassende Annotation nicht zielführend.

Die Berichte sind weit weniger streng strukturiert, Überschriften sind nicht über alle Jahre hinweg konsistent und weiterhin folgen nicht unbedingt alle Unternehmen der Form oder lassen bestimmte Abschnitte schlicht aus. Nach ersten Versuchen zeigte sich darüber hinaus, dass sich die Form in den letzten zehn Jahren weiterentwickelte und entsprechende Vorgaben beispielsweise zu den Abschnittsbezeichnungen Änderungen unterzogen waren. Nichtsdestotrotz wurde ausgehend von den Überschriften ein Parser entwickelt, welcher allerdings im Funktionsumfang um kontextsensitive Komponenten erweitert wurde. Der Algorithmus ist in der Lage, einen Großteil der relevanten Abschnitte zu identifizieren. Soweit die Überschriften in den einzelnen Texten maschinell auszulesen waren, sind diese entsprechend in den Kopusdaten hinterlegt. Somit sind gezielte Analysen beispielsweise des *Items 1A Risk Factors* möglich. Eine Übersicht über die gewonnenen Texte in Bezug zum jeweiligen Jahrgang findet sich in Tabelle 1. Der Großteil des Parserquelltextes wurde von Professor Scharloth entwickelt, ohne dessen Unterstützung ein derartiges Ergebnis sowohl in Quantität als auch in Qualität nicht denkbar wäre.

Jahr	Anzahl Berichte	Jahr	Anzahl Berichte
2006	415	2011	449
2007	422	2012	455
2008	430	2013	461
2009	440	2014	465
2010	445	2015	474

Tabelle 1: Anzahl Berichte nach Jahr

Nachdem die risikorelevanten Texte extrahiert und in das XML-Schema eingebettet wurden, folgt eine syntaktische Annotation und Lemmatisierung mit Hilfe des *Treetaggers*. Die Software nutzt trainierte Modelle, um anhand derer Texte linguistisch anzureichern. Dabei werden die Daten zunächst tokenisiert, d.h. einzelne Worte werden identifiziert und unter anderem Funktionen interpretiert. Somit lassen sich satzbeendende Zeichen von beispielsweise Punkten unterscheiden, die auf Abkürzungen hindeuten. Den einzelnen Tokens werden dann Lemmata, also deren Grundformen hinzugefügt. So wird beispielsweise dem Token *risks* das Lemma *risk* angefügt oder *saw* entsprechend *see*. An diesem Beispiel lässt sich verdeutlichen, dass der Tagger in der Lage ist, Entscheidungen zu treffen. *Saw* ließe sich auch *saw* im Sinne von *Säge* zuordnen. Mit Hilfe von Entscheidungsbaumverfahren werden jedoch spezifische Lemmata auf Basis von statistischen Verteilungen zugewiesen.

Entsprechend wird nicht nur das einzelne Wort analysiert, sondern eine Zuschreibung über dessen Kontext vorgenommen. Die Annotation der Part of Speech Tags, also der Wortarten vollzieht sich gleichermaßen auf Basis der Modelle (vgl. Schmid, 1999, 1994). In den Korpora findet sich jedes Wort auf einer separaten Zeile mit den entsprechenden Informationen als Attribut eines XML-Tags, wie das folgende Beispiel des Wortes *saw*, welches mit dem Lemma *see* und dem Part of Speech Tag VVD (verb, past tense) versehen wurde, verdeutlichen soll:

```
<w pos="VVD" lemma="see">saw</w>
```

Die Korpusdaten sind nur noch umständlich für den menschlichen Betrachter zu erfassen, allerdings wird somit die maschinelle Weiterverarbeitung stark begünstigt.

5.4. Wirtschaftliche Vergleichsbasis

Um Veränderungen in den Risikokommunikationsstrategien von wirtschaftlichen Unternehmen mit Hilfe von linguistischen Ansätzen zu analysieren, müssen nicht nur die sprachwissenschaftlichen Grundlagen operationalisiert und systematisiert werden, sondern auch die Basis, auf derer man *Veränderung* definiert. Zunächst beschreiben Veränderungen Prozesse. Das Ziel, sprachliche Muster zu identifizieren und in einen Zusammenhang mit der wirtschaftlichen Entwicklung zu setzen, steht fest. Welche Jahrgänge Daten zur Berechnung beitragen sollen, muss allerdings spezifiziert werden.

In einer Vorarbeit mit ähnlicher Herangehensweise wurde ein Boom- und ein Krisenjahr definiert, von welchen ausgehend alle relevanten Muster über alle Unternehmen hinweg berechnet wurden (vgl. Bonazzi u. a., 2016). Der globale Ansatz soll in hier abgewandelt werden und einem vergleichsweise detaillierterem beziehungsweise individuellerem weichen. Die Problematik, wenn schlicht ein Jahr als Vergleichsbasis genutzt wird, ergibt sich daraus, dass damit angenommen wird, alle Unternehmen wären verlustbehaftet und die somit resultierende Risikokommunikation ließe sich als vermeintlich repräsentativ für ein *schlecht performtes Jahr* werten. Betrachtet man die Werte des S&P 500, so findet sich im Jahr 2009 ein deutlicher Ausschlag in den negativen Bereich. Für einen derartigen Ansatz ist das Jahr damit prädestiniert. Unterschiedliche Unternehmen sind jedoch unterschiedlich stark betroffen und mitunter konnten sie sogar mit Gewinn aus dem Krisenjahr hervorgehen, sodass diese Methodik Schwächen aufweist. Es erscheint sinnvoll, nicht die Daten eines Jahrgangs über alle Unternehmen hinweg als Basis zu nutzen, sondern vermehrt individuell anzusetzen.

Um für derartige Vergleiche eine Basis zu schaffen, müssen unternehmenseigene Kennzahlen gefunden werden, mit welchen vermeintlich gute von eher schlechten Jahren unterschieden werden können. Auch an dieser Stelle konnte Professor Günther die wirtschaftswissenschaftlich relevanten Informationen beisteuern und verwies auf den sogenannten Return on Assets Wert. Dabei handelt es sich um die Gesamtkapitalrendite, also um einen Prozentwert, welcher vereinfacht über den Quotient aus Reingewinn zuzüglich Fremdzinsen und Gesamtkapital gebildet wird (vgl. Hail, 2002: S. 54). Der Wert kann eine Auskunft zur wirtschaftlichen Lage eines Unternehmens geben. Die Kennzahlen der 500 Unternehmen über den Zeitraum von 2006 bis 2015 wurden wiederum von wirtschaftswissenschaftlicher Seite bereitgestellt und den Dokumenten im Korpus annotiert.

Den Erfolg von Unternehmen einzig anhand dieser Kennzahl festzumachen wird der wirtschaftlichen Realität sicherlich nicht gerecht, um jedoch im Rahmen dieser Arbeit eine Grundlage zu schaffen und eine Vergleichsbasis zu erstellen, eignet er sich durch seine vermeintliche Eindimensionalität. Allerdings stellt sich immer noch die Frage, welche Jahrgänge verglichen werden sollen. Aus einem naiven Ansatz heraus erscheint es naheliegend, das Jahr mit dem höchsten Wert und das mit dem niedrigstem zu wählen. Weiterhin läge die Überlegung nahe, sich eventuell auf gleitende Durchschnitte der Return on Assets zu berufen. Dabei handelt es sich um ein Glättungsverfahren, um längerfristige Entwicklungen mit in einem Modell zu berücksichtigen. Im Rahmen von Chartanalysen lassen sich auf diese Art Trends nachverfolgen (vgl. Murphy, 2006: S. 205ff.). Da mit der Gesamtkapitalrendite jeweils zehn Einzeldaten pro Unternehmen vorliegen, ließe sich der Durchschnitt über zwei Jahre nutzen, um übergeordnete Entwicklungen nachzuvollziehen. Durch die Berechnungen verlagern sich mitunter die erfolg- beziehungsweise verlustreichsten Jahre. Während bei Boeing beispielsweise nach den absoluten Return on Assets Werten 2008 das erfolgreichste Jahr markiert, findet sich in den geglätteten Werten das Jahr 2009 an dieser Stelle. Es muss wirtschaftswissenschaftliches Wissen einfließen, da die Entscheidung, welche Werte letztendlich genutzt werden von einem linguistischen Standpunkt nicht zufriedenstellend getroffen werden kann. Auf Anraten von Professor Günther werden daher die absoluten Werte genutzt, die Analyse jedoch nicht auf das Modell „bestes gegen schlechtestes Jahr pro Unternehmen“ verlagert, sondern es wird das beste Jahr im Vergleich zum Folgejahr genauso wie das schlechteste Jahr im Vergleich zum Folgejahr betrachtet. Weiterhin erscheint aus

wirtschaftswissenschaftlicher Sicht die Untersuchung von Datensätzen interessant, sobald ein Unternehmen eine negative Gesamtkapitalrendite aufweist. In diesem Fall wird zusätzlich das Jahr vor dem Vorzeichenwechsel untersucht.

5.5. Subkorporaerstellung

Die Vorgaben zur den relevanten Jahrgängen ließen sich die über mehrere Wege umsetzen, am sinnvollsten erscheint jedoch die Bildung von einzelnen Subkorpora mit einem entsprechenden Schwerpunkt. Somit finden sich letztendlich alle Texte mit beispielsweise negativen Return on Assets Werten in einer Textsammlung. Denkbar wäre auch, immer auf die Gesamtkorpora zuzugreifen und lediglich die relevanten Datensätze auszuwerten. Dies würde den zeitlichen Aufwand der Berechnungen jedoch immens vergrößern, sodass die Bildung von spezifischen Korpora vor allem gegen diesen Effekt steuern soll. Es entstehen sechs Textsammlungen:

- Korpus 1: Jahr mit der besten Performance
- Korpus 2: Nachfolgejahr zur besten Performance
- Korpus 3: Jahr mit der schlechtesten Performance
- Korpus 4: Nachfolgejahr der schlechtesten Performance
- Korpus 5: Jahr mit negativen Vorzeichen
- Korpus 6: Jahr vor dem negativem Vorzeichen

Im Rahmen der Subkorporaerstellung werden zunächst die relevanten Return on Assets Werte für jedes Unternehmen ermittelt. Dieser Schritt, wie auch die Erstellung selbst, erfolgt dabei auf Grundlage von Perl Skripts, welche die Sortieraufgaben automatisch bewältigen. Einschränkend sei selbstverständlich erwähnt, dass wenn 2006 das Jahr mit der schlechtesten oder besten Performance eines Unternehmens ist, sich kein Vorjahr ausmachen lässt. Sollte dies der Fall sein, so werden die Daten trotzdem mit in das Subkorpora aufgenommen. Aufgrund der Größe der Datensammlung ist nicht damit zu rechnen, dass auf diese Art und Weise die Ergebnisse in signifikanten Maße verfälscht werden. Die recht klare Beziehung zwischen Top beziehungsweise Flop Jahr und Vorjahr ist relativ simpel beschrieben. Beim Vorzeichenwechsel ist jedoch mit besonderen Konstellationen zu rechnen, die kurz erläutert werden sollen. Insgesamt finden sich 356 negative Return on Assets Werte. Nicht selten allerdings sind zwei direkt aufeinanderfolgende Jahrgänge eines Unternehmens betroffen. In dieser Arbeit sollen die Jahre mit einem negativen Vorzeichen mit den Vorjahren verglichen werden, sodass lediglich das Erste in das Subkorpora einfließt. Wenn beispielsweise die Jahre 2013 und 2014 negative Werte Aufweisen, wird 2013 in das Korpus aufgenommen. Weiterhin ist es nicht unüblich, dass Unternehmen über den Zeitraum mehrfach negative

Werte aufweisen, denen jedoch zwischendurch positive Jahre folgen. In solchen Fällen wurden mehrere Datensätze des Unternehmens erfasst. Durch diese Systematik überschneiden sich die Dokumente in den einzelnen Subkorpora zum Teil, da das Jahr mit dem Vorzeichenwechsel auch gleichzeitig das mit der vergleichsweise schlechtesten Performance generell sein kann oder ein Vorzeichenwechsel direkt auf das erfolgreichste Jahr folgt. Tabelle 2 verdeutlicht Anhand der Return on Assets Werte von Amazon.com welche Daten jeweils in welches Subkorpora einfließen.

Unternehmen: Amazon.com ISIN: US0231351067			
Year	Return on Assets	Erklärung	Korpus
2006	0.0862151654	Bestes Jahr	1
2007	0.0305220861	Nachfolge Bestes Jahr	2
2008	0.0582690105		
2009	0.0467560455		
2010	0.0480425858		
2011	0.0456237418		
2012	0.0194560729	Jahr vor negativem Vorzeichen	6
2013	-0.0009711282	Jahr mit negativem Vorzeichen	5
2014	0.0050270641	Jahr vor negativem Vorzeichen	6
2015	-0.003682531	Schlechtestes Jahr / Vorzeichenwechsel	3 / 5

Tabelle 2: Beispiel Korpuszuordnung

Deutlich wird, dass im Jahr 2015 sowohl die vergleichsweise schlechteste Performance als auch ein Vorzeichenwechsel zusammenfallen. Der Risikobericht findet sich demnach in beiden Subkorpora wieder. Darüber hinaus lassen sich in diesem Fall keine Daten für das Korpus 4 akquirieren, da diese aus dem Jahr 2016 stammen müssten. Obwohl derartige Konstellationen nicht die Mehrheit bilden, lässt sich doch ableiten, dass die Korpora unterschiedlich groß sein werden, da nicht alle Datensätze vorliegen. Dieser Effekt wird verstärkt, da nicht wirklich jeder Risikobericht beim Parsen der Dateien extrahiert werden konnte. Tabelle 3 gibt daher eine Übersicht über die Anzahl der Dokumente in den einzelnen Korpora. Während das Gesamtkorpus zwar zur Verfügung steht, beruhen alle weiteren Berechnungen im Rahmen der Frameberechnung auf den gebildeten Subkorpora.

Korpus	Anzahl Dokumente	Anzahl Wortformen
1	445	8366905
2	373	7738965
3	437	9654386
4	408	9142857
5	163	4414836
6	161	3971684

Tabelle 3: Verteilung der Dokumente auf Subkorpora

6. Phraseframeberechnung

Nachdem in den Punkten zur Frame-Semantik bereits grundlegend theoretisch auf den Aufbau und die Zusammensetzungen von Phraseframes eingegangen wurde, wird an dieser Stelle das technische Vorgehen erläutert und bereits auf einige Einschränkungen eingegangen. Diese sind nicht nur der Datenreduktion zuträglich, sondern verstehen sich auch im Rahmen der Grounded Theorie als Ansätze des offenen Kodierens. Dabei werden einige Prozesse übersprungen, da sich diese Arbeit grundsätzlich mit Phraseframes auseinandersetzt und somit hinsichtlich der übergeordneten Analysekategorie festgelegt ist. Im Zuge der Berechnung und Auswertung des Rohmaterials werden dann Einschränkungen vorgenommen, die eine Betrachtung relevanter Phänomene ermöglichen sollen, indem beispielsweise über Mindestanzahlen schwach frequentierte und damit vermeintlich uninteressante Datensätze nicht zur Kategorisierung beitragen können.

6.1. N-Gram Konfiguration

Die automatisierte Analyse von Texten bringt mit sich, dass die verwendeten Algorithmen auf vielfältige Arten konfiguriert werden können. In der Theorie ließen sich beispielsweise eine Vielzahl von unterschiedlichen Berechnungen durchführen und anschließend entscheiden, mit Hilfe welcher sich ein Modell bilden lässt, dass die Realität am ehesten widerspiegelt. Diese Freiheit besteht auf nahezu allen Ebenen. Im Zuge angewandter Untersuchungen müssen Einschränkungen vorgenommen werden, da das schiere Volumen der Ergebnisse keine sinnvollen Analysen mehr zuließe. Problematisch ist, dass sich viele der Entscheidungen nicht theoretisch einwandfrei begründen lassen und daher aus pragmatischen Gesichtspunkten heraus erfolgen beziehungsweise schlicht festgelegt werden müssen. Im Rahmen der Grounded Theorie

ließe sich dieser Schritt mit dem offenen Kodieren beschreiben, in dem zunächst Kategorien grob identifiziert werden.

Die Problematik verdeutlicht sich bereits beim Versuch zu begründen, ob sich zur Untersuchung der Risikokommunikation Phraseframes im Sinne von Trigrammen mit einer Leerstelle besser eignen als eventuell Heptagramme mit zwei Auslassungen. Auf Basis der derzeitigen Forschungen zu Phraseframes ist eine Beurteilung theoriegeleitet schlicht nicht möglich. Einzig durch die eher unbefriedigenden Ergebnisse der vorherigen Forschungsarbeit auf Basis der ähnlicher Daten lässt sich annehmen, dass Pentagramme mit zwei Auslassungen anscheinend nicht geeignet sind, um sinnvolle Ergebnisse zu modellieren (vgl. Bonazzi u. a., 2016). Um die vermeintlich idealen Konfigurationen der diskontinuierlichen n-Grammen zu bestimmen, müssen alle möglichen Typen getestet und deren Ergebnisse verglichen werden. Dabei handelt es sich jedoch um die Abstraktion der in dieser Arbeit untersuchten Thematiken, sodass dies momentan nicht möglich ist.

Im Rahmen der hier vorliegenden Untersuchung wird sich auf Hexagramme mit zwei Leerstellen berufen. Die Entscheidung beruht auf dem vermeintlich subjektiven Erkenntnissen der vorangegangene Arbeit, in der ein n-Gramm aus fünf Einheiten mit zwei Auslassung als zu kurz erachtet wurde. In den statistisch signifikanten Mustern konnten manuell nur sehr vereinzelt zufriedenstellende Frames nachvollzogen werden (vgl. Bonazzi u. a., 2016: S. 24ff.), sodass die Ausweitung um eine Einheit den Ergebnissen folgt.

6.2. Filter bei der Frameberechnung

Neben den Überlegungen zur allgemeinen Länge der n-Gramme, müssen auch Einschränkungen in Bezug auf Mindestfrequenzen getroffen werden. Korpuslinguistische Untersuchungen produzieren häufig Ergebnisse in sogenannten Long Tail Verteilungen. Wenigen hochfrequenten Phänomenen stehen sehr viele Muster entgegen, die vergleichsweise selten auftreten. Abbildung 1 soll diesen Effekt verdeutlichen. Darin wurden exemplarisch alle Frames des Korpus 1, also dem vermeintlich erfolgreichsten Unternehmensjahr, mit einer n-Gram Länge von sechs und jeweils zwei Auslassungen ihrer absoluten Frequenz nach geordnet und dargestellt. Obwohl eine Beschreibung der Frame Berechnung erst in Punkt 6.3 *Technische Umsetzung* folgt, sei mit dem vorgezogenen Beispiel auf die Prozesshaftigkeit der induktiven Vorgehensweise verwiesen. Es wurde zunächst getestet, welche

Einschränkungen sinnvoll erscheinen, um diese in die letztendliche Berechnung einfließen zu lassen.

Ohne weitere Reduktionen würden für das Korpus 74.688.655 unterschiedliche Frames erfasst. Das Diagramm zeigt eine stark abfallende Kurve lediglich der 210.000 häufigsten Frames, in welcher bereits die überwiegende Mehrheit vergleichsweise niederfrequent auftritt. Unter Hinzunahme aller Frames würde der Effekt noch weiter verstärkt, da der Long Tail noch wesentlich ausgeprägter aufträte.




Abbildung 1: Long Tail Verteilung

Würde man in weitere Berechnungen alle Daten einfließen lassen, stiege der Rechenaufwand in nicht mehr vertretbare Dimensionen. Filter müssen somit aus rein technischen Beweggründen eingesetzt werden. Allerdings sprechen auch andere Faktoren dafür, die Anzahl über Mindestfrequenzen zu beschneiden. Wenn beispielsweise ein Frame nur von einem Unternehmen genutzt wird, liegt die Vermutung nahe, dass es sich um die selbstreferentielle Nennung des Namens handelt oder starke Ausreißer. Sicherlich kann davon nicht in jedem Fall ausgegangen werden, die Berechnungen sollen jedoch übergeordnete Kommunikationsstrategien aufdecken, mit welchen sich bestenfalls zukünftige Entwicklungen prognostizieren lassen. Demnach kann es nicht Sinn und Zweck sein, Frames zu nutzen, die nur bei einem Unternehmen auftreten. Auch an dieser Stelle ist es problematisch, willkürlich eine

Mindestanzahl festzusetzen. Rechnerisch erscheint es allerdings nicht vollkommen abwegig, eine Grenze bei fünf Unternehmen zu ziehen, die einen einzigen Frame nutzen. Unter der Annahme, es stünden Datensätze von allen 500 Unternehmen zur Verfügung, müsste ein Frame also mindestens von 1% der Unternehmen genutzt werden. Damit lässt sich der Datenausstoß bereits um ein vielfaches eindämmen. Rein rechnerisch erscheint in dieser Logik eine prinzipielle Mindestfrequenz von 5 pro Frame als folgerichtig. Allerdings ist hier anzunehmen, dass der Nutzen derart niederfrequenter Phänomene in Anbetracht der schieren Anzahl eher zu vernachlässigen ist. Daher soll an dieser Stelle ein höheres Minimum eingeführt werden. Die Mindestfrequenz für einen einzelnen Frame wird entsprechend auf 25 festgesetzt.

Ein Frame muss also entweder über mehr als fünf Unternehmen verteilt sein oder aber von einer größeren Anzahl genutzt werden. Auch hier zeigt sich die zentrale Problematik. Da derartige Einschränkungen nicht zufriedenstellend objektiviert werden können, sind die genannten Ansatzpunkte und theoretischen Überlegungen durchaus anfechtbar. Nichtsdestotrotz sind die Begrenzungen notwendig, um mit den Daten im Sinne der Untersuchung von globalen Sprachgebrauchsmustern weiter arbeiten zu können, aus pragmatischen Beweggründen sind sie zwingend erforderlich. Daher werden sie auf alle weiteren Berechnungen angewandt.

6.3. Technische Umsetzung

Nachdem insbesondere für das Auszählen der einzelnen Frames Einschränkungen beschrieben wurden, soll die Berechnung selbst in diesem Punkt zentral abgehandelt werden. Auch in diesem Zusammenhang werden Möglichkeiten diskutiert, wie ein möglichst ökonomischer Datenausstoß zu realisieren ist.

Wie bereits beschrieben, handelt es sich bei Phraseframes zunächst um n-Gramme. Die Länge wurde auf sechs Einheiten festgesetzt. Auf der technischen Seite werden demnach zunächst sechs *Zeichenketten* zusammengefasst und anschließend Slots berechnet. Dabei muss es sich nicht zwingend um Worte handeln, auch Satz- sowie Sonderzeichen finden Beachtung. Entsprechend den Annotationen durch den Treetagger ist eine *Zeichenkette* in dem Zusammenhang die Information, die durch einen w-Tag beschrieben wird. Den Hexagrammen werden in einem weiteren Schritt systematisch Leerstellen hinzugefügt. Die Slots werden mit XXX gekennzeichnet. Die nachfolgende Aufstellung enthält alle, anhand des einen Hexagramms „carefully consider the following risk factors“ errechneten, Frames:

XXX XXX the following risk factors
 XXX consider XXX following risk factors
 XXX consider the XXX risk factors
 XXX consider the following XXX factors
 XXX consider the following risk XXX
 carefully XXX XXX following risk factors
 carefully XXX the XXX risk factors
 carefully XXX the following XXX factors
 carefully XXX the following risk XXX
 carefully consider XXX XXX risk factors
 carefully consider XXX following XXX factors
 carefully consider XXX following risk XXX
 carefully consider the XXX XXX factors
 carefully consider the XXX risk XXX
 carefully consider the following XXX XXX

Bei der Frameberechnung entsteht ein nicht unerheblicher Datenausstoß. Aus einem einzigen Hexagramm entstehen 15 Frames. Sobald sich das betrachtete Fenster um ein Wort verschiebt, entstehen erneut 15 mögliche Rahmen. Damit im Zusammenhang von weiteren Betrachtungen Vergleiche angestellt werden können, müssen zunächst alle Frames in allen Subkorpora ermittelt und zusammengezählt werden. So lässt sich die Gesamtanzahl der von den Unternehmen genutzten Frames eruieren. Die Rechnungen lässt sich nicht herkömmlich in einem Schritt verwirklichen, da hardwareseitige Beschränkungen, insbesondere durch überfüllte Arbeitsspeicher, auftreten. Im Rahmen eines Workarounds werden zunächst alle möglichen Frames eines n-Grammes ermittelt. Die Umwandlung der ersten drei Buchstaben in deren Entsprechung im ASCII-Code ermöglicht es, Dateien mit numerischen Namen zu generieren, in welchen die Frames zunächst abgelegt werden können. Die Daten des obigen Beispieles würden so in zwei unterschiedliche Dateien geschrieben. Bei diesem Schritt werden die Frames nicht gezählt. Das sofortige Übertragen auf die Festplatte entlastet allerdings Arbeitsspeicherressourcen und macht die Erhebung der Daten erst möglich.

Bei der Berechnung der Frames werden bereits einige Vorarbeiten zur weiteren Reduktion des Datenausstoßes beschrieben. So werden sämtliche Majuskel in Minuskel umgewandelt, um bei der späteren Zählung oder sonstigen Abgleichen auf Zeichenebene möglichen Komplikationen vorzubeugen. Diese können allein daraus entstehen, dass ein Frame sowohl am Anfang als auch an späterer Stelle im Satz genutzt werden kann. Die vermeintlich triviale Großschreibung am Satzanfang führt auf der Ebene der maschinellen Weiterverarbeitung dazu, dass zwei unterschiedliche Frames erkannt würden. Auf einer qualitativen Ebene finden sich durchaus Beweggründe, den

Satzanfang als vermeintliche Sonderform beizubehalten, durch die Betrachtung größerer Korpora und in dem Bestreben, Datenmengen handhabbar zu gestalten, scheint die Abstraktion jedoch sinnvoll.

Weiterhin wurden die Frames ausschließlich innerhalb der Satzgrenzen berechnet. Da die Risikoberichte im Zuge der Datenaufbereitung mit Part of Speech Tags versehen wurden, lässt sich diese Einschränkung vergleichsweise simpel umsetzen. Das englische Tagset sieht für satzbegrenzende Interpunktionen den Tag *SENT* vor. Im Zuge der Framegenerierung lassen sich somit Grenzen setzen. Stößt der Algorithmus auf ein Element, dem der Part of Speech Tag zugeordnet ist, wird das jeweilige n-Gram schlicht nicht beachtet. Da Abkürzungen gesondert von satzbeendenden Interpunktionen getaggt werden, sollte sich inhaltlich kein Verlust einstellen. Die Entscheidung, Satzgrenzen nicht zu beachten, wurde getroffen, nachdem erste Tests mit weiterführenden Methodiken zur Datenreduktion durchgeführt wurden. Es zeigte sich, dass insbesondere bei der Berechnung von Ähnlichkeitsmaßen, Satzzeichen die Ergebnisse stark beeinflussen, da sie sehr häufig auftreten. Ohne näher auf die Berechnung und Verwendung von Distanzmaßen eingehen zu wollen, sei angemerkt: Bei dem Vergleich zweier Frames, die beide am Satzende gebildet wurden, findet sich eher eine vermeintliche Übereinstimmung, wenn das Satzzeichen mit in die Kalkulation aufgenommen wird. Der Versuch, über die Zeichenoberfläche auch inhaltlich ähnliche Frames zu entdecken, wird somit erschwert, da der Toleranzbereich unnötig vergrößert wird.

Den größten Effekt im Zusammenhang mit der Datenreduktion bei der Frameberechnung ist jedoch dem Umwandeln von Numeralen zuzuschreiben. Sprachliche Konstruktionen, die auf der Zeichenebene beinahe identisch sind, unterscheiden sich oftmals durch numerische Angaben. Unternehmen berufen sich in ihrer Risikoberichterstattung naturgemäß auf Zahlen, um alle möglichen Größen zu beschreiben, wie das folgende Beispiel verdeutlicht.

driven by XXX \$1 million XXX
driven by XXX \$9 million XXX

Obwohl die Frames bis auf die Ausprägung der Ziffer augenscheinlich keinen Unterschied ausweisen, so würden doch zwei unterschiedliche Phänomene auf automatischem Wege berechnet. Sicherlich ist der Unterschied aus wirtschaftlicher Sicht nicht trivial und auch aus sprachwissenschaftlicher Perspektive sind unterschiedliche Strategien, je nach Art und Größe des zu erklärenden Betrages, zu

erwarten. Den Einfluss zu untersuchen ist jedoch nicht die Aufgabe dieser Arbeit und in Anbetracht der Fülle der gleichartigen Konstruktionen mit verschiedenen Numeralen, ist deren Umformung ein nützliches Mittel, um Daten handhabbar zu gestalten. Beim Einlesen der Korpusdaten werden daher alle auftretenden Zahlen in eine Raute – # – umgewandelt. Im Rahmen der technischen Aufbereitung ist an dieser Stelle hinzuzufügen, dass das Verfahren sowohl auf ganze Zahlen angewandt wurde, als auch auf Phänomene mit Dezimaltrennzeichen. Den Eigenarten der englischsprachigen Datengrundlage folgend, werden dabei sowohl Kommata als auch Punkte beachtet.

Bei den Einschränkungen handelt es sich um Manipulationen der Ausgangstexte, die letztendlich das Ergebnis beeinflussen. Im Zuge der linguistischen Aufarbeitung zur Untersuchung von Sprachgebrauchsmustern wurden allerdings lediglich Abwandlungen vorgenommen, die dem Ziel der Arbeit zutragen. Um in diesem Rahmen übergeordnete Aussagen machen zu können, ist eine Bestimmung der Satzanfänge oder eine Auswertung von Zahlen eher hinderlich. Die Wirksamkeit der Einschränkungen lässt sich quantifizieren und soll am Beispiel des Risikoberichts von Amazon.com aus dem Jahr 2014 belegt werden.

Finden die getroffenen Regelungen keine Anwendung, lassen sich in dem Bericht insgesamt 233.192 unterschiedliche Frames errechnen. Dem entgegen stehen 184.307 Muster unter Einbezug der Einschränkungen. Die Reduktion beträgt in diesem Fall rund 21%, woraus sich zwei nicht zu verachtende Vorteile ergeben: Zum einen kann im Kontext des Gesamtkorpus Rechenzeit gespart werden. Zum anderen lassen sich übergeordnete Konstruktionen durch die Generalisierung identifizieren, da sie entweder bereits zusammen klassifiziert wurden oder aber dadurch simpler im Zuge weiterer Verarbeitungsschritte zusammengefasst werden können. Auf diese Art wurden alle Frames in den sechs Subkorpora gebildet und ausgezählt.

7. Datenreduktion

Im Zuge der Frameberechnung und Zählung wurden bereits Strategien zur Datenreduktion angewandt. Die folgenden Ansätze gehen dabei über Mindestfrequenzen und Manipulationen einiger Zeichenketten hinaus. Sie verfolgen zwei Ziele. Erstens wird die Anzahl der Muster weiter reduziert, zweitens aber auch korpuspragmatischen Anforderungen Folge geleistet. Erst mit der Bestimmung statistisch signifikanter Sprachgebrauchsmuster lassen sich Rückschlüsse auf ein

Sprachhandeln ziehen. Darüber hinaus werden Ansätze zur Clusterbildung und damit Generierung von Featuresets für etwaige Modelltests beschrieben.

7.1. Signifikanzberechnungen

Nach der Berechnung der Phraseframes in den sechs unterschiedlichen Korpora sollen die Ergebnisse weiter reduziert werden. Durch die Einschränkungen auf unterschiedliche Unternehmen und Mindestfrequenzen kann zwar bereits ein Großteil irrelevanter Frames identifiziert und ignoriert werden. Die Ergebnismenge ist jedoch zum einen immer noch zu groß, als das sich zielführende Berechnungen auf deren Basis durchführen ließen, zum anderen ist sie auch durchzogen von redundanten Frames. Im Korpus 1 finden sich beispielsweise immer noch 176.929 *unterschiedliche* Frames mit spezifischen Häufigkeiten. Mit der Festlegung bestimmter Geschäftsjahre als Ausgangspunkte für einen Vergleich sprachlicher Muster geht die Annahme einher, dass sich der Sprachgebrauch auf Grund der wirtschaftlichen Entwicklung veränderte. Eine Untersuchung hinsichtlich aller Frames wird somit nicht angestrebt. Ein einfacher Vergleich der Anzahlen ist darüber hinaus nicht zielführend, da die Korpora unterschiedlich viele Frames produzieren und sich nicht abschätzen lässt, welche bezeichnend und damit relevant sind.

Die Prüfung lässt sich jedoch mit Hilfe statistischer Signifikanztests durchführen. In diesem Zusammenhang ließen sich sowohl Chi-Quadrat also auch Log-Likelihood-Tests nutzen. Bei kleineren Stichproben zeichnet sich der Chi-Quadrat Test weniger stabil gegenüber niedrigen Werten (vgl. Bubenhofer, 2009: S. 139). Obwohl die Ergebnisse in diesem Fall nicht weiter voneinander abweichen sollten, wird doch der Log-Likelihood Test genutzt. Der Test stellt die spezifischen Häufigkeiten eines Frames auf Basis einer Vierfelder-Kontingenztafel in das Verhältnis zur Gesamtframeanzahl. Betrachtet werden die Werte aus zwei konkurrierenden Korpora. Eine Relativierung der Ergebnisse im Vorhinein ist nicht notwendig, da aus den empirisch nachgewiesenen Werten Erwartungswerte gebildet werden, die sich wiederum vergleichen lassen. Je nachdem, wie sich erwartete und beobachtete Werte zu den Gesamtframeanzahlen verhalten, wird einem Frame ein Log-Likelihood-Wert zugewiesen. Der Wert beschreibt die Abweichung der beobachteten in Bezug zu einer hypothetischen und zufälligen Verteilung (vgl. Bubenhofer, 2009: S. 121).

Der Log-Likelihood-Wert selbst gibt jedoch noch keinen Aufschluss über die statistische Signifikanz. Diese lässt sich über die Umrechnung in das Signifikanzniveau

bestimmen. Der sogenannte *p-Wert* errechnet sich aus dem Log-Likelihood-Wert und der Anzahl der Freiheitsgrade, je nachdem, wieviele Datensätze vorliegen (vgl. Fahrmeir u. a., 2011: S. 376ff.). Er pegelt zwischen Null und Eins und ist in der Lage, die Nullhypothese überprüfen. Diese wiederum geht davon aus, dass Verteilungen rein zufällig bedingt sind und dass kein signifikanter Zusammenhang der Werte besteht (vgl. Fahrmeir u. a., 2011: S. 417ff.). Lässt sie sich ablehnen, wird ein Frame als signifikant für ein Korpus gewertet und er fließt in weitere Berechnungen ein. Das Signifikanzniveau lässt sich mit Hilfe kritischer Werte interpretieren, die in der Praxis meist dann relevante Zusammenhänge beschreiben, sobald p kleiner ist als 0,05. In diesem Fall sind die Frequenzunterschiede mit einer Wahrscheinlichkeit von 95% nicht zufällig (Bubenhofer, 2016b).

So wird jedoch nicht die Signifikanz eines Frames für ein bestimmtes Korpus untersucht, sondern lediglich abgeschätzt, inwieweit die Verteilungen prinzipiell statistische Auffälligkeiten aufweisen. Die Zuordnung zum Korpus lässt sich über einen Vergleich der Häufigkeiten der Frames rekonstruieren. Wenn ein Muster häufiger in Korpus A auftaucht und gleichzeitig als signifikant markiert wurde, dann kann es eben auch Korpus A zugeordnet werden. Dazu sind zwingend die relativen Frequenzen der Frames zu nutzen, um unterschiedliche Korpusgrößen auszugleichen. Der Test funktioniert daher zunächst nur in eine Richtung. Je nachdem für welches Korpus signifikante Frames ermittelt werden sollen, müssen die Eingaben erfolgen. Da jeweils zwei Korpora miteinander verglichen werden, wird die Signifikanzberechnung sowohl für Korpus A zu Korpus B, um signifikante Frames für Korpus A zu erhalten, als auch Korpus B zu Korpus A, um entsprechende Werte für Korpus B zu generieren, durchgeführt. Die Berechnung signifikanter Frames der eingangs erwähnten 176.929 Muster aus Korpus 1 gegen 158.183 Phänomene aus Korpus 2 generiert insgesamt 41.723 relevante Vertreter. Reichlich 76% der Frames sind somit statistisch nicht signifikant und beschreiben damit in dem spezifischen Zusammenhang kein relevantes Muster. Die Angaben unterscheiden sich selbstredend von Korpus zu Korpus, die Einsparung an Rechenkapazität aber auch an Redundanz ist dabei nicht trivial.

Darüber hinaus vollzieht sich mit der Berechnung von signifikanten Frames auch ein Schritt des axialen Kodierens im Rahmen der Grounded Theorie. Während Mindestfrequenzen zwar Ansätze bildeten und in kleinem Rahmen relevante Muster aufzeigen konnten, so ist doch die Errechnung signifikanter Vertreter am ehesten zielführend hinsichtlich der Kategoriebildung.

7.2. Levenshtein-Distanzalgorithmus

Im Zuge der Signifikanzberechnungen wurden Frames mit statistischen Auffälligkeiten anhand deren spezifischer Verteilungen in den einzelnen Korpora ermittelt. Es handelte sich rechnerisch also um eine Reduktion anhand der Häufigkeit. Mit Hilfe der Levenshtein-Editierdistanz soll daran anschließend versucht werden, gleichartige Frames, die sich in vergleichsweise wenigen Eigenschaften beziehungsweise Worten unterscheiden, zusammenzufassen. Das zugrunde liegende Verfahren wurde bereits Mitte der 1960er Jahre erdacht. Es berechnet einen numerischen Wert, welcher Aufschluss über die minimale Anzahl von Einfüge-, Ersetz- und Löschvorgängen gibt, die nötig sind, um eine Zeichenkette in eine andere zu transformieren (vgl. Levenshtein, 1965). In der Praxis lässt sich dies mit Hilfe einer Matrix berechnen, die die einzelnen Zeichenketten gegenüberstellt. Der Distanzwert ermittelt sich aus der Addition beziehungsweise Subtraktion des Wertes 1 je nach verwendeter Operation. Bei gleichen Zeichen ändert sich der Wert entsprechend nicht. Implementierungen des Algorithmus finden sich in den meisten Programmiersprachen. Der Perl Code ist frei verfügbar (Wikibooks, 2016), er wurde übernommen und angepasst.

Mit dem Distanzmaß werden in der Regel Wörter auf Buchstabenebene verglichen, sodass es beispielsweise in der teilautomatisierten Rechtschreibkorrektur eingesetzt werden kann. Ausgehend von einer als fehlerhaft identifizierten Zeichenkette können so mögliche Korrekturen gefunden und vorgeschlagen werden. Ein derartiger Abgleich wäre jedoch im Spannungsfeld der Phraseframes nicht sinnvoll, da zum einen auch die unterschiedlichen Längen der Ketten in das Ergebnis einfließen und zum anderen Frames über Wort- und nicht Zeichenähnlichkeiten zusammengefasst werden sollen. Der Ansatz, mit Hilfe der buchstabengetreuen Berechnung von einem Frame zum anderen zu gelangen, würde spätestens bei dem Versuch, kritische Werte zu ermitteln, scheitern. Der Algorithmus wird daher abgewandelt implementiert, sodass nicht mehr die Ebene des einzelnen Zeichens als Berechnungsgrundlage dient, sondern eine Zeichenkette bis hin zum nächsten Leerzeichen oder Frameende – also ein Wort, Satz- oder Sonderzeichen. Da die Länge der Frames festgesetzt ist, verliert die Wortanzahl an Bedeutung. Demzufolge ergibt sich eine größtmögliche Editierdistanz von 6, wenn keine Übereinstimmung vorliegt. Das folgende Beispiel soll einen ersten Einblick in die Funktionsweise des Algorithmus geben:

Frame 1: million in XXX principal amount XXX
Frame 2: million in XXX principal XXX of

Um von Frame 1 zu Frame 2 zu gelangen müssen sowohl *amount* als auch *XXX* ersetzt werden, die Editierdistanz beträgt somit 2. Bei identischen Ketten würde sie entsprechend mit 0 ausgezeichnet. Mit Hilfe von Tests soll zunächst überprüft werden, welche Distanzen im Rahmen dieser Arbeit sinnvoll erscheinen. Die Berechnung möglichst gleicher Frames über den Levenshtein-Algorithmus unterliegt dabei einer zentralen Problematik, die an folgendem Beispiel der Editierdistanz 2 verdeutlicht werden soll. Gegeben seien dabei die drei folgenden Frames:

Frame 1: of contents notes XXX XXX financial
Frame 2: of contents XXX XXX consolidated financial
Frame 3: of contents XXX to consolidated XXX

Augenscheinlich sollten die drei Phänomene zusammen gruppiert werden. Der Abstand zwischen dem ersten und zweiten, sowie dem ersten und dritten Frame beträgt 2. Zwischen Frame 2 und Frame 3 sind jedoch insgesamt drei Operationen für die Umwandlung nötig. Trotz dessen fallen sie in die gleiche Kategorie. Was zunächst sehr irritierend scheint und auf etwaige Programmierfehler hindeuten könnte, lässt sich jedoch aus der Logik des Algorithmus heraus erklären. Ausgehend von den höchst frequentierten Frames, wird die Distanz zu jedem weiteren berechnet. *Ein* Frame muss immer als Ausgangspunkt und damit Zentrum für ein Cluster ähnlicher sprachlicher Muster dienen. Eine Zuordnung wird in diesem Beispiel bei Editierdistanzen von eins oder zwei vorgenommen und der entsprechende Kandidat von der Liste möglicher Ausgangsframes gestrichen, sodass kein Frame Ausgangspunkt und Teilmenge zu gleich sein kann. Dies würde eine spätere Zuordnung und Auswertung erschweren. Auf der anderen Seite wird das Ergebnis durch die Kürzung verfälscht, weil sich Cluster mit unter neu bilden, die aus der Logik heraus nicht entstehen sollten. Wie oft sich Frames doppeln würden und welchen Einfluss das auf die Anzahl der Cluster hätte, kann nicht ohne weiteres abgeschätzt werden. Es ist vorstellbar, dass sich vermeintlich kleine Cluster stark erweitern und einzelne Frames vielfach Beachtung finden. Wenn diese Frames häufig vorkommen, können sie die Werte ganzer Cluster bestimmen, sodass Auswertungen nicht generalisierbar sind. Im Rahmen dieser Arbeit wird daher der erste Ansatz weiter verfolgt. Frames werden nur einmal entweder als Zentrum *oder* als Vertreter beachtet.

Da sich die Cluster somit je nach Reihenfolge der Frames bei der Distanzberechnung bilden, unterscheiden sie sich je nachdem, welches Korpus zu Grunde liegt. Veränderungen ergeben sich nicht nur auf Basis einer anderen Reihenfolge, sondern auch, weil nicht alle Frames in den einzelnen Korpora mit einer signifikanten Häufigkeit auftreten. Ein anschließender Vergleich würde somit unmöglich gemacht. Die Problematik lässt sich allerdings auflösen, wenn die Cluster auf Basis *aller* möglichen Phraseframes in *allen* Korpora gebildet werden. Zunächst werden dazu die 152.162 *signifikanten* und *einzigartigen* Frames *aller* Textgrundlagen ermittelt. Die Zusammenfassung erfolgt anschließend mit dem Distanzalgorithmus.

Unter den beschriebenen Bedingungen hat jeder Ausgangsframe zu jedem anderen innerhalb seiner Gruppe eine Distanz von zwei. Im Umkehrschluss bedeutet dies auch, dass zwischen den Frames 2 und 3 eines Clusters eine größte Distanz von 4 möglich ist, wenn beide maximal von Frame 1 als auch voneinander abweichen. In dem eingangs genannten Beispiel ist die Abweichung nicht weiter verwunderlich und trägt eher dem Ziel der Datenreduktion bei. Nach ersten Tests erwies sich eine maximale Editierdistanz von 2 als am ehesten geeignet, da jede größere Entfernung zu viele Frames zusammenfasst. Aus über 152.000 unterschiedlichen Frames ermittelt der Algorithmus mit einer maximalen Distanz von 3 lediglich 1.529 unterschiedliche Cluster. Obwohl die Datenreduktion ein zentrales Anliegen dieser Arbeit ist, kann eine Verkleinerung der Menge um rund 97% keine Option sein. Auf dieser Grundlage ließen sich keine sinnvollen Ergebnisse erwarten. Versuche mit der Levenshtein-Distanz von 1 wiederum ermöglichen lediglich *eine* Veränderung in den n-Grammen, was auch nicht zielführend sein kann, da sehr viele Cluster mit sehr wenigen Frames entstünden. Insbesondere weil jeder Frame mit jedem anderen verglichen werden muss und erst bei einer Korrelation aus dem Pool möglicher Kandidaten verschwindet, nimmt die Berechnung der Cluster mit einer Distanz von 1 enorm viel Rechenzeit in Anspruch.

Die Sichtung erster Ergebnisse brachte zwei weitere Problemfelder hervor: 1.) Es findet sich eine Vielzahl von Frames, die lediglich aus Sonderzeichen, Zahlen und Slots bestehen. Im Sinne sprachwissenschaftlicher Auswertungen vor einem korpuspragmatischen Hintergrund lassen sich derartige Phänomene durchaus vernachlässigen. Ihnen wird in diesem spezifischen Zusammenhang der linguistische Mehrwert abgesprochen, da nicht davon ausgegangen werden kann, dass sich bedeutungstragende Sprachhandlungen im Rahmen derartiger Zeichenketten vollziehen. Technisch wurden dazu die Frames zunächst in ihre Bestandteile zerlegt und neben den

Slots nach Ketten alphanumerischer Zeichen mit einer Mindestlänge von mindestens 2 gesucht. Interpunktionen entfallen somit. Bedingt durch die Herangehensweise wird werden jedoch auch sehr kurze Worte wie *I* oder *a* ignoriert. Aus einer pragmatischen Sicht sollte dies jedoch keine größeren Abweichungen verursachen. 2.) Semantisch ähnliche Frames lassen sich durch unterschiedliche Realisationen nicht zusammenfassen. Diese Symptomatik zeigt sich insbesondere bei den Monatsbezeichnungen, da diese in den Berichten der Unternehmen vergleichsweise häufige Verwendung finden. Im Sinne der Editierdistanz sind die Zeichenketten *January* oder dessen Abkürzung *Jan* selbstverständlich unterschiedlich. Inhaltlich sind sie jedoch nahezu identisch. Die Frames wurden daher weiter bearbeitet und nicht nur die vollständig ausgeschriebenen oder abgekürzten Monatsbezeichnungen zusammengefasst, sondern alle unterschiedlichen Monate (January – December) unter der Bezeichnung *month*. In diesem Sinne wurden auch sämtliche Variationen von *million*, *millions*, *billion*, *billions* etc. unter der Zeichenkette *million/billion* zusammengefasst. Die Einschränkungen wurden rückwirkend in die Frameberechnung integriert. Die beiden vergleichsweise marginalen Abwandlungen decken nahezu 30.000 Frames ab, die sich somit verallgemeinern ließen. Über alle Korpora hinweg ergibt sich somit ein Pool von 124.145 Frames, die als Grundlage zur Clustererstellung dienen.

Auf Basis der Einschränkungen und vorheriger Tests, erscheint eine Editierdistanz von maximal 2 am sinnvollsten. Auch sie kann jedoch nicht ohne weitere Bearbeitungen genutzt werden, wie das folgenden Beispiel verdeutlichen soll:

Frame 1: XXX of goodwill and XXX assets
Frame 2: XXX of oil and XXX gas
Frame 3: XXX of cash and XXX equivalents

Frame 1 bildet wieder den Ausgangspunkt. In diesem Fall beträgt die Levenshtein-Editierdistanz zwischen allen drei Frames jeweils zwei. Bezeichnend ist allerdings, dass die drei Frames inhaltlich nahezu keine Übereinstimmung aufweisen. Da jedoch die Stellung der Slots jeweils an der ersten und vorletzten Position, sowie *of* und *and* identisch sind, ergibt sich die Distanz aus dem Austausch von jeweils zwei Wörtern. Die Struktur der Frames bedingt damit die Bildung des Clusters, auf inhaltlicher Ebene verbindet sie jedoch nichts. Das Problem lässt sich nur lösen, wenn die komplette Ersetzung von Worten den Distanzwert stärker erhöht als beispielsweise einfache Umstellungen. Daher geht der Berechnung der Editierdistanz ein weiterer Test voraus. Die Phraseframes werden in einzelne Glieder zerlegt und diese wiederum auf

Wortebene vergleichen. Wenn dabei nicht mindestens zwei Einheiten identisch sind, wird die Distanz um den Wert Eins erhöht. Von dieser Regelung sind die Slots oder reine Zahlenwerte ausgenommen. Frames, die nur aus Zahlen bestehen oder Slots lediglich Positionen tauschen fallen somit durch das Raster. Unter den Bedienungen und einer maximalen Distanz von 2 ließen sich die vergleichsweise besten Ergebnisse erzielen. Somit werden zwar zum Teil viele kleine Cluster mit entsprechend wenigen Frames gebildet, diese sind jedoch inhaltlich zumeist näher beieinander. Während vorher, aufgrund der Differenzen auf Wortebene die Ausgangsframes nur sehr sporadisch in der Länge waren, ein Cluster zu bezeichnen, ist das mit den Beschränkungen eher möglich. Vereinzelt finden sich immer noch Ausreißer und es ist unter Umständen auch denkbar, dass sich Frames mit entgegengesetzten inhaltlichen Positionen in einem Cluster befinden. Das folgende Beispiel mit zwei Frames deren Abstand 1 beträgt ist konstruiert, zeigt jedoch genau dieses Potential auf.

Frame 1: which XXX negatively XXX our business

Frame 2: which XXX positively XXX our business

Durch die maschinelle Verarbeitung der Daten lassen sich solche Phänomene jedoch nicht vollkommen ausschließen. Dafür müssten die Frames händisch evaluiert werden, was weder im Rahmen dieser Arbeit möglich noch zielführend ist. Aus pragmatischen Gründen wird daher mit den so generierten Frameclustern weitergearbeitet, die eine Editierdistanz von zwei oder weniger aufweisen und neben Slots oder Numeralen möglichst wenige Worte vollkommen ersetzen.

7.3. Zusammenfassung

Da sich die Datenreduktion über die Frameberechnung bis hin zur Clusterbildung erstreckte und in zuweilen in kleinen Schritten vollzog, soll an dieser Stelle eine Zusammenfassung folgen.

Im Zuge der Frameerstellung wurde sämtliche Groß- durch Kleinschreibung, Zahlen durch Rauten, und Monatsbezeichnungen durch month und Million beziehungsweise Billion durch million/billion ersetzt. In die anschließende Zählung flossen lediglich Frames ein, die von fünf unterschiedlichen Unternehmen genutzt und mit einer globalen Mindestfrequenz von 25 vorzufinden waren. Die Berechnungen wurden in allen sechs Korpora durchgeführt und anschließend mittels Log-Likelihood-Tests statistisch signifikante Frames nachgewiesen. Die so ermittelten Frames wurden über eine abgewandelte Implementierung der Levenshtein-Editierdistanz in Cluster

zusammengefasst. Somit ließen sich aus den ursprünglich 126.083 vermeintlich relevanten Phraseframes 24.654 Cluster ermitteln. Die Reduktion um reichlich 80% ist nicht nur für ewige qualitative Auswertungen von Vorteil, auch quantitative Berechnungen lassen sich somit schneller durchführen.

Abbildung 2 stellt die Anzahl der Frames, welche einem Cluster zugeordnet wurden, in das Verhältnis zu allen Clustern. Da es sich wiederum um eine Long Tail-Verteilung handelt, wurden die extremen Ausreißer abgeschnitten, die 20 größten Cluster sind daher nicht aufgeführt. Die y-Achse beginnt bei 100 Frames, die einem Cluster zugeordnet wurden. Auf der x-Achse wiederum wurden die rund 4600 Cluster, die die wenigsten Frames beinhalten, abgeschnitten. Den größten Teil dieser Phänomene bilden 4430 Vertreter, die sich nicht gruppieren ließen, also einzelne Frames. Durchschnittlich konnten fünf Frames zusammengefasst werden, was die horizontale Linie im Diagramm beschreibt.




Abbildung 2: Verteilung Frames auf Cluster

Die Distribution der Frames auf die Cluster ist erwartbar, da sie der Verteilung der Frameanzahlen grob entspricht. Abstrahierend ließe sich somit die Methodik bestätigen, inwiefern jedoch die errechneten Frames beziehungsweise Cluster in der Lage sind, wirtschaftliche Entwicklungen zu beschreiben, muss mit Hilfe von Tests

untersucht werden. Die Daten in diesem Abschnitt bezogen sich auf alle signifikanten Frames beziehungsweise die errechneten Cluster. Um Aussagen über die Verteilung in den einzelnen Korpora treffen zu können, müssen alle Frames eines Clusters herangezogen werden und nicht nur der Zentrale, da es nicht unwahrscheinlich ist, dass zwar Teilmengen eines Clusters in einem Korpora zu finden sind, nicht jedoch der Ausgangsframe selbst. Jede Gruppierung von Frames wurde daher mit einer Identifikationsnummer (Id) versehen. Somit lassen sich alle Frames zählen und im Nachhinein dem Cluster wieder zuordnen. Am Beispiel des größten Clusters soll die Form der Datenaufbereitung erläutert werden. Es bildet sich um den Frame *">monthgin-bottom:#px"> XXX XXX of \$# million/billion* und besitzt die Id 115. Der Ausgangsframe beinhaltet HTML-Informationen und scheint daher auf den ersten Blick fehlerhaft. Bei näherem Hinblicken verliert das jedoch an Bedeutung und ist in diesem Fall der Reihenfolge der Frames bei der Berechnung der Editierdistanz und vereinzelt Fehlern beim Parsen der Dokumente zuzuschreiben. Betrachtet man die weiteren n-Gramme, die sich um den Term gruppieren, erscheint das Bild logischer. Bei der Aufstellung in Tabelle 4 handelt es sich lediglich um einen Auszug, der verdeutlichen soll, wie sich typische Gruppierungen gestalten.

XXX loss XXX of \$# million/billion	, XXX XXX of \$# million/billion
XXX notional XXX of \$# million/billion	XXX XXX acquisitions of \$# million/billion
XXX XXX gains of \$# million/billion	XXX XXX of \$# million/billion for
XXX XXX of \$# million/billion from	XXX XXX of our \$# million/billion
XXX transaction XXX of \$# million/billion	XXX a XXX of \$# million/billion
with XXX XXX of \$# million/billion	XXX investing XXX of \$# million/billion

Tabelle 4: Cluster Id 115 *">monthgin-bottom:#px"> XXX XXX of \$# million/billion*

Zentrale Inhalte dieses Frames bilden sich entsprechend um *of \$# million/billion* während ansonsten eher marginale Änderungen in der Position des Slots zu verzeichnen sind. Auch bei der Betrachtung weiterer Cluster scheint sich das Verfahren zu eignen, um Frames zu gruppieren. Es finden sich allerdings auch kleinere Cluster mit wenigen Vertretern, die bei händischer Bearbeitung sicherlich zusammengefasst würden, da das Verfahren jedoch maschinell konzeptioniert und über die beschriebenen Einschränkungen optimiert wurde, soll an dieser Stelle nicht weiter manuell und damit interpretativ in die Daten eingegriffen werden. Auch sei bedacht, dass es sich bei dem aufgezeigten Beispiel um das größte Cluster handelt, während in der Regel um die fünf Frames gruppiert wurden.

8. Modelltest

Die signifikanten Phraseframes und die daraus berechneten Cluster sollen als Featuresets für Modelltests im Rahmen der Theoriebildung dienen. Da die Cluster auf den signifikanten Frames aller Jahre beruhen, wird zunächst berechnet, welche Cluster in den einzelnen Subkorpora auftreten. Es müssen schließlich nicht alle in jedem Subkorpora vorkommen. Diese so ermittelten, zentralen Kategorien sollen anschließend mit den Return on Assets Werten aller Unternehmensjahre korreliert werden und so das vorläufige Modell zur Beschreibung wirtschaftlicher Entwicklungen getestet. Dazu wurden zunächst unternehmensspezifische Korpora gebildet, in denen die Cluster dann jahresweise berechnet werden können.

Die Frage, die sich stellt ist, inwieweit die Sets in der Lage sind, wirtschaftliche Entwicklungen zu beschreiben. Gleichartige Hypothesen lassen sich entsprechend für alle Framecluster bilden. Sind beispielsweise die Cluster aus den besten Unternehmensjahren in der Lage, die Return on Assets Werte der anderen Jahre vorauszusagen? Die Annahme in diesem Fall wäre, dass je höher der Return on Assets Wert in einem Jahr ausfällt, umso frequentierter sind die entsprechend positiven Cluster. Gleiches lässt sich für den vermeintlich schlechtesten Jahrgang andenken oder überprüfen, inwieweit Cluster aus Jahrgängen mit negativem Return an Assets in der Lage sind, weitere Entwicklungen zu beschreiben. Statistisch valide Ergebnisse lassen sich in diesem Zusammenhang über Korrelationsberechnungen und anschließende Signifikanztests eruieren. Dabei wird entsprechend der Return on Assets Wert mit der relativen Häufigkeit der Clusternutzung in Verbindung gebracht. In den Unternehmenskorpora wird also ausgezählt, wie häufig die Frames eines Featuresets genutzt werden. Der relativierte Wert lässt sich daraufhin korrelieren.

8.1. Korrelationsberechnung und vorläufige Ergebnisse

Während Regressionsanalysen die Art des Zusammenhangs mehrerer Variablen berechnen, sind Korrelationsanalysen in der Lage, die Stärke einer Relation zu beschreiben (vgl. Scharnbacher, 2002: S. 166). Im vorliegenden Fall lässt sich der Gebrauch eines Featuresets mit den wirtschaftlichen Kennzahlen in Verbindung setzen und somit im Rahmen der Grounded Theorie in Kontexte einbetten. Da insgesamt sechs unterschiedliche Sets berechnet wurden, lassen sich diese auch nutzen um vermeintliche Zusammenhänge aufzudecken. Dabei sollte erneut bedacht werden, dass die Framecluster immer den spezifischen Sprachgebrauch eines Subkorpora, d. h., auch

eines bestimmten Jahres widerspiegeln. Obwohl es sich dabei von Unternehmen zu Unternehmen um unterschiedliche Jahre handelt, so sind diese doch verbunden über die Kategorien, die bei der Korpuserstellung gewählt wurden.

Es existieren eine ganze Reihe statistischer Korrelationskoeffizienten, die sich zur Beurteilung der Daten heranziehen ließen. Die Wahl eines Bestimmten ist mit der Verteilung und Art der Daten verbunden. Kann davon ausgegangen werden, dass die Messwerte normalverteilt sind, lässt sich die Korrelation nach Pearson nutzen (vgl. Fahrmeir u. a., 2011: S. 135ff.). Damit ist jedoch weder im Rahmen der Return on Assets Werte noch bei der Verteilung der Framecluster zu rechnen. Daher wird an dieser Stelle auf den Rangkorrelationskoeffizienten nach Spearman zurückgegriffen. Die Verteilungsunterschiede der Werte spielen dabei eine untergeordnete Rolle, da sie zunächst in Ränge umgewandelt werden. Dem empirisch nachgewiesenen höchsten Wert wird dabei der Rang 10 zugeordnet, dem zweithöchsten 9 usw. (vgl. Fahrmeir u. a., 2011: S. 142ff.). Umgerechnet werden sowohl die relativierten Clusterhäufigkeiten als auch die Return on Assets Werte. Beispielhaft soll die Zuordnung der einzelnen Ränge in Tabelle 5 verdeutlicht werden. Bei den Angaben zum Clustergebrauch handelt es sich um das Set, welches aus dem besten Unternehmensjahr im Vergleich zum Folgejahr generiert wurde. Relativiert sind die Werte jeweils auf alle Framecluster.

Jahr	RoA Rank	Cluster Rank	RoA	Cluster relativ
2006	8	9	0.1743567143	0.012447831609
2007	10	8	0.3570781723	0.0116049382716
2008	9	7	0.2430257659	0.010261502813
2009	6	6	0.1715357639	0.009315718157
2010	3	5	0.1178450694	0.008963331824
2011	5	4	0.1578112985	0.008548530721
2012	2	3	0.111493833	0.008492063492
2013	1	1	0.0922534749	0.008255393440
2014	4	2	0.1210826133	0.008263695450
2015	7	10	0.1732484576	0.017703232125

Tabelle 5: Rangkorrelation Texas Instruments Cluster: Bestes Jahr

Prinzipiell können Korrelationskoeffizienten einen Wert zwischen +1 und -1 annehmen. Demzufolge lässt sich von positiven und negativen Korrelationen sprechen (vgl. Scharnbacher, 2002: S. 166). Da untersucht wird, inwiefern Clusternutzung und Return on Assets Werte übereinstimmen, ist in diesem Fall lediglich die positive

Korrelation von Bedeutung. Darüber hinaus muss geprüft werden, inwiefern die berechneten Zusammenhänge nicht lediglich im Zufall begründet liegen. Dazu wird der Korrelationsberechnung ein weiterer Signifikanztest angeschlossen.

Die praktische Umsetzung vollzieht sich wieder automatisiert mit Hilfe eines Perl Skriptes. Dieses zählt in den einzelnen Unternehmensjahren alle signifikanten Frames aus und ordnet diese dem entsprechenden Cluster zu. Gleichzeitig werden alle möglichen Frames gezählt, um somit die Clusternutzung relativieren zu können. Auf diese Art lassen sich die gewonnen Werte über unterschiedliche Jahre hinweg vergleichen. Dieser Schritt ist nötig, da unterschiedlich lange Risikoberichte das Ergebnis verfälschen würden. Anschließend werden die Return on Assets Werte und die relative Clusternutzung pro Jahr einem Statistikmodul übergeben, welches selbstständig die Ränge zuweist und den Korrelationskoeffizienten nach Spearman berechnet.⁸ Daraufhin wird mit Hilfe eines t-Tests überprüft, inwieweit die positiven Korrelationen statistisch signifikant sind. Es wird eine Prüfgröße mit kritischen Werten abgeglichen (Faes, 2016b). In der folgenden Formel bezeichnet PG die Prüfgröße, r den Korrelationskoeffizienten und n die Anzahl verfügbarer Datensätze, aus der auch ein Freiheitsgrad f abgeleitet wird. Dieser ist wiederum für den Abgleich mit den kritischen t-Werten von Bedeutung.

$$PG = r * \sqrt{\frac{n-2}{1-r^2}} \quad f = n - 2$$

Die Cluster und Return on Assets Werte aus dem Beispiel der Tabelle 5 korrelieren positiv mit einem Koeffizienten von 0,83030303030303. Es sind insgesamt 10 Datensätze vorhanden. Setzt man die Werte in die erste Formel ein, erhält man eine Prüfgröße von 4,213888825. Beim Abgleich mit der Wertetabelle und einem Freiheitsgrad von 8, lässt sich die Nullhypothese mit einer Wahrscheinlichkeit von 99,5% ablehnen. Im Rahmen der weiteren Berechnungen, wird von einem statistisch signifikanten Zusammenhang dann ausgegangen, wenn eine zufällige Korrelation mit einer Wahrscheinlichkeit von mindestens 95% abgelehnt werden kann. Die Grenzwerte wurden fest in das Perl Skript nach den Vorgaben einer t-Wert-Tabelle kodiert (Faes, 2016a).

Mit Hilfe des Tests lassen sich nicht nur Einschätzungen zum Grad der Korrelation machen, sondern auch Aussagen zur Güte. Wenn ein hoher

⁸ Bei dem Modul handelt es sich um Statistics::RankCorrelation. Es wurde von Gene Boggs geschrieben und ist im CPAN Archiv frei verfügbar (Boggs, 2015).

Korrelationskoeffizient errechnet wurde, so kann mit Hilfe des t-Tests eine Einschätzung darüber vorgenommen werden, inwiefern der Wert über die Anzahl der verfügbaren Datensätze aussagekräftig ist. Wenn demnach die Clusteranzahlen positiv mit den Return on Assets Werten korrelieren und eine statistische Signifikanz vorliegt, ist ein Zusammenhang bewiesen. Über die Berechnung der Ränge lassen sich die Ergebnisse vereinfacht in Diagrammen darstellen, sodass theoretisch für jedes Unternehmen mit jedem Featureset ein Chart erstellt werden könnte, aus dem die Korrelation vergleichbar einfach ersichtlich wird. Bei dem Beispiel Texas Instruments kann die Korrelation entsprechend durch die Graphen in Abbildung 3 beschrieben werden. Ein Zusammenhang der Werte ist deutlich erkennbar. In dem Fall ließe sich die Hypothese, dass die vermehrte Nutzung von Frameclustern aus vermeintlich erfolgreichen Unternehmensjahren übergreifend mit der Performance korreliert, bestätigen. Da der Zusammenhang darüber hinaus statistisch signifikant ist, kann eine zufällige Korrelation ausgeschlossen werden. Die Nutzung der Framecluster ist bei diesem Fallbeispiel also tatsächlich in der Lage, mit den wirtschaftlichen Kennzahlen zu korrelieren und es ließe sich vermuten, dass weitere Datensätze prognostiziert werden könnten. Es können somit begründete Vermutungen zum Return on Assets Wert von angestellt werden, wenn die spezifische Clusternutzung des Jahres 2016 mit in die Berechnung eingebracht würde.




Abbildung 3: Korrelation Texas Instruments

Auf diese Weise wurden alle Unternehmen mit den Featuresets der einzelnen Subkorpora getestet, sodass über die Anzahl der positiv signifikanten Korrelationen überprüft werden kann, inwiefern sich die Sets eignen, um wirtschaftliche

Wirklichkeiten abzubilden. Veranschaulicht werden die Ergebnisse in Abbildung 4. Deutlich ersichtlich ist zunächst, dass unterschiedliche Featuresets sehr unterschiedlich mit den Unternehmensdaten korrelieren. Am wenigsten signifikant positive Korrelationen finden sich bei den Clustern aus dem Unternehmensjahr mit einem negativen Vorzeichen. Cluster, die sich jedoch im Vergleich zu dessen Vorjahr signifikant unterscheiden, sind in der Lage, mehr als doppelt so viele Entwicklungen abzubilden. Während sich weder die Cluster des verlustreichsten Jahres noch des Folgejahres scheinbar effizient nutzen lassen, stechen die Featuresets aus dem vermeintlich besten Jahren heraus. Mit insgesamt 63 positiven Korrelationen weisen sie die höchsten Werte aus. Im Verhältnis zu den über 450 Unternehmen ist das Erlebnis jedoch nicht befriedigend.




Abbildung 4: Korrelationen: Alle Unternehmen mit Cluster

8.2. Optimierung

Nachdem die Return on Assets Werte lediglich in Einzelfällen mit der Nutzung bestimmter Framecluster korrelierten, soll anschließend versucht werden, über die Manipulation der Featuresets die Ergebnisse zu verbessern. Darüber hinaus wurde ein komplett neues Set erhoben. Da die Cluster des erfolgreichsten Unternehmensjahres prinzipiell am ehesten positiv signifikante Korrelationen aufwiesen, speist sich das Set aus den Frames des erfolgreichsten im Gegensatz zum verlustreichsten Jahr jedes Unternehmens. Der Entscheidung liegt die Überlegung zu Grunde, dass sich die Frames des erfolgreichsten Jahres von denen des verlustreichsten vermeintlich „stärker“

unterscheiden als lediglich zum Folgejahr. Die weiteren Optimierungen beziehen sich auf die Auswahl der Cluster, welche zur Berechnung herangezogen werden. Nach insgesamt fünf weiteren Kriterien werden bestimmte Vertreter ausgewählt. So wird versucht das Modell zu verbessern und die Korrelationsraten zu steigern. Die Schritte verstehen sich als Teil des selektiven Kodierens, da versucht wird über die weiteren Einschränkungen, zentrale Konzepte zu erarbeiten. Die Berechnung ausgewählter Frames basiert in allen Fällen auf einem Abgleich mit einem bestimmten Wortschatz auf Lemmabasis, um alle Phänomene abzugreifen. Dazu wurden die Cluster zunächst mit der Software Treetagger bearbeitet und sowohl Lemmata als auch Part of Speech annotiert. Zunächst werden die einzelnen Optimierungen beschrieben und abschließend in Punkt 8.3 *Ergebnisse der Optimierungen* zusammenfassend ausgewertet.

8.2.1 Wirtschaftswörterbücher

Bereits im Rahmen eines Projektes, welches dieser Arbeit vorausging, wurden wirtschaftswissenschaftliche Wörterbücher maschinell zugänglich gemacht und ausgewertet. Sie sollten ursprünglich als Taxonomie dienen, um Frames zusammenzufassen und übergeordnete Themenschwerpunkte rechnerisch herauszustellen. Dabei wurden Definitionen automatisiert bearbeitet und nach Oberbegriffen durchsucht. Im Rahmen der hier genutzten Verfahren wurden alle Fachtermini herangezogen und mit den Clustern abgeglichen. Demzufolge gehen in die Berechnungen theoretisch nur Frames ein, in denen relevanter Wortschatz im Sinne wirtschaftlicher Fachwörterbücher vorkommt. Bei der Betrachtung fällt jedoch auf, dass sich in den Definitionen vergleichsweise allgemeine Begrifflichkeiten wie *table* oder *year* wiederfinden, die entsprechend auch im Bereich der Cluster hoch frequentiert sind. Nichtsdestotrotz wurden derartige Begriffe in die Reduktion mit einbezogen. Dem entgegen ließe sich auch ein interpretatives Eingreifen andenken, in dem vermeintlich weniger bedeutsame Termini manuell gefiltert würden. Darunter würde jedoch die Verallgemeinerbarkeit leiden. Darüber hinaus sollen zunächst automatisierte Vorgehensweisen und Zugänge getestet werden, ohne dabei wertend an die Datengrundlage heranzutreten. Bei den ausgewerteten Wörterbüchern handelt es sich um die Online-Ressource von Businessdictionary.com und das Routledge Dictionary of Economics. Die Datensätze wurden freundlicherweise von Prof. Scharloth und Prof. Günther bereitgestellt. Bearbeitet wurden sie von Anna Bonazzi. Von den ursprünglich 24.654 Frameclustern werden nach dem Abgleich noch 21.119 genutzt.

8.2.2 Wirtschaftliche Keywords

Der Abgleich der Framecluster mit wirtschaftlich relevanten Keywords ähnelt stark den Einschränkungen über Wörterbücher. In diesem Fall stammen die Kriterien jedoch nicht aus Wortlisten, die von den Autoren der Lexika zusammengestellt wurden, sondern begründen sich statistisch auf dem signifikanten Wortschatz der Risikoberichte. Zur Keywordberechnung wurden entsprechend Lemmata herangezogen, da der Abgleich mit den Clustern so vereinfacht wird. Keywords sind zunächst Wörter, denen ein besonderer Status zugeschrieben wird. Im korpuslinguistischem Sinne handelt es sich dabei um bezeichnendes Vokabular einer bestimmten Textsammlung. Rechnerisch identifiziert werden Keywords mit Hilfe von Korpusvergleichen und Signifikanzberechnungen (vgl. Bubenhofer, 2016a). Dabei kommen die selben Tests zum Einsatz, die bereits in Punkt 7.1 *Signifikanzberechnungen* näher erläutert wurden. Errechnet wurden die Keywords durch einen Vergleich der Korpora der Risikoberichte aus dem Jahr 2015 mit den Daten des Kentucky Kernel. Das Jahr 2015 wurde dabei gewählt, da es sich um das größte Teilkorpus handelt. Da davon auszugehen ist, dass sich der allgemeine Sprachgebrauch auf Wortebene nicht signifikant änderte, hätte die Berechnung auch auf jedem andern Jahr oder dem Gesamtkorpus fußen können. Der Kentucky Kernel ist eine amerikanische Studentenzeitschrift der Universität von Kentucky. Das Korpus wurde von Prof. Scharloth bereitgestellt. Es umfasst 19.502 Artikel aus den Jahren 2006 bis 2014 und stellt damit als Vergleich 9.747.566 Wortformen den 10.574.631 des Jahreskorpus 2015 der Risikoberichte gegenüber. Auf dieser Grundlage ließen sich 6.395 signifikante Keywords errechnen. Ausschlaggebend für eine Aufnahme ist dabei ein p-Wert unter 0,05 und eine Mindestfrequenz von 10 in den Risikoberichten. Die Clusteranzahl verkleinert sich durch diesen Ansatz lediglich um knapp 2000 von 24.654 auf 22.892.

8.2.3 Adjektive

Die Wortart *Adjektiv* bezeichnet nach der Definition des Dudens ein Eigenschaftswort, dass „ein Wesen oder Ding, ein Geschehen, eine Eigenschaft oder einen Umstand mit einem bestimmten Merkmal, mit einer bestimmten Eigenschaft kennzeichnet“ (Duden Online, 2016). Der Optimierungsansatz über die Verwendung von Frameclustern, die mindestens ein Adjektiv beinhalten entsteht aus der Überlegung heraus, dass so Entwicklungen beschrieben, mit Eigenschaften versehen und bewertet werden. In diesem Zusammenhang wäre die Verwendung von ausschließlich

evaluativen Adjektiven zum Abgleich sicherlich interessant, um Einschätzungen abzugreifen. Als einfaches Muster sei dabei an eine „gute“ oder schlechte“ Entwicklungen gedacht. In der Realität jedoch lassen sich evaluative von beispielsweise deskriptiven oder definitorische Adjektiven nicht ohne ein interpretatives Vorgehen unterscheiden. Da im Rahmen der Optimierungen jedoch weitestgehend auf manuelle Eingriffe verzichtet werden soll, basiert die Auswahl der Adjektive schlicht auf den annotierten Frameclustern. Demzufolge wurden Cluster gewählt, in denen der *Treetagger* einem Wort das Part of Speech Tag *JJ*, *JJR* oder *JJS* zugeschrieben hat und somit als Positiv, Komparativ oder Superlativ eines Adjektivs identifiziert. Es wurden demnach schlicht alle Adjektive herangezogen, da sich eine bestimmte Art nicht ohne weiteres automatisiert herausfiltern lässt. Auf diese Art verbleiben noch 12.373 Cluster im Pool.

8.2.4 SentiWordNet

Das SentiWordNet ist eine frei zugängliche lexikalische Ressource, die interpretierte englische Lexeme für Untersuchungen im Rahmen von Opinion Mining und Sentiment Analysis aufbereitet (SentiWordNet, 2010). Unterschiedliche Wortbedeutungen werden durch Id's widergespiegelt und ähnliche Bedeutungen wiederum in Synsets zusammengefasst. Ein Synset besitzt sowohl einen positiven wie auch negativen Score, die jeweils zwischen 0 und 1 liegen. Bei der Erstellung des Wordnets stützen sich Esuli und Sebastiani auf semi-überwachte Methodiken des maschinellen Lernens. Demnach wurden zunächst mehrere klassifizierende Indizes erhoben und die Scores maschinell auf deren Basis ermittelt (vgl. Esuli, Sebastiani, 2006: S. 418ff.). Einzelne Lexeme können in mehreren Synsets vorkommen und demnach unterschiedliche positive und negative Werte aufweisen. Da bei einem Abgleich mit den Frameclustern durch den nur sehr marginal vorhandenen Kontext nicht näher auf Einzelbedeutungen geschlossen werden kann, lässt sich eine Zuschreibung auf diesem Level nicht vornehmen. Wenn demnach ein Lexem in mehreren Synsets auftaucht, wurde mit Summen gearbeitet. Das Lemma *risk* befindet sich beispielsweise in insgesamt 3 Synsets, von denen eines mit 0,25 Punkten positiv und die anderen jeweils mit 0,625 und 0,25 Punkten negativ ausfallen. Demnach werden negative Werte von den Positiven subtrahiert und in diesem Fall erhielte man das Ergebnis -0,625. Das Lexem würde demnach „negativem Wortschatz“ zugeordnet. Auf diese Art wurde das SentiWordNet ausgewertet und 17.597 positive und 20.308

negative Termini gefiltert. Durch den Ansatz entsteht somit nicht ein Subclusterset sondern zwei, da sowohl die negativen als auch die positiven Begriffe als Grundlage dienen. Auf positiver Seite fließen somit noch 19.626 und auf negativer 16.062 Cluster in die Berechnungen ein.

8.3. Ergebnisse der Optimierungen

Die Ergebnisse der Optimierungsansätze werden in Abbildung 5 zusammengefasst.⁹ Das Diagramm stellt die Anzahl der korrelierenden Unternehmen auf der y-Achse in Verbindung mit den genutzten Cluster auf der x-Achse.




Abbildung 5: Optimierungsergebnisse

Zunächst kann grundsätzlich festgehalten werden, dass die einzelnen Optimierungsansätze einen Einfluss auf die Anzahl der korrelierenden Unternehmen haben. Sie verändern die Ergebnisse sowohl in die positive als auch in die negative Richtung. Deutlich erscheint, dass alle Framecluster aus den vermeintlich verlustreichsten Unternehmensjahren am schwächsten korrelieren, ganz gleich mit welchen Einschränkungen. Ähnlich verhält es sich mit den Clustern aus Jahren mit negativem Return on Assets Wert. Die Jahre vor dem Negativ korrelieren im Vergleich erstaunlich stark und die Optimierungen hinsichtlich der Cluster mit Adjektiven und den wirtschaftlichen Keywords verbessern der Ergebnis leicht. Von den ursprünglich erhobenen Frameclustern korrelieren die des Unternehmensjahres mit dem höchsten

⁹ Die zugrundeliegende Tabelle findet sich im Anhang unter Punkt 11.2 Korrelationstabelle.

Return on Assets Wert am stärksten. Die Optimierungen sind allerdings lediglich in der Lage, das beste Ergebnis zu reproduzieren, erhöhen können sie es nicht.

Das neu erhobene Framecluster auf Basis von signifikanten Frames des besten und schlechtesten Unternehmensjahrs erzielt die höchsten Korrelationswerte. Zunächst lassen sich unter Einbezug der aller Cluster 66 positive und signifikante Zusammenhänge bestimmen. Obwohl der Optimierungsansatz hinsichtlich des negativen Wortschatzes des SentiWordNet in anderen Fällen nicht in der Lage war, eine Verbesserung zu erzielen, erhöht die Einschränkung in diesem Fall die Rate um 15 Unternehmen auf 81.

Übergeordnet lassen sich mit den Optimierungen lediglich marginale Verbesserungen erzielen, die darüber hinaus keiner Regelmäßigkeit zu folgen scheinen. Wenn in einem Cluster beispielsweise die Einschränkungen auf den negativen Wortschatz aus dem SentiWordNet die Anzahl der korrelierenden Unternehmen im Vergleich zu allen Frameclustern sinken lässt, so ermöglicht sie doch gleichzeitig in den Clustern des besten vs. schlechtesten Jahres die höchste Rate. Allgemein lässt sich lediglich den wirtschaftlichen Keywords ein positiver Einfluss auf die Anzahlen zuschreiben, da ausschließlich in diesem Fall die Summe der korrelierenden Unternehmen höher liegt, als bei der Berechnung mit allen Clustern.

Letztendlich muss attestiert werden, dass die Optimierungen lediglich in vergleichsweise wenigen Fällen in der Lage sind, die Korrelationsraten zu erhöhen. Darüber hinaus scheinen die Ausschläge keiner Systematik zu folgen. Es wäre zu erwarten, dass Einschränkung in den Featuresets gleichartige Tendenzen aufweisen und entsprechend mehr oder weniger Unternehmen korrelieren, als mit allen Clustern. Dies ist jedoch nicht der Fall. Darüber hinaus muss bedacht werden, dass selbst die maximalen 81 Unternehmen, die im Rahmen des besten vs. schlechtesten Jahres bei Einschränkungen auf negativ markierten Wortschatz, in ein Verhältnis zu allen 478 Unternehmen gesetzt werden müssen. Demnach lässt sich ein signifikanter Zusammenhang zwischen Frameclustern und Return on Assets Wert maximal lediglich in 28,72% beweisen. Das Ziel, mit Hilfe der sprachlichen Musterverteilung Aussagen über die wirtschaftlichen Kennzahlen machen zu können, kann zumindest mit der hier angesetzten Methodik nicht erreicht werden. Die Möglichkeit, ein solches Modell auf Basis von Phraseframes zu generieren ist damit jedoch nicht kategorisch ausgeschlossen. Es zeigt lediglich, dass die gewählten Cluster mit der angelegten Metrik dazu nicht in der Lage sind.

Es kann durchaus Gegenstand weiterer Forschungen sein, die Korrelationswerte zu erhöhen, da sich Einflüsse der zugrundeliegenden Frames nachweisen ließen. Die hier genutzten Optimierungsversuche konnten die Ergebnisse nicht in wünschenswerter Weise verbessern und müssen daher überdacht werden. Für Forschungen in diesem Zusammenhang scheint es allerdings sinnvoll, zur Frameberechnung mit den vergleichsweise erfolgreichsten und verlustreichsten Unternehmensjahren weiterzuarbeiten, da diese insgesamt die höchsten Raten aufwiesen.

9. Fazit und Ausblick

Diese Arbeit hatte das Ziel, die Beziehung zwischen wirtschaftlichen Entwicklungen und dem Sprachgebrauch von Unternehmen in deren Risikoberichterstattung quantitativ zu untersuchen und die gewonnenen Daten qualitativ zu testen. Es sollten Modelle geschaffen werden, die in der Lage sind, ökonomische Tendenzen widerzuspiegeln, sie erklärbar und prognostizierbar zu machen. Im Rahmen von korpuslinguistischen und induktiven Verfahren wurden dazu Phraseframes in spezifischen Unternehmensjahren berechnet, über Signifikanztests ausgewertet, zu Clustern zusammengefasst und mit Hilfe von Korrelationsberechnungen in Relation zur wirtschaftlichen Entwicklung gesetzt.

Einen Kernpunkt der Arbeit bildete die Reduktion des vergleichsweise großen Datenausstoßes der Methodiken und damit der Versuch, möglichst ähnliche Frames zu bündeln. Der gewählte Ansatz setzte dabei auf der Zeichenoberfläche an und kombinierte den Levenshtein-Distanzalgorithmus mit dem Abgleich identischer Zeichenketten. Somit ließen sich Framecluster bilden, die insbesondere überlappende n-Gramme zusammenfassten. Die Ergebnisse der Berechnung sind befriedigend, wenngleich verbesserungswürdig. Das Verfahren lässt sich durchaus auf andere Konstellationen übertragen und hat gezeigt, dass es in der Lage ist, die Datenmenge stark zu reduzieren. Die Clusterbildung basiert jedoch auf der Reihenfolge, wie die Frames vom System eingelesen werden. Der *zentrale* Frame, um welchen sich ein Cluster bildet ist damit nicht zwingend der Häufigste oder statistisch Signifikanteste, sondern der Erste, der bearbeitet wird. Das Vorgehen bleibt damit zwar methodisch nachvollziehbar, die Verallgemeinerbarkeit leidet jedoch darunter, da auf anderen Systemen mit anderen Ergebnissen zu rechnen ist.

Die Framecluster wurden zunächst auf Basis bestimmter Unternehmensjahrgänge gebildet. Somit ließen sich zunächst sechs unterschiedliche Konfigurationen bestimmen und an der tatsächlichen Unternehmensentwicklung testen. Dazu wurden einzelne Unternehmenskorpora gebildet und die Nutzung der Cluster in diesen berechnet. Anschließend Korrelationsrechnungen gaben Aufschluss über signifikant positive Zusammenhänge zwischen der Clusternutzung und der wirtschaftlichen Kennzahl. Dies war zunächst bei 63 Unternehmen der Fall. Über Optimierungen der Framecluster sollte anschließend versucht werden, die Anzahl zu erhöhen. Dazu wurden Manipulationen aus insgesamt fünf Kategorien vorgenommen. Automatisiert wurden die verwendeten Cluster nach den Kriterien verkleinert. Das Vorgehen ist dabei nicht interpretativ. Es wurden vorab lediglich Hypothesen darüber formuliert, welche Einschränkungen sinnvoll sein könnten, die Datenauswahl erfolgte dann maschinell. Die Optimierungsansätze konnten die Ergebnisse jedoch nur marginal verändern, geschweige denn systematisch verbessern. Es zeigte sich keine Regelmäßigkeit und auch die Ausschläge blieben kleiner als erhofft. Die Anzahl der positiven Korrelationen liegt danach mit maximal 81 von 478 möglichen Unternehmen unter einem wünschenswerten Level. Bei diesen 81 ist der Zusammenhang allerdings nicht nur rechnerisch positiv, sondern gleichzeitig statistisch signifikant. Er beruht demnach nicht auf dem Zufall. Die Nutzung der spezifischen Framecluster ist bei diesen Unternehmen in der Lage, Aussagen zur wirtschaftlichen Entwicklung zu machen, sodass neben den numerischen und tabellarischen Angaben in den Risikoberichten, die Sprache einen entscheidenden Einfluss auf Ergebnisse hat.

Über die Resultate der Optimierungen lassen sich Tendenzen abschätzen, die eine Vielzahl weiterer Forschungsfragen aufwerfen und gleichzeitig Ansätze liefern. Das neu erhobene Clusterset aus den Daten der Jahre mit dem höchsten vs. dem niedrigsten Return on Assets Wert brachte die meisten positiven Korrelationen hervor. Es ließe sich daher die Hypothese formulieren, dass mit einer maximalen Differenz der Kennzahl gleichzeitig auch die sprachlichen Unterschiede am größten sind und dass sich die Gegenüberstellung somit als Basis für weitere Untersuchungen eignet. Im Zuge der Clusterbildung ließe sich auch andenken, das Verfahren von der Zeichenebene abzuheben und eventuell Frames nach statistischen Gesichtspunkten zusammenzufassen. Dabei ließen sich eventuell Faktorenanalysen heranziehen. Die Ergebnisse wiederum könnten mit Hilfe von Regressionsanalysen weiter eingeschränkt und somit versucht werden, Framecluster nach ihrem Einfluss zu gewichten.

Wesentlich grundsätzlicher müsste das Konzept der Phraseframes ausgearbeitet werden. Diese Arbeit stützte sich auf Hexagramme mit jeweils zwei Slots – alle Ergebnisse beschreiben daher nur diese spezifische Konstellation. Aussagen, inwiefern andere Framekonfigurationen vergleichsweise bessere oder schlechtere Ergebnisse liefern würden, lassen sich auf theoretischer Basis zumindest noch nicht treffen. Phraseframes scheinen hinsichtlich der zu erwartenden Ergebnisse in Bezug auf Konfigurationen im Moment als unzureichend beschrieben. Weiterführend ließe sich somit überlegen, das genutzte Verfahren auszuweiten und zu testen, wie sich andere Frames verhalten. Vielleicht sind längere n-Gramme mit mehr Slots, kürzere mit weniger oder Hexagramme mit drei oder vier Auslassungen, in der Lage, die wirtschaftliche Realität besser widerzuspiegeln. Dieser Ansatz ließe sich weiter denken und es stellt sich die Frage, ob spezifische Frames in der Lage sind, auch spezifische Bereiche der Sprache abzubilden oder ob sich gar eine „universelle“ Formel findet, die sich für nahezu alle Situationen eignet. Über vergleichende Studien, die verschiedene Konfigurationen untersuchen, sollte sich daher der Kategorie *Phraseframe* weiter angenähert und der theoretische Unterbau erweitert werden. Das scheint jedoch im Moment nur mit empirischen Studien möglich, da aus der Theorie heraus (noch) nicht sinnvoll argumentiert werden kann. Im Rahmen der Grounded Theorie lässt sich die Arbeit insgesamt als Teil des offenen Kodierens denken, in dem sich die Kategorie „Hexagramm mit zwei Leerstellen“ unter Betrachtung von vergleichsweise eindimensionalen Korrelationen eben nicht wirklich bewährt.

Die Arbeit konnte somit zwar das übergeordnete Ziel nicht zufriedenstellend erreichen, jedoch methodische Ansätze ausformulieren und testen. Obwohl die Vorgehensweisen nicht die erhofften Ergebnisse produzierten, konnten Tendenzen ausgemacht und insbesondere Fundamente für weitere Forschungen gelegt werden. Die Untersuchung sprachlicher Muster in Risikoberichten scheint demnach ein produktives Feld, welches sich insbesondere von wirtschaftswissenschaftlicher Seite, zumindest an der TU Dresden durch Prof. Thomas Günther, großer Nachfrage erfreut und auch aus linguistischer Sicht hochspannend erscheint. Die induktive Phraseframeberechnung und besonders die gezielte und gleichzeitig maschinelle Auswertungen der Ergebnisse sollten dabei stark fokussiert werden. Dabei bedarf es neuer Metriken, die die Daten nicht nur weiter vereinfachen, sondern auch spezifizieren. Die Ansätze treffen sich mit den Entwicklungen um „Big Data“ und maschinellem Lernen. Andere Zugänge zu den Daten ermöglichen damit auch weiterführende

Analysen. Das Forschungsgebiet steht somit noch am Anfang einer sicherlich lebendigen Entwicklung, da die schiere Anzahl an Texten stetig steigt und damit auch das Bedürfnis, diese möglichst effizient auszuwerten und bestenfalls nicht manuell analysieren zu müssen.

10. Literaturverzeichnis

- Abraham, Santhosh; Cox, Paul (2007): „Analysing the determinants of narrative risk information in UK FTSE 100 annual reports“. In: *The British Accounting Review*. 39 (3), S. 227–248.
- AktG §91 Abs. 2 (o. J.): *Aktiengesetz § 91: Organisation. Buchführung*.
- Beretta, Sergio; Bozzolan, Saverio (2004): „A framework for the analysis of firm risk communication“. In: *The International Journal of Accounting*. 39 (3), S. 265–288.
- Bloomfield, Leonard (1926): „A Set of Postulates for the Science of Language“. In: *Language*. 2 (3), S. 153–164.
- Boggs, Gene (2015): „Statistics::RankCorrelation“. CPAN. Abgerufen am 12.01.2016 von <http://search.cpan.org/~gene/Statistics-RankCorrelation-0.1205/lib/Statistics/RankCorrelation.pm>.
- Böhm, Andreas (1994): „Grounded Theory - wie aus Texten Modelle und Theorien gemacht werden“. In: Böhm, Andreas; Mengel, Andreas; Muhr, Thomas (Hrsg.) *Texte verstehen: Konzepte, Methoden, Werkzeuge*. Konstanz: UVK Verlagsgesellschaft (Schriften zur Informationswissenschaft), S. 121–140.
- Bonazzi, Anna; Strakatova, Yana; Keilholz, Franz (2016): „Maschinelle Analyse sprachlicher Muster in Risikoberichten - Linguistische Zugänge zur ökonomischen Chancen und Risikokommunikation in amerikanischen 10-K Geschäftsberichten“.
- Brühwiler, Bruno (2001): *Unternehmensweites Risk Management als Frühwarnsystem: Methoden und Prozesse für die Bewältigung von Geschäftsrisiken in integrierten Managementsystemen*. Bern: Haupt.
- Bubenhof, Noah (2016a): „CQPweb: Recherche in den Korpora des Dresden Center for Digital Linguistics“. Abgerufen am 08.09.2016 von http://www.bubenhof.com/korpuslinguistik/kurs/index.php?id=statistik_signifikanzChi.html.
- Bubenhof, Noah (2016b): „Einführung in die Korpuslinguistik (Signifikanz 1)“. Abgerufen am 08.09.2016 von http://www.bubenhof.com/korpuslinguistik/kurs/index.php?id=statistik_signifikanzChi.html.
- Bubenhof, Noah (2009): *Sprachgebrauchsmuster, Korpuslinguistik als Methode der Diskurs- und Kulturanalyse*. Berlin, Boston: De Gruyter.
- Buß, Björn (2015): „Facebook, Inc.“. *Institut für Medien- und Kommunikationspolitik*. Abgerufen am 17.11.2016 von <http://www.mediadb.eu/datenbanken/onlinekonzerne/facebook-inc.html>.
- Cho, Charles H.; Roberts, Robin W.; Patten, Dennis M. (2010): „The language of {US} corporate environmental disclosure“. In: *Accounting, Organizations and Society*. 35 (4), S. 431–443.
- Clarke, Adele E.; Keller, Reiner (Hrsg.) (2012): *Situationsanalyse. Grounded Theory nach dem Postmodern Turn*. Wiesbaden: Springer VS.
- Davis, Angela K.; Piger, Jeremy M.; Sedor, Lisa M. (2012): „Beyond the Numbers: Measuring the Information Content of Earnings Press Release Language“. In: *Contemporary Accounting Research*. 29 (3), S. 845–868.
- Diction (o. J.): „Diction Website“. Abgerufen am 07.12.2016 von <http://www.dictionsoftware.com/product-tour/>.

- Dobler, Michael; Lajili, Kaouthar; Zéghal, Daniel (2011): „Attributes of Corporate Risk Disclosure: An International Investigation in the Manufacturing Sector“. In: *Journal of International Accounting Research*. 10 (2), S. 1–22.
- Duden Online (2016): „Adjektiv“. Abgerufen am von <http://www.duden.de/rechtschreibung/Adjektiv>.
- Elzahar, Hany; Hussainey, Khaled (2012): „Determinants of narrative risk disclosures in UK interim reports“. In: *The Journal of Risk Finance*. 13 (2), S. 133–147.
- Esuli, Andrea; Sebastiani, Fabrizio (2006): „SentiWordNet: A Publicly Available Lexical Resource for Opinion Mining“. In: *In Proceedings of the 5th Conference on Language Resources and Evaluation (LREC'06)*, S. 417–422.
- Faes, Günther (2016a): „Tabelle t-Werte der t-Verteilung“. *Tabelle t-Werte der t-Verteilung*. Abgerufen am 12.10.2016 von <http://www.faes.de/Basis/Basis-Statistik/Basis-Statistik-Korrelation-Re/Basis-Statistik-K-R-t-Test/basis-statistik-k-r-t-test.html>.
- Faes, Günther (2016b): „t-Test zur Prüfung des Korrelationskoeffizienten r“. *t-Test zur Prüfung des Korrelationskoeffizienten r*. Abgerufen am 12.10.2016 von <http://www.faes.de/Basis/Basis-Statistik/Basis-Statistik-Korrelation-Re/Basis-Statistik-K-R-t-Test/basis-statistik-k-r-t-test.html>.
- Fahrmeir, Ludwig; Künstler, Rita; Pigeot, Iris; u. a. (2011): *Statistik - Der Weg zur Datenanalyse*. 7. korrigierter Nachdruck. Berlin; Heidelberg: Springer.
- Feilke, Helmuth (2000): „Die pragmatische Wende in der Textlinguistik“. In: Brinker, Klaus; Antos, Gerd; Heinemann, Wolfgang; u. a. (Hrsg.) *Text- und Gesprächslinguistik/Linguistics of Text and Conversation*. Berlin, New York: De Gruyter (Handbücher zur Sprach- und Kommunikationswissenschaft), S. 64–82.
- Felder, Ekkehard; Müller, Marcus; Vogel, Friedemann (2011): „Korpuspragmatik. Paradigma zwischen Handlung, Gesellschaft und Kognition“. In: Felder, Ekkehard; Müller, Marcus; Vogel, Friedemann (Hrsg.) *Korpuspragmatik Thematische Korpora als Basis diskurslinguistischer Analysen*. Berlin, Boston: De Gruyter (Linguistik – Impulse & Tendenzen), S. 3–30.
- Fillmore, Charles J. (1988): „The Mechanisms of “Construction Grammar”“. In: *Annual Meeting of the Berkeley Linguistics Society*. 14, S. 35–55.
- Fillmore, Charles J.; Atkins, B. T. S. (1992): „Towards a frame-based lexicon: The semantics of RISK and its neighbors“. In: Lehrer, A.; Kittay, E. (Hrsg.) *Frames, Fields and Contrasts: New Essays in Semantics and Lexical Organization*. Hillsdale: Lawrence Erlbaum Associates, S. 75–102.
- Fischer, Kerstin (2006): „Konstruktionsgrammatik und situationales Wissen“. In: Günthner, Susanne; Imo, Wolfgang (Hrsg.) *Konstruktionen in der Interaktion*. Berlin, New York: Walter de Gruyter (Linguistik - Impule & Tendenzen), S. 343–364.
- Fischer, Kerstin; Stefanowitch, Anatol (2006): „Konstruktionsgrammatik: Ein Überblick“. In: Fischer, Kerstin; Stefanowitch, Anatol (Hrsg.) *Konstruktionsgrammatik: Von der Anwendung zur Theorie*. Tübingen: Staufenburg, S. 3–17.
- Gassert, Kathrin (2003): *Risikokommunikation von Unternehmen: Modelle und Strategien am Beispiel gentechnisch veränderter Lebensmittel*. Wiesbaden: Deutscher Universitätsverlag.
- Glaser, Barney G.; Strauss, Anselm L. (2005): *Grounded Theory: Strategien qualitativer Forschung*. 2. korrigierte Auflage. Bern: Huber.
- Goldberg, Adele E (2003): „Constructions. A New Theoretical Approach To Language“. In: *Trends in Cognitive Sciences*. 7 (5), S. 219–224.

- Goldberg, Joachim (2017a): „Marktstimmung: „Das neue Trump-Risiko““. *Marktstimmung: „Das neue Trump-Risiko“*. Abgerufen am 18.01.2017 von <http://www.boerse-frankfurt.de/nachrichten/aktien/Marktstimmung-Das-neue-Trump-Risiko-2243466>.
- Goldberg, Joachim (2017b): „Vertrauensverlust“. *Vertrauensverlust*. Abgerufen am 18.01.2017 von <http://joachim-goldberg.com/2017/01/18/vertrauensverlust/>.
- Hail, Luzi (2002): „Kennzahlenanalyse: Beurteilung von Abschlussinformationen mit Hilfe finanzieller Kennzahlen und Kennzahlensysteme“. In: *Der Schweizer Treuhändler*. 1/2, S. 53–66.
- Hart, Roderick P. (2016): „Curriculum Vita“. Abgerufen am 20.11.2016 von <http://moody.utexas.edu/sites/communication.utexas.edu/files/images/rod-hart-cv.pdf>.
- Hax, Herbert (2005): *Unternehmen und Unternehmer in der Marktwirtschaft*. Göttingen: Vandenhoeck & Ruprecht.
- HGB §315 Abs. 2 (o. J.): *Handelsgesetzbuch § 315: Inhalt des Konzernlageberichts*.
- HGB §325 (o. J.): *Handelsgesetzbuch § 325: Offenlegung*.
- International Organization for Standardization (2013): „ISO 6166:2013(en), Securities and related financial instruments — International securities identification numbering system (ISIN)“. Abgerufen am 05.09.2016 von <https://www.iso.org/obp/ui/#iso:std:iso:6166:ed-7:v1:en>.
- Jacobsen, Kjell; Adams, Michael (Hrsg.) (2015): *Die Pflicht zum Risikomanagement im Aktienrecht*. Frankfurt am Main: Internationaler Verlag der Wissenschaften (Ökonomische Analyse des Rechts - Schriftenreihe Law and Economics).
- Kaack, Jörn (2012): *Performance Measurement für die Unternehmenssicherheit: Entwurf eines Kennzahlen- und Indikatorensystems und die prozessorientierte Implementierung*. Wiesbaden: Springer Gabler.
- Kajüter, Peter (2012): *Risikomanagement im Konzern: eine empirische Analyse börsennotierter Aktienkonzerne*. München: Vahlen.
- Katarzyna, Smirska (2009): *Optimierung eines Risikomanagementsystems im Mittelstand*. Norderstedt: Books on Demand GmbH.
- Knight, Frank H. (1921): *Risk, Uncertainty and Profit*. Boston: The Riverside Press Cambridge.
- Kravet, Todd; Muslu, Volkan (2013): „Textual risk disclosures and investors’ risk perceptions“. In: *Review of Accounting Studies*. 18 (4), S. 1088–1122.
- Kürsten, Wolfgang; Straßberger, Mario (Hrsg.) (2004): „Risikomessung, Risikomaße und Value-at-Risk“. In: *Das Wirtschaftsstudium*. 33, S. 202–207.
- Levenshtein, Vladimir I. (1965): „Binary codes capable of correcting spurious insertions and deletions of ones“. In: *Problems of Information Transmission*. (1), S. 8–17.
- Li, Feng; Asare, Stephen K.; Knechel, Warren R. (Hrsg.) (2010a): „Textual analysis of corporate disclosures: A survey of the literature“. In: *Journal of Accounting Literature*. 29, S. 143–165.
- Li, Feng (2010b): „The Information Content of Forward-Looking Statements in Corporate Filings—A Naïve Bayesian Machine Learning Approach“. In: *Journal of Accounting Research*. 48 (5), S. 1049–1102.
- Lies, Jan (o. J.): „Unternehmenskommunikation“. *Gabler Wirtschaftslexikon*. Abgerufen am 12.12.2016 von <http://wirtschaftslexikon.gabler.de/Archiv/326741/unternehmenskommunikation-v7.html>.
- Linsley, Philip. M.; Shrives, Philip. J. (2005): „Examining risk reporting in UK public companies“. In: *Journal of Risk Finance*. 6 (4), S. 292–305.

- Mast, Claudia (2015): „Was ist Unternehmenskommunikation?“. In: Hundt, Markus; Biadala, Dorota (Hrsg.) *Handbuch Sprache in der Wirtschaft*. Berlin, Boston: De Gruyter Mouton, S. 3–24.
- Matthias, Schulenberg (o. J.): „Bundesanzeiger - Über uns“. Abgerufen am 10.11.2016 von <https://www.bundesanzeiger-verlag.de/ueber-uns/editorial.html>.
- Mey, Günther; Mruck, Katja (2010): „Grounded-Theorie-Methodologie“. In: Mey, Günther; Mruck, Katja (Hrsg.) *Handbuch Qualitative Forschung in der Psychologie*. Wiesbaden: VS Verlag für Sozialwissenschaften, S. 614–626.
- Minsky, Marvin (1975): „A Framework for Representing Knowledge“. In: Winston, Patrick Henry (Hrsg.) *The Psychology of Computer Vision*. McGraw-Hill.
- Murphy, John J. (2006): *Technische Analyse der Finanzmärkte: Grundlagen, Methoden, Strategien, Anwendungen*. 3. aktualisierte Auflage. München: FinanzBuch-Verlag.
- Myers, Brad A. (1998): „A Brief History of Human Computer Interaction Technology“. In: *ACM interactions*. 5 (2), S. 44–54.
- Perkuhn, Rainer; Belica, Cyril (2006): „Korpuslinguistik – Das unbekannte Wesen oder Mythen über Korpora und Korpuslinguistik“. In: *Sprachreport : Informationen und Meinungen zur deutschen Sprache*. 22 (1), S. 2–8.
- Perkuhn, Rainer; Keibel, Holger; Kupietz, Marc (2012): *Korpuslinguistik*. Paderborn: Fink.
- Rogler, Silvia (2002): *Risikomanagement im Industriebetrieb: Analyse von Beschaffungs-, Produktions- und Absatzrisiken*. Wiesbaden: Springer-Verlag (Neue betriebswirtschaftliche Forschung).
- Scharloth, Joachim (2017): „Korpuspragmatik“. In: Hagemann, Jörg; Staffeldt, Sven (Hrsg.) *Pragmatheorien II. Diskursanalysen im Vergleich*. Tübingen: Stauffenburg (eingereicht).
- Scharloth, Joachim; Bubenhofer, Noah (2011): „Datengeleitete Korpuspragmatik. Korpusvergleich als Methode der Stilanalyse“. In: Felder, Ekkehard; Müller, Marcus; Vogel, Friedemann (Hrsg.) *Korpuspragmatik Thematische Korpora als Basis diskurslinguistischer Analysen*. Berlin, Boston: De Gruyter (Linguistik – Impulse & Tendenzen), S. 195–230.
- Scharloth, Joachim; Bubenhofer, Noah (2010): „Kontext korpuslinguistisch: Die induktive Berechnung von Sprachgebrauchsmustern in großen Textkorpora“. In: Klotz, Peter; Portmann-Tselikas, Paul; Weidacher, Georg (Hrsg.) *Text-Zeichen und Kon-Texte. Studien zu soziokulturellen Konstellationen literalen Handelns*. Tübingen: Niemeyer, S. 85–108.
- Scharnbacher, Kurt (2002): *Statistik im Betrieb - Lehrbuch mit praktischen Beispielen*. 13. Aufl. Wiesbaden: Gabler.
- Schmid, Beat F.; Lyczek, Boris (2008): „Die Rolle der Kommunikation in der Wertschöpfung der Unternehmung“. In: Meckel, Miriam; Schmid, Beat F. (Hrsg.) *Unternehmenskommunikation: Kommunikationsmanagement aus Sicht der Unternehmensführung*. 2., überarbeitete und erweiterte Auflage. Wiesbaden: Gabler, S. 3–152.
- Schmid, H. (1999): „Improvements in Part-of-Speech Tagging with an Application to German“. In: Armstrong, Susan; Church, Kenneth; Isabelle, Pierre; u. a. (Hrsg.) *Natural Language Processing Using Very Large Corpora*. Dordrecht: Springer Netherlands, S. 13–25.
- Schmid, Helmut (1994): „Probabilistic Part-of-Speech Tagging Using Decision Trees“. In: *International Conference on New Methods in Language Processing*. Manchester, UK, S. 44–49.

- Schwarz-Friesel, Monika (2009): „Ironie als indirekter expressiver Sprechakt: Zur Funktion emotionsbasierter Implikaturen bei kognitiver Simulation“. In: Bachmann-Stein, Andrea; Merten, Stephen; Roth, Christiane (Hrsg.) *Perspektiven auf Wort, Satz und Text: Semantisierungsprozesse auf unterschiedlichen Ebenen des Sprachsystems*. Trier: WVT Wissenschaftlicher Verlag Trier, S. 223–232.
- SentiWordNet (2010): „How to obtain SentiWordNet“. *SentiWordNet*. Abgerufen am 10.12.2016 von <http://sentiwordnet.isti.cnr.it/>.
- Sexena, Achintya Nath; Dube, Indrajit; Mishra, C.S. (2015): „Corporate Risk Disclosure: a review (working paper)“. IIT-Kharagpur.
- Standard & Poor's (2016): „S&P Factsheet“.
- TEI (2014): „What is the TEI?“. *TEI: Frequently Asked Questions*. Abgerufen am 12.10.2016 von http://www.tei-c.org/About/faq.xml#body.1_div.1_div.1.
- Thommen, Jean-Paul (o. J.): „Anspruchsgruppen“. *Gabler Wirtschaftslexikon*. Abgerufen am 12.10.2016 von <http://wirtschaftslexikon.gabler.de/Archiv/1202/anspruchsgruppen-v6.html>.
- Truschkat, Inga; Kaiser, Manuela; Reinartz, Vera (2005): „Forschen nach Rezept? Anregungen zum praktischen Umgang mit der Grounded Theory in Qualifikationsarbeiten“. In: *Forum Qualitative Sozialforschung / Forum: Qualitative Social Research*. 6 (2), S. 18.
- United States Congress (1934): *Securities Exchange Act of 1934*.
- Volkswagen AG (2016): „Geschäftsbericht 2015“. *Volkswagen AG Geschäftsbericht*. Abgerufen am 13.12.2016 von https://www.volkswagenag.com/presence/startseite/dokumente/Volkswagen_AG_Gesch%C3%A4ftsbericht_2015_de.pdf.
- Wikibooks (2016): „Perl“. *Algorithm Implementation/Strings/Levenshtein distance*. Abgerufen am 15.11.2016 von https://en.wikibooks.org/w/index.php?title=Algorithm_Implementation/Strings/Levenshtein_distance&oldid=3120544.
- Wildgen, Wolfgang (1990): „Konstruktionsgrammatik“. In: Wagner, Karl Heinz; Wildgen, Wolfgang (Hrsg.) *Studien zur Grammatik und Sprachtheorie*. Bremen: Institut für Allgemeine und Angewandte Sprachwissenschaft, Universität Bremen, S. 65–84.
- Wittmann, Waldemar (1959): *Unternehmung und unvollkommene Information: Unternehmerische Voraussicht - Ungewißheit und Planung*. Köln: Westdeutscher Verlag.
- Zepp, Marcus (2009): *Der Risikobericht von Kreditinstituten*. Berlin: Erich Schmidt Verlag.
- Ziem, Alexander (2005): „Frame-Semantik und Diskursanalyse. Zur Verwandtschaft zweier Wissensanalysen“. In: *Diskursanalyse in Deutschland und Frankreich: Aktuelle Tendenzen in den Sprach- und Sozialwissenschaften*.

11. Anhang

11.1. Unternehmen und Jahrgänge

Wenn die Anzahl der vorhandenen Dokumente nicht mit den Jahren von-bis übereinstimmt, fehlen innerhalb der Spanne einzelne Jahrgänge. Die Lücken wurden nicht einzeln aufgeführt. Darüber hinaus wird nur ein Unternehmensname angegeben, auch wenn dieser sich änderte. Eine eindeutige Bestimmung kann mit Hilfe der ISIN-Nummer vorgenommen werden.

Unternehmensname	ISIN	Anzahl	Jahre	Unternehmensname	ISIN	Anzahl	Jahre
3M CO	US88579Y1010	10	06-15	American Water Works Company, Inc.	US0304201033	7	09-15
ABBOTT LABORATORIES	US0028241000	10	06-15	Aon plc	GB00B5BT0K07	10	06-15
ACTIVISION INC /NY	US00507V1098	10	06-15	Avery Dennison Corp	US0536111091	10	06-15
ACUITY BRANDS INC	US00508Y1029	10	06-15	BAKER HUGHES INC	US0572241075	10	06-15
ADOBE SYSTEMS INC	US00724F1012	10	06-15	BALL CORP	US0584981064	10	06-15
ADVANCE AUTO PARTS INC	US00751Y1064	10	06-15	BANK OF AMERICA CORP /DE/	US0605051046	10	06-15
AES CORP	US00130H1059	10	06-15	BARD C R INC /NJ/	US0673831097	10	06-15
AETNA INC /PA/	US00817Y1082	10	06-15	BAXTER INTERNATIONAL INC	US0718131099	10	06-15
AFFILIATED MANAGERS GROUP INC	US0082521081	10	06-15	BB&T CORP	US0549371070	10	06-15
AFLAC INC	US0010551028	10	06-15	BECTON DICKINSON & CO	US0758871091	10	06-15
AGILENT TECHNOLOGIES INC	US00846U1016	10	06-15	BED BATH & BEYOND INC	US0758961009	10	06-15
AGL RESOURCES INC	US0012041069	10	06-15	BERKSHIRE HATHAWAY INC	US0846707026	10	06-15
AIR PRODUCTS & CHEMICALS INC /DE/	US0091581068	10	06-15	BEST BUY CO INC	US0865161014	9	06-15
AKAMAI TECHNOLOGIES INC	US00971T1016	10	06-15	BIOGEN IDEC INC.	US09062X1037	10	06-15
ALASKA AIR GROUP INC	US0116591092	10	06-15	BOEING CO	US0970231058	10	06-15
ALCOA INC.	US0138171014	10	06-15	BORGWARNER INC	US0997241064	10	06-15
ALEXION PHARMACEUTICALS INC	US0153511094	9	07-15	BOSTON PROPERTIES INC	US1011211018	10	06-15
ALLERGAN INC	IE00BY9D5467	10	06-15	BOSTON SCIENTIFIC CORP	US1011371077	10	06-15
ALLIANCE DATA SYSTEMS CORP	US0185811082	10	06-15	BRISTOL MYERS SQUIBB CO	US1101221083	10	06-15
ALLSTATE CORP	US0200021014	10	06-15	BROADCOM CORP	SG9999014823	10	06-15
ALTRIA GROUP, INC.	US02209S1033	10	06-15	BROWN FORMAN CORP	US1156372096	10	06-15
AMAZON COM INC	US0231351067	10	06-15	Bank of New York Mellon Corp	US0640581007	8	08-15
AMB PROPERTY CORP	US74340W1036	10	06-15	BlackRock Inc.	US09247X1019	9	07-15
AMERICAN ELECTRIC POWER CO INC	US0255371017	10	06-15	C H ROBINSON WORLDWIDE INC	US12541W2098	10	06-15
liter	US0258161092	10	06-15	CA, INC.	US12673P1057	10	06-15
AMERICAN INTERNATIONAL GROUP INC	US0268747849	10	06-15	CABOT OIL & GAS CORP	US1270971039	10	06-15
AMERICAN TOWER CORP /MA/	US03027X1000	10	06-15	CAMPBELL SOUP CO	US1344291091	10	06-15
AMERIPRISE FINANCIAL INC	US03076C1062	10	06-15	CAPITAL ONE FINANCIAL CORP	US14040H1059	10	06-15
AMERISOURCEBERGEN CORP	US03073E1055	10	06-15	CARDINAL HEALTH INC	US14149Y1082	9	06-14
AMETEK INC/	US0311001004	10	06-15	CARMAX INC	US1431301027	10	06-15
AMGEN INC	US0311621009	10	06-15	CARNIVAL PLC	PA1436583006	10	06-15
AMPHENOL CORP /DE/	US0320951017	10	06-15	CAROLINA POWER & LIGHT CO	US26441C2044	10	06-15

AMR CORP	US02376R1023	10	06-15	CATERPILLAR INC	US1491231015	10	06-15
ANADARKO PETROLEUM CORP	US0325111070	10	06-15	CB RICHARD ELLIS GROUP INC	US12504L1098	10	06-15
ANALOG DEVICES INC	US0326541051	10	06-15	CBS CORP	US1248572026	10	06-15
APACHE CORP	US0374111054	10	06-15	CELGENE CORP /DE/	US1510201049	10	06-15
APARTMENT INVESTMENT & MANAGEMENT CO	US03748R1014	10	06-15	CENTENE CORP	US15135B1017	10	06-15
APPLE INC	US0378331005	10	06-15	CENTERPOINT ENERGY INC	US15189T1079	10	06-15
APPLIED MATERIALS INC /DE	US0382221051	10	06-15	CENTRAL ILLINOIS LIGHT CO	US0236081024	10	06-15
ARCHER DANIELS MIDLAND CO	US0394831020	9	06-15	CENTURYLINK, INC	US1567001060	10	06-15
ASSURANT INC	US04621X1081	10	06-15	CERNER CORP /MO/	US1567821046	10	06-15
AT&T INC.	US00206R1023	10	06-15	CF Industries Holdings, Inc.	US1252691001	10	06-15
AUTODESK INC	US0527691069	10	06-15	CHESAPEAKE ENERGY CORP	US1651671075	10	06-15
AUTOMATIC DATA PROCESSING INC	US0530151036	10	06-15	CHEVRON CORP	US1667641005	10	06-15
AUTONATION, INC.	US05329W1027	10	06-15	CHICAGO MERCANTILE EXCHANGE HOLDINGS INC	US12572Q1058	10	06-15
AUTOZONE INC	US0533321024	10	06-15	CHIPOTLE MEXICAN GRILL INC	US1696561059	10	06-15
AVALONBAY COMMUNITIES INC	US0534841012	10	06-15	CHUBB CORP	CH0044328745	10	06-15
AbbVie Inc.	US00287Y1091	3	13-15	CHURCH & DWIGHT CO INC /DE/	US1713401024	10	06-15
Accenture plc	IE00B4BNMY34	7	09-15	CIGNA CORP	US1255091092	10	06-15
Allegion plc	IE00BFRT3W74	2	14-15	CIMAREX ENERGY CO	US1717981013	10	06-15
CINCINNATI FINANCIAL CORP	US1720621010	10	06-15	EMC CORP	US2686481027	10	06-15
CINTAS CORP	US1729081059	10	06-15	EMERSON ELECTRIC CO	US2910111044	10	06-15
CISCO SYSTEMS, INC.	US17275R1023	10	06-15	ENTERGY CORP /DE/	US29364G1031	10	06-15
CITIZENS FINANCIAL GROUP INC/RI	US1746101054	1	15-15	EOG RESOURCES INC	US26875P1012	10	06-15
CITRIX SYSTEMS INC	US1773761002	10	06-15	EQUIFAX INC	US2944291051	10	06-15
CLOROX CO /DE/	US1890541097	10	06-15	EQUINIX INC	US29444U7000	10	06-15
COACH INC	US1897541041	10	06-15	EQUITABLE RESOURCES INC /PA/	US26884L1098	10	06-15
COCA COLA CO	US1912161007	10	06-15	ESSEX PROPERTY TRUST INC	US2971781057	10	06-15
COGNIZANT TECHNOLOGY SOLUTIONS CORP	US1924461023	10	06-15	ESTEE LAUDER COMPANIES INC	US5184391044	10	06-15
COLGATE PALMOLIVE CO	US1941621039	10	06-15	EXELON GENERATION CO LLC	US30161N1019	10	06-15
COMCAST CORP	US20030N1019	10	06-15	EXPEDITORS INTERNATIONAL OF WASHINGTON INC	US3021301094	10	06-15
COMERICA INC /NEW/	US2003401070	10	06-15	EXXON MOBIL CORP	US30231G1022	10	06-15
CONAGRA FOODS INC /DE/	US2058871029	10	06-15	Eaton Corp plc	IE00B8KQN827	3	13-15
CONCHO RESOURCES INC	US20605P1012	8	08-15	Edwards Lifesciences Corp	US28176E1082	10	06-15
CONOCOPHILLIPS	US20825C1045	10	06-15	Endo International plc	IE00BJ3V9050	1	15-15
CONSOLIDATED EDISON INC	US2091151041	10	06-15	Expedia, Inc.	US30212P3038	10	06-15
CONSTELLATION BRANDS, INC.	US21036P1084	10	06-15	Express Scripts Holding Co.	US30219G1085	3	13-15
CONSUMERS ENERGY CO	US1258961002	10	06-15	Extra Space Storage Inc.	US30225T1025	10	06-15
CORNING INC /NY	US2193501051	10	06-15	F5 NETWORKS INC	US3156161024	10	06-15
COSTCO WHOLESALE CORP /NEW	US22160K1051	10	06-15	FASTENAL CO	US3119001044	10	06-15
CROWN CASTLE INTERNATIONAL CORP	US22822V1017	10	06-15	FEDERAL REALTY INVESTMENT TRUST	US3137472060	10	06-15
CSC HOLDINGS LLC	US12686C1099	10	06-15	FEDEX CORP	US31428X1063	10	06-15
CSX CORP	US1264081035	10	06-15	FIFTH THIRD BANCORP	US3167731005	10	06-15
CUMMINS INC	US2310211063	10	06-15	FIRST SOLAR, INC.	US3364331070	9	07-15
CVS CAREMARK CORP	US1266501006	8	08-15	FIRSTENERGY CORP	US3379321074	10	06-15

DANAHER CORP /DE/	US2358511028	10	06-15	FISERV INC	US3377381088	10	06-15
DARDEN RESTAURANTS INC	US2371941053	10	06-15	FLIR SYSTEMS INC	US3024451011	10	06-15
DAVITA INC	US23918K1088	10	06-15	FLOWERVE CORP	US34354P1057	10	06-15
DEERE & CO	US2441991054	10	06-15	FLUOR CORP	US3434121022	10	06-15
DELTA AIR LINES INC /DE/	US2473617023	10	06-15	FMC CORP	US3024913036	10	06-15
DEVON ENERGY CORP/DE	US25179M1036	10	06-15	FMC TECHNOLOGIES INC	US30249U1016	10	06-15
DIAMOND OFFSHORE DRILLING INC	US25271C1027	10	06-15	FOOT LOCKER INC	US3448491049	10	06-15
DOLLAR GENERAL CORP	US2566771059	10	06-15	FORD MOTOR CO	US3453708600	10	06-15
DOLLAR TREE STORES INC	US2567461080	10	06-15	FRANKLIN RESOURCES INC	US3546131018	10	06-15
DOMINION RESOURCES INC /VA/	US25746U1097	10	06-15	FREEMPORT-MCMORAN INC	US35671D8570	1	15-15
DOVER CORP	US2600031080	10	06-15	FRONTIER COMMUNICATIONS CORP	US35906A1088	10	06-15
DOW CHEMICAL CO /DE/	US2605431038	10	06-15	Facebook Inc	US30303M1027	3	13-15
DTE ENERGY CO	US2333311072	10	06-15	Fidelity National Information Services, Inc.	US31620M1062	10	06-15
DUN & BRADSTREET CORP/NW	US26483E1001	10	06-15	GALLAGHER ARTHUR J & CO	US3635761097	10	06-15
Delphi Automotive PLC	JE00B783TY65	4	12-15	GAP INC	US3647601083	10	06-15
Digital Realty Trust, Inc.	US2538681030	10	06-15	GARMIN LTD	CH0114405324	10	06-15
Discover Financial Services	US2547091080	8	08-15	GENERAL DYNAMICS CORP	US3695501086	10	06-15
Discovery Communications, Inc.	US25470F1049	7	09-15	GENERAL ELECTRIC CO	US3696041033	10	06-15
Discovery Communications, Inc.	US25470F3029	7	09-15	GENERAL MILLS INC	US3703341046	10	06-15
Dr Pepper Snapple Group, Inc.	US26138E1091	6	09-14	GENUINE PARTS CO	US3724601055	10	06-15
E TRADE FINANCIAL Corp	US2692464017	10	06-15	GILEAD SCIENCES INC	US3755581036	10	06-15
EASTMAN CHEMICAL CO	US2774321002	10	06-15	GLOBAL PAYMENTS INC	US37940X1028	10	06-15
EBAY INC	US2786421030	10	06-15	GOLDMAN SACHS GROUP INC/	US38141G1040	10	06-15
ECOLAB INC	US2788651006	10	06-15	GOODYEAR TIRE & RUBBER CO /OH/	US3825501014	10	06-15
ELECTRONIC ARTS INC.	US2855121099	10	06-15	General Motors Co	US37045V1008	6	10-15
H&R BLOCK INC	US0936711052	10	06-15	KROGER CO	US5010441013	10	06-15
HALF ROBERT INTERNATIONAL INC /DE/	US7703231032	10	06-15	L 3 COMMUNICATIONS HOLDINGS INC	US5024241045	10	06-15
HALLIBURTON CO	US4062161017	10	06-15	L Brands, Inc.	US5017971046	10	06-15
HARLEY DAVIDSON INC	US4128221086	10	06-15	LABORATORY CORP OF AMERICA HOLDINGS	US50540R4092	10	06-15
HARMAN INTERNATIONAL INDUSTRIES INC /DE/	US4130861093	10	06-15	LAM RESEARCH CORP	US5128071082	9	06-15
HARRIS CORP /DE/	US4138751056	10	06-15	LEGG MASON, INC.	US5249011058	10	06-15
HARTFORD FINANCIAL SERVICES GROUP INC/DE	US4165151048	10	06-15	LEGGETT & PLATT INC	US5246601075	10	06-15
HASBRO INC	US4180561072	10	06-15	LENNAR CORP /NEW/	US5260571048	10	06-15
HCA INC/TN	US40412C1018	10	06-15	LEUCADIA NATIONAL CORP	US5272881047	10	06-15
HCP, INC.	US40414L1098	10	06-15	LEVEL 3 COMMUNICATIONS INC	US52729N3089	10	06-15
HENRY SCHEIN INC	US8064071025	10	06-15	LILLY ELI & CO	US5324571083	10	06-15
HERSHEY CO	US4278661081	10	06-15	LINCOLN NATIONAL CORP	US5341871094	10	06-15
HESS CORP	US42809H1077	10	06-15	LINEAR TECHNOLOGY CORP /CA/	US5356781063	10	06-15
HEWLETT PACKARD CO	US40434L1052	10	06-15	LKQ CORP	US5018892084	10	06-15
HOLOGIC INC	US4364401012	10	06-15	LOCKHEED MARTIN CORP	US5398301094	10	06-15
HOME DEPOT INC	US4370761029	10	06-15	LOEWS CORP	US5404241086	10	06-15
HONEYWELL INTERNATIONAL INC	US4385161066	10	06-15	LOWES COMPANIES INC	US5486611073	10	06-15
HORMEL FOODS CORP /DE/	US4404521001	10	06-15	LyondellBasell Industries N.V.	NL0009434992	5	11-15

HUMANA INC	US4448591028	10	06-15	M&T BANK CORP	US55261F1049	10	06-15
HUNT J B TRANSPORT SERVICES INC	US4456581077	10	06-15	MACERICH CO	US5543821012	10	06-15
HUNTINGTON BANCSHARES INC/MD	US4461501045	10	06-15	MARATHON OIL CORP	US5658491064	10	06-15
Hanesbrands Inc.	US4103451021	9	06-15	MARRIOTT INTERNATIONAL INC /MD/	US5719032022	10	06-15
Helmerich & Payne, Inc.	US4234521015	10	06-15	MARSH & MCLENNAN COMPANIES, INC.	US5717481023	10	06-15
Hewlett Packard Enterprise Co	US42824C1099	1	15-15	MARTIN MARIETTA MATERIALS INC	US5732841060	10	06-15
ILLINOIS TOOL WORKS INC	US4523081093	10	06-15	MASCO CORP /DE/	US5745991068	10	06-15
ILLUMINA INC	US4523271090	10	06-15	MASTERCARD INC	US57636Q1040	10	06-15
INTEL CORP	US4581401001	10	06-15	MATTEL INC /DE/	US5770811025	10	06-15
INTERNATIONAL BUSINESS MACHINES CORP	US4592001014	10	06-15	MCCORMICK & CO INC	US5797802064	10	06-15
INTERNATIONAL FLAVORS & FRAGRANCES INC	US4595061015	10	06-15	MCDONALDS CORP	US5801351017	10	06-15
INTERNATIONAL PAPER CO /NEW/	US4601461035	10	06-15	MCKESSON CORP	US58155Q1031	10	06-15
INTERPUBLIC GROUP OF COMPANIES, INC.	US4606901001	10	06-15	METLIFE INC	US59156R1086	10	06-15
INTUIT INC	US4612021034	10	06-15	MICROCHIP TECHNOLOGY INC	US5950171042	10	06-15
INTUITIVE SURGICAL INC	US46120E6023	10	06-15	MICRON TECHNOLOGY INC	US5951121038	10	06-15
IRON MOUNTAIN INC	US46284V1017	10	06-15	MICROSOFT CORP	US5949181045	10	06-15
Ingersoll-Rand plc	IE00B6330302	6	10-15	MOHAWK INDUSTRIES INC	US6081901042	10	06-15
Intercontinental Exchange, Inc.	US45866F1049	2	14-15	MOLSON COORS BREWING CO	US60871R2094	10	06-15
Invesco Ltd.	BMG491BT1088	8	08-15	MONSANTO CO /NEW/	US61166W1018	10	06-15
J M SMUCKER Co	US8326964058	10	06-15	MOODYS CORP /DE/	US6153691059	10	06-15
JACOBS ENGINEERING GROUP INC /DE/	US4698141078	10	06-15	MORGAN STANLEY	US6174464486	10	06-15
JOHNSON & JOHNSON	US4781601046	10	06-15	MOSAIC CO	US61945C1036	9	06-15
JOHNSON CONTROLS INC	US4783661071	10	06-15	MURPHY OIL CORP /DE	US6267171022	10	06-15
JUNIPER NETWORKS INC	US48203R1041	10	06-15	MYLAN LABORATORIES INC	NL0011031208	9	06-15
KANSAS CITY SOUTHERN	US4851703029	10	06-15	Mallinckrodt plc	IE00BBGT3753	3	13-15
KELLOGG CO	US4878361082	10	06-15	Marathon Petroleum Corp	US56585A1025	4	12-15
KEYCORP /NEW/	US4932671088	10	06-15	Mead Johnson Nutrition Co	US5828391061	7	09-15
KIMBERLY CLARK CORP	US4943681035	10	06-15	Medtronic plc	IE00BTN1Y115	1	15-15
KIMCO REALTY CORP	US49446R1095	10	06-15	Merck & Co. Inc.	US58933Y1055	10	06-15
KINDER MORGAN, INC.	US49456B1017	8	06-15	Michael Kors Holdings Ltd	VGG607541015	3	13-15
KLA TENCOR CORP	US4824801009	9	07-15	Mondelez International, Inc.	US6092071058	10	06-15
KOHL'S Corp	US5002551043	10	06-15	Monster Beverage Corp	US61174X1090	10	06-15
Motorola Solutions, Inc.	US6200763075	10	06-15	PRUDENTIAL FINANCIAL INC	US7443201022	10	06-15
NASDAQ OMX GROUP, INC.	US6311031081	10	06-15	PUBLIC SERVICE CO OF NORTH CAROLINA INC	US80589M1027	10	06-15
NATIONAL OILWELL VARCO INC	US6370711011	10	06-15	PUBLIC SERVICE ENTERPRISE GROUP INC	US7445731067	10	06-15
NAVIENT CORP	US63938C1080	1	15-15	PULTEGROUP INC/MI/	US7458671010	5	11-15
NETFLIX INC	US64110L1061	10	06-15	PVH CORP. /DE/	US6936561009	4	12-15
NETWORK APPLIANCE INC	US64110D1046	10	06-15	Philip Morris International Inc.	US7181721090	7	09-15
NEWFIELD EXPLORATION CO /DE/	US6512901082	10	06-15	Phillips 66	US7185461040	3	13-15
NEWMONT MINING CORP /DE/	US6516391066	10	06-15	Public Storage	US74460D1090	8	08-15
NEWS CORP	US65249B1098	10	06-15	QUALCOMM INC/DE	US7475251036	10	06-15
NEWS CORP	US65249B2088	10	06-15	QUANTA SERVICES INC	US74762E1029	10	06-15

NEXTERA ENERGY INC	US65339F1012	10	06-15	QUEST DIAGNOSTICS INC	US74834L1008	10	06-15
NISOURCE INC/DE	US65473P1057	10	06-15	Qorvo, Inc.	US74736K1016	1	15-15
NOBLE ENERGY INC	US6550441058	10	06-15	RALPH LAUREN CORP	US7512121010	4	12-15
NORDSTROM INC	US6556641008	10	06-15	RANGE RESOURCES CORP	US75281A1097	10	06-15
NORFOLK SOUTHERN CORP	US6558441084	10	06-15	RAYTHEON CO/	US7551115071	10	06-15
NORTHERN TRUST CORP	US6658591044	10	06-15	REALTY INCOME CORP	US7561091049	10	06-15
NORTHROP GRUMMAN CORP /DE/	US6668071029	10	06-15	RED HAT INC	US7565771026	10	06-15
NRG ENERGY, INC.	US6293775085	10	06-15	REGENERON PHARMACEUTICALS INC	US75886F1075	10	06-15
NUCOR CORP	US6703461052	10	06-15	REGIONS FINANCIAL CORP	US7591EP1005	10	06-15
NVIDIA CORP	US67066G1040	10	06-15	REPUBLIC SERVICES, INC.	US7607591002	10	06-15
Nielsen Holdings N.V.	GB00BWFY5505	5	11-15	REYNOLDS AMERICAN INC	US7617131062	10	06-15
O REILLY AUTOMOTIVE INC	US67103H1077	10	06-15	ROCKWELL AUTOMATION INC	US7739031091	10	06-15
OCCIDENTAL PETROLEUM CORP /DE/	US6745991058	9	07-15	ROCKWELL COLLINS INC	US7743411016	10	06-15
OMNICOM GROUP INC.	US6819191064	10	06-15	ROSS STORES INC	US7782961038	10	06-15
ONEOK INC /NEW/	US6826801036	10	06-15	ROYAL CARIBBEAN CRUISES LTD	LR0008862868	10	06-15
ORACLE CORP	US68389X1054	10	06-15	RYDER SYSTEM INC	US7835491082	10	06-15
OWENS ILLINOIS INC /DE/	US6907684038	10	06-15	SALESFORCE COM INC	US79466L3024	10	06-15
PACCAR INC	US6937181088	10	06-15	SCHLUMBERGER LTD /NV/	AN8068571086	10	06-15
PACIFIC ENTERPRISES INC	US8168511090	10	06-15	SCHWAB CHARLES CORP	US8085131055	10	06-15
PARKER HANNIFIN CORP	US7010941042	10	06-15	SEALED AIR CORP/DE	US81211K1007	10	06-15
PATTERSON COMPANIES, INC.	US7033951036	10	06-15	SHERWIN WILLIAMS CO	US8243481061	10	06-15
PAYCHEX INC	US69351T1060	10	06-15	SIGNET JEWELERS LTD	BMG812761002	6	10-15
PAYCHEX INC	US7043261079	10	06-15	SIMON PROPERTY GROUP INC /DE/	US8288061091	10	06-15
PENTAIR INC	IE00BLS09M33	8	06-15	SKYWORKS SOLUTIONS, INC.	US83088M1027	10	06-15
PERKINELMER INC	US7140461093	10	06-15	SL GREEN REALTY CORP	US78440X1019	10	06-15
PERRIGO Co plc	IE00BGH1M568	2	14-15	SNAP-ON Inc	US8330341012	10	06-15
PFIZER INC	US7170811035	10	06-15	SOUTHERN CALIFORNIA EDISON CO	US2810201077	9	06-14
PG&E Corp	US69331C1080	10	06-15	SOUTHERN CO	US8425871071	10	06-15
PINNACLE WEST CAPITAL CORP	US7234841010	10	06-15	SOUTHWEST AIRLINES CO	US8447411088	10	06-15
PIONEER NATURAL RESOURCES CO	US7237871071	10	06-15	SOUTHWESTERN ENERGY CO	US8454671095	10	06-15
PITNEY BOWES INC /DE/	US7244791007	7	06-12	ST JUDE MEDICAL INC	US7908491035	10	06-15
PNC FINANCIAL SERVICES GROUP, INC.	US6934751057	10	06-15	STANLEY BLACK & DECKER, INC.	US8545021011	10	06-15
PPG INDUSTRIES INC	US6935061076	10	06-15	STAPLES INC	US8550301027	10	06-15
PPL Corp	US7134481081	10	06-15	STARBUCKS CORP	US8552441094	10	06-15
PRAXAIR INC	US74005P1049	10	06-15	STARWOOD HOTEL & RESORTS WORLDWIDE INC	US85590A4013	10	06-15
PRICE T ROWE GROUP INC	US74144T1088	10	06-15	STATE STREET Corp	US8574771031	10	06-15
PRICELINE COM INC	US7415034039	10	06-15	STERICYCLE INC	US8589121081	10	06-15
PRINCIPAL FINANCIAL GROUP INC	US74251V1026	10	06-15	STRYKER CORP	US8636671013	10	06-15
PROCTER & GAMBLE CO	US7427181091	10	06-15	SUNTRUST BANKS INC	US8679141031	10	06-15
PROGRESSIVE CORP/OH/	US7433151039	10	06-15	SYMANTEC CORP	US8715031089	10	06-15
SYSCO CORP	US8718291078	10	06-15	Viacom Inc.	US92553P2011	10	06-15
Scripps Networks Interactive, Inc.	US8110651010	7	09-15	Visa Inc.	US92826C8394	9	07-15
Seagate Technology	IE00B58JVZ52	10	06-15	Vulcan Materials CO	US9291601097	10	06-15

Spectra Energy Corp.	US8475601097	9	07-15	WAL MART STORES INC	US9311421039	10	06-15
Synchrony Financial	US87165B1035	1	15-15	WALT DISNEY CO/	US2546871060	10	06-15
TARGET CORP	US87612E1064	10	06-15	WASTE MANAGEMENT INC	US94106L1098	10	06-15
TE Connectivity Ltd.	CH0102993182	5	11-15	WATERS CORP /DE/	US9418481035	10	06-15
TECO ENERGY INC	US8723751009	10	06-15	WELLPOINT INC	US0367521038	10	06-15
TERADATA CORP /DE/	US88076W1036	8	08-15	WELLS FARGO & COMPANY/MN	US9497461015	3	13-15
TESORO CORP /NEW/	US8816091016	10	06-15	WESTERN DIGITAL CORP	US9581021055	10	06-15
TEXAS INSTRUMENTS INC	US8825081040	10	06-15	WEYERHAEUSER CO	US9621661043	10	06-15
TEXTRON INC	US8832031012	10	06-15	WHIRLPOOL CORP /DE/	US9633201069	10	06-15
THERMO ELECTRON CORP	US8835561023	10	06-15	WHOLE FOODS MARKET INC	US9668371068	10	06-15
TIFFANY & CO	US8865471085	10	06-15	WILLIAMS COMPANIES INC	US9694571004	10	06-15
TIME WARNER INC.	US8873173038	10	06-15	WYNDHAM WORLDWIDE CORP	US98310W1080	9	07-15
TJX COMPANIES INC /DE/	US8725401090	10	06-15	WYNN RESORTS LTD	US9831341071	10	06-15
TORCHMARK CORP	US8910271043	10	06-15	Walgreens Boots Alliance, Inc.	US9314271084	1	15-15
TOTAL SYSTEM SERVICES INC	US8919061098	10	06-15	WestRock Co	US96145D1054	1	15-15
TRACTOR SUPPLY CO /DE/	US8923561067	10	06-15	Western Union CO	US9598021098	9	07-15
TRAVELERS COMPANIES, INC.	US89417E1091	10	06-15	Under Armour, Inc.	US9043111072	10	06-15
TWENTY-FIRST CENTURY FOX, INC.	US90130A1016	10	06-15	Under Armour, Inc.	US9043112062	10	06-15
TWENTY-FIRST CENTURY FOX, INC.	US90130A2006	3	13-15	V F CORP	US9182041080	10	06-15
TYCO INTERNATIONAL LTD	IE00BQRQXQ92	10	06-15	VALERO ENERGY CORP/TX	US91913Y1001	10	06-15
TYSON FOODS INC	US9024941034	10	06-15	VARIAN MEDICAL SYSTEMS INC	US92220P1057	10	06-15
TransDigm Group INC	US8936411003	10	06-15	VENTAS INC	US92276F1003	10	06-15
Transocean Ltd.	CH0048265513	7	09-15	VERISIGN INC/CA	US92343E1029	10	06-15
TripAdvisor, Inc.	US8969452015	4	12-15	VERIZON COMMUNICATIONS INC	US92343V1044	10	06-15
UAL CORP /DE/	US9100471096	10	06-15	VERTEX PHARMACEUTICALS INC / MA	US92532F1003	10	06-15
UNION PACIFIC CORP	US9078181081	10	06-15	VORNADO REALTY TRUST	US9290421091	10	06-15
UNITED DOMINION REALTY TRUST INC	US9026531049	10	06-15	Verisk Analytics, Inc.	US92345Y1064	6	10-15
UNITED PARCEL SERVICE INC	US9113121068	10	06-15	XCEL ENERGY INC	US98389B1008	10	06-15
UNITED RENTALS NORTH AMERICA INC	US9113631090	10	06-15	XEROX CORP	US9841211033	10	06-15
UNITED TECHNOLOGIES CORP /DE/	US9130171096	10	06-15	XILINX INC	US9839191015	10	06-15
UNITEDHEALTH GROUP INC	US91324P1021	10	06-15	XL GROUP PLC	IE00B5LRL25	10	06-15
UNIVERSAL HEALTH SERVICES INC	US9139031002	10	06-15	Xylem Inc.	US98419M1009	4	12-15
UNUMPROVIDENT CORP	US91529Y1064	10	06-15	YAHOO INC	US9843321061	10	06-15
URBAN OUTFITTERS INC	US9170471026	10	06-15	YUM BRANDS INC	US9884981013	10	06-15
US BANCORP \DE\	US9029733048	10	06-15	ZIONS BANCORPORATION /UT/	US9897011071	10	06-15
Ultra Salon, Cosmetics & Fragrance, Inc.	US90384S3031	8	08-15	Zoetis Inc.	US98978V1035	3	13-15

11.2. Korrelationstabelle

Die Tabelle führt die Anzahl der korrelierenden Unternehmen mit den jeweiligen Clustersets beziehungsweise Optimierungsansätzen.

Kategorie	Alle Cluster	Adjektive	Wörterbücher	Keywords	SentiWordNet Positiv	SentiWordNet Negativ
Vor negativem RoA	46	49	40	49	44	42
RoA Negativ	22	15	23	25	21	19
Bestes Jahr	63	57	19	23	19	19
Bestes Jahr Folgejahr	23	18	58	63	60	52
Schlechtestes Jahr	26	27	29	28	30	20
Schlechtestes Jahr Folgejahr	28	21	24	27	23	26
Bestes vs. Schlechtestes Jahr	66	66	63	74	74	81

Selbstständigkeitserklärung

Ich versichere, dass ich die Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich reiche sie erstmals als Prüfungsleistung ein. Mir ist bekannt, dass ein Betrugsversuch mit der Note „nicht ausreichend“ (5,0) geahndet wird und im Wiederholungsfall zum Ausschluss von der Erbringung weiterer Prüfungsleistungen führen kann.

Franz Keilholz

Dresden, den 24. Januar 2017